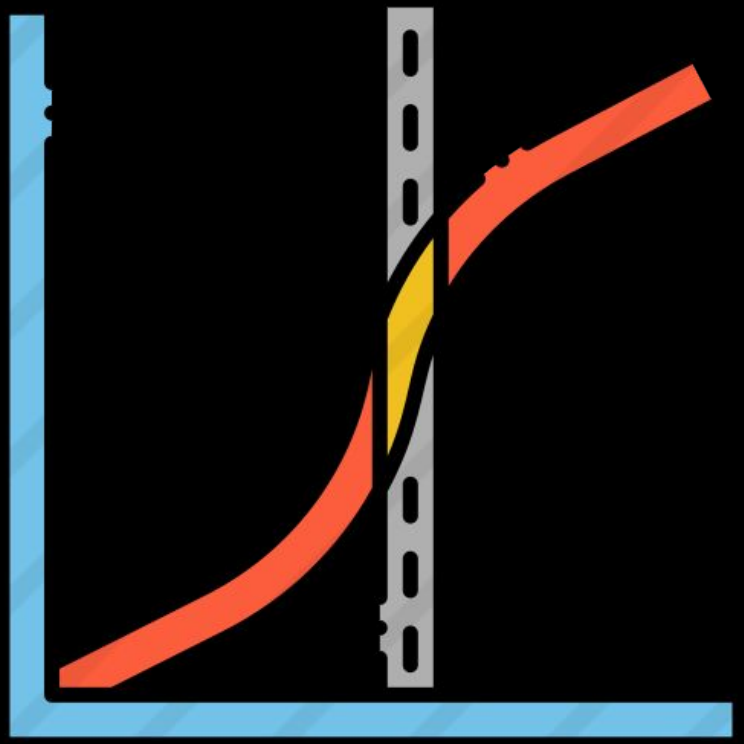
PUCP

INGENIERÍA INFORMÁTICA



Aprendizaje Automático

Unidad 4: Clasificación con Regresión Logística
Tema: Clasificación Binaria

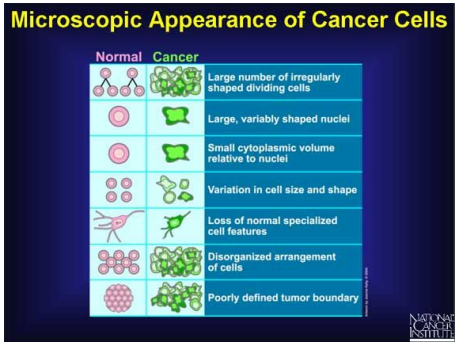
Prof. César A. Beltrán Castañón

Basado en material de Stanford University (by Andrew Ng)

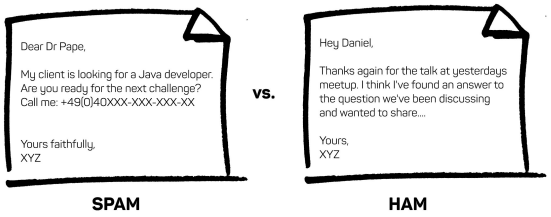
Clasificación

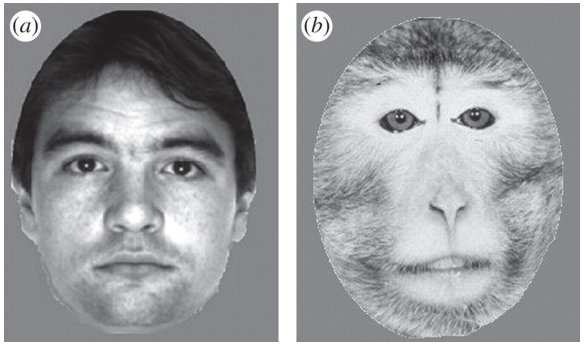
Problemas de Clasificación

- Células de Cáncer: **benigno** o **maligno**
- Correos: **spam** o **no spam**
- Reconocimiento de rostros: **humano** o **no humano**
- Análisis de sentimiento: **positivo** o **negativo**





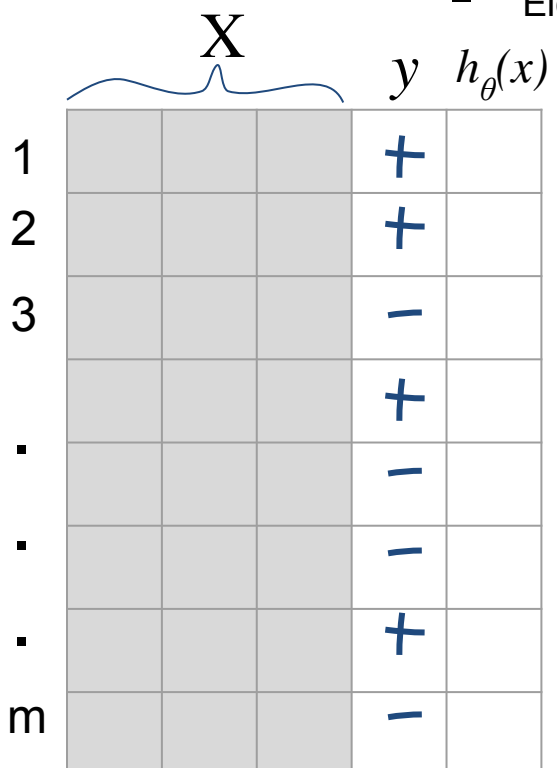




Clasificación

Clasificación Binaria

- Caso más simple de clasificación
- Lo que se quiere es: $0 <= h_\theta(x) <= 1$
  - Elemento **pertenece** a la clase si está próximo a 1
  - Elemento **NO pertenece** a la clase si está próximo a 0

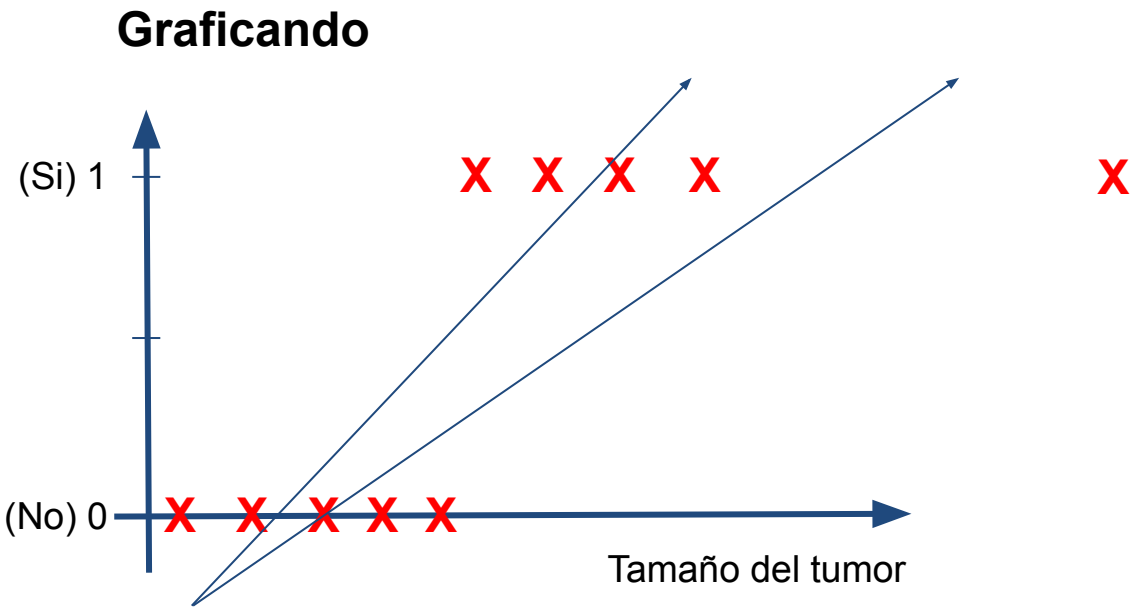


$y \in \{0, 1\}$

0 = “Clase Negativa”
(ejm: tumor benigno)

1 = “Clase Positiva”
(ejem: tumor maligno)

Clasificación

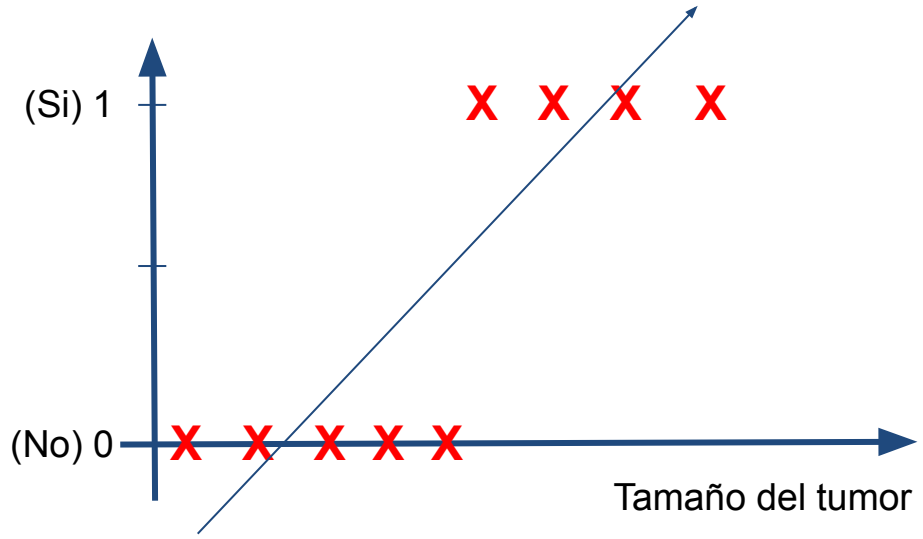


Limiar (threshold) de clasificación de $h_\theta(x)$ en 0.5:

Si $h_\theta(x) \geq 0.5$, predecir “y = 1”

Si $h_\theta(x) < 0.5$, predecir “y = 0”

Graficando



Clasificación

Resumiendo:

Se requiere que $y = 0$ ó $y = 1$

Pero $h_\theta(x)$ podría ser >1 ó <0

Cómo hacemos para que:

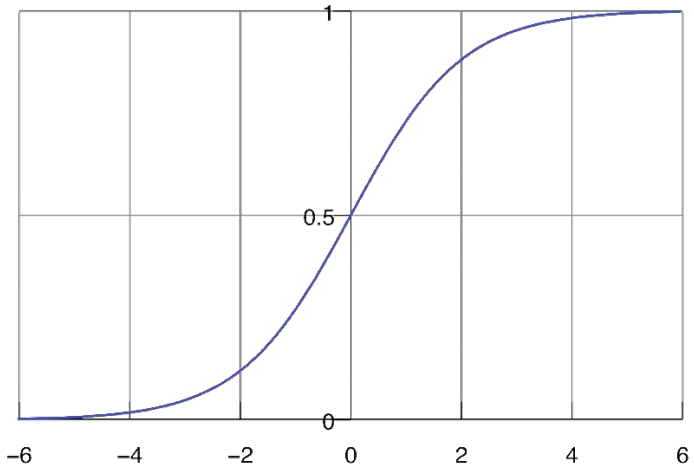
$$0 \leq h_\theta(x) \leq 1$$

Solución: **Regresión Logística**

Regresión Logística

$$g(z) = \frac{1}{1+e^{-z}}$$

- Mapea cualquier valor $\mathbb{R}$ dentro del intervalo [0;1]
- Asíntota 0, cuando $x \to -\infty$
- Asíntota 1, cuando $x \to \infty$



Función Sigmoidal (forma de S)
Función logística

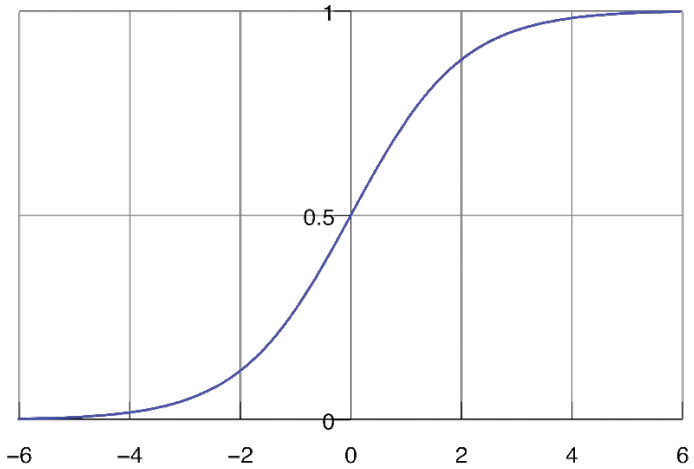
Regresión Logística

Representación de la nueva hipótesis

$$h_\theta(x) = \quad \theta^T x$$

$$h_\theta(x) = g(\theta^T x), \quad \text{Si } g(z) = \frac{1}{1+e^{-z}}$$

$$h_\theta(x) = \frac{1}{1 + e^{-\theta^T x}}$$



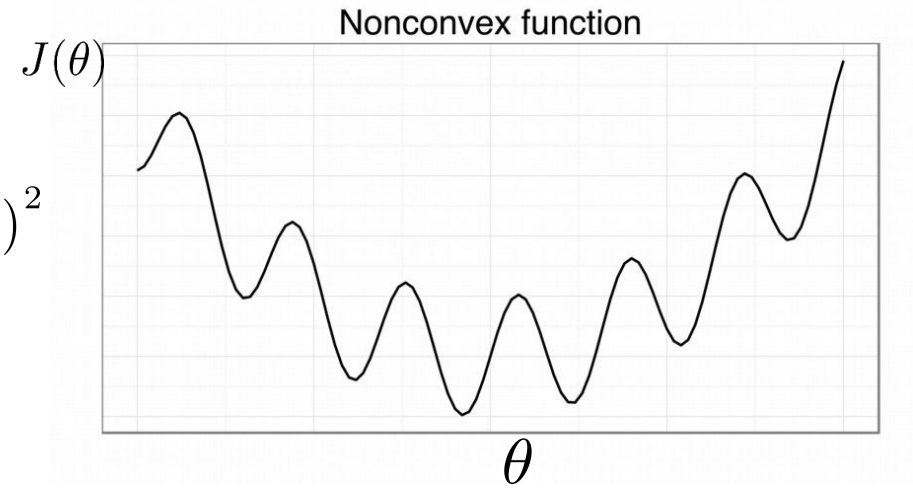
Regresión Logística
Función de costo

NO podemos usar la misma **función de costo** de Regresión Lineal Simple, porque la salida con Regresión Logística resulta en una **curva ondulada**, con muchos mínimos locales

$$J(\theta) = \frac{1}{m} \sum_{i=1}^{m} \frac{1}{2} \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2$$

$$\text{Cost}(h_\theta(x^{(i)}), y^{(i)}) = \frac{1}{2} \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2$$

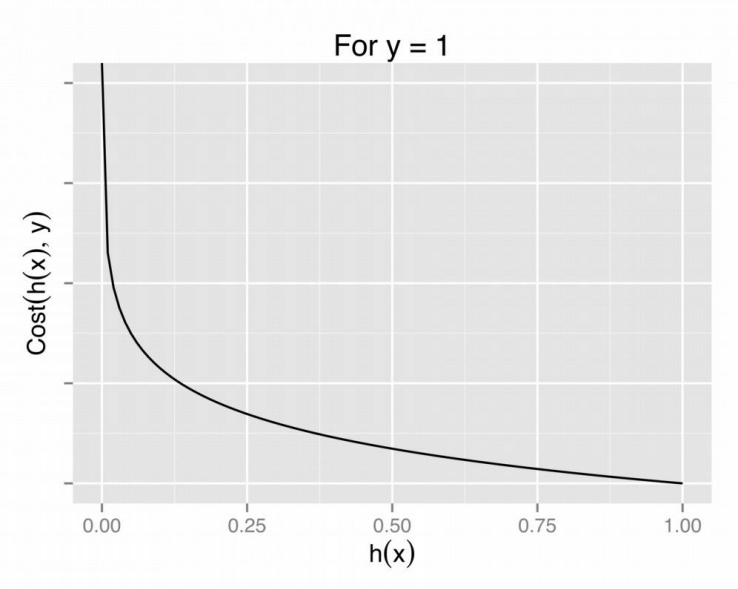
$$h_\theta(x) = \frac{1}{1+e^{-\theta^T x}}$$



Regresión Logística
Función de costo

$$Cost(h_\theta(x), y) = \begin{cases} -log(h_\theta(x)) & \text{if } y = 1 \\ -log(1 - h_\theta(x)) & \text{if } y = 0 \end{cases}$$

Si $y = 1$

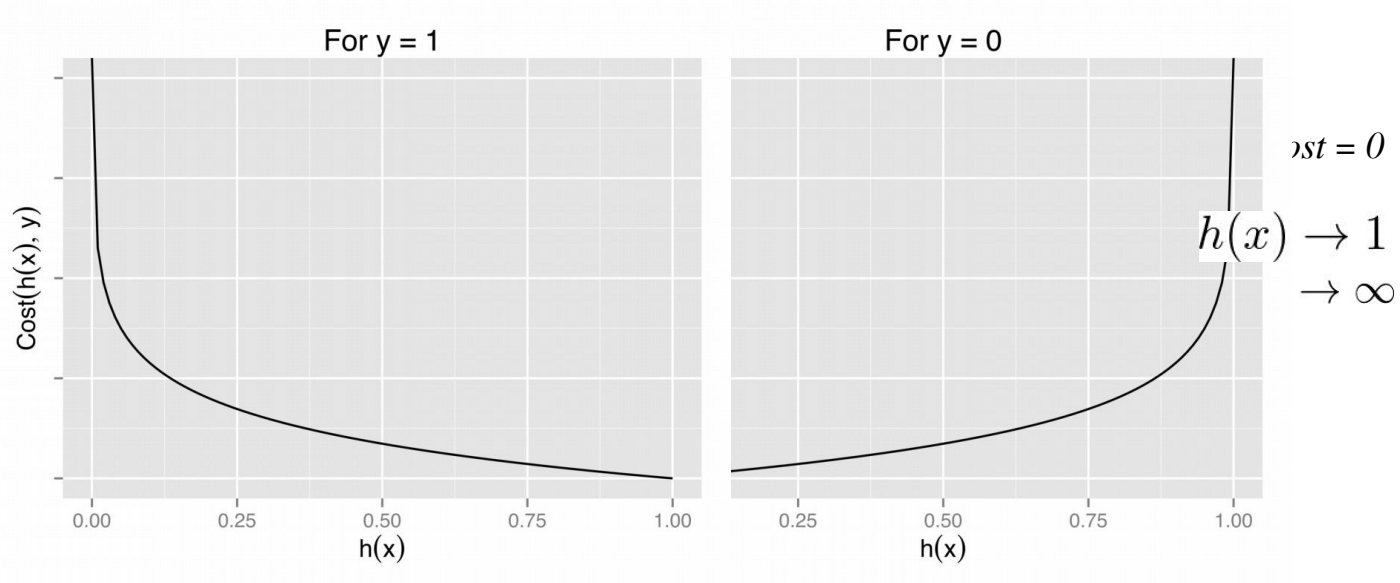


- Si $y = 1$ y $h(x) = 1$, $Cost = 0$
- Pero, cuando $h(x) \to 0$
  $Cost \to \infty$
- Interpretando: Si la predicción $h(x) = 0$, pero el valor real fue de $y = 1$, el algoritmo de aprendizaje penalizará con un costo alto.

Regresión Logística
Función de costo

$$Cost(h_\theta(x), y) = \begin{cases} -log(h_\theta(x)) & \text{if } y = 1 \\ -log(1 - h_\theta(x)) & \text{if } y = 0 \end{cases}$$

Si $y = 0$



Regresión Logística
Gradiente Descendente

- función de costo para todo el conjunto de entrenamiento:

$$J(\theta) = \frac{1}{m}\sum_{i=1}^{m} Cost(h_\theta(x^{(i)}), y^{(i)})$$

$$= -\frac{1}{m}\left(\sum_{i=1}^{m} y^{(i)}\ log(h_\theta(x^{(i)})) + (1-y^{(i)}) log(1-h_\theta(x^{(i)}))\right)$$

- Entonces, nuestro objetivo es ajustar los parámetros θ con el fin de minimizar la función de costo :

$$\min_\theta J(\theta)$$

- Así, poder realizar predicciones dado un nuevo x:

Salida $h_\theta(x) = \frac{1}{1+e^{-\theta^T x}}$

Regresión Logística
Algoritmo Gradiente Descendente

- Dada la función de costo

$$J(\theta) = -\frac{1}{m}[\sum_{i=1}^{m} y^{(i)} \log h_\theta(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_\theta(x^{(i)}))]$$

- Se quiere $\min_\theta J(\theta)$

- El algoritmo consiste en:

Repetir hasta converger $\{$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} \left((h_\theta(x_i) - y_i) x_i \right)$$

$\}$ (actualizando simultáneamente todos los θ_J)

El algoritmo es idéntico al de Regresión Lineal!!!

http://sambfok.blogspot.pe/2012/08/partial-derivative-logistic-regression.html

Regresión logística multinomial

Softmax

La regresión **softmax** (o **regresión logística multinomial**) no es más que una generalización de la regresión logística cuando tenemos más de dos clases distintas.

Si tenemos K clases,
tendremos K vectores de parámetros θ_k:

$$h_\theta(x) = \begin{bmatrix} P(y=1 \mid x) \\ P(y=2 \mid x) \\ \mathrm{M} \\ P(y=K \mid x) \end{bmatrix} = \frac{1}{\sum_{j=1}^{K} e^{\theta_j^T x}} \begin{bmatrix} e^{\theta_1^T x} \\ e^{\theta_2^T x} \\ \mathrm{M} \\ e^{\theta_K^T x} \end{bmatrix}$$

$$softmax(\hat{y}_i) = \frac{e^{\hat{y}_i}}{\sum_j e^{\hat{y}_j}}$$

Función de costo: Cross-Entropy

La función de coste asociada a la regresión logística la podríamos reescribir como:

$$J(\theta) = -\sum_i \left(y_i \log h_\theta(x_i) + (1 - y_i)(1 - \log h_\theta(x_i)) \right)$$

$$= -\sum_i t_i \log P(t_i \mid x_i)$$

Extendiendo esta función de coste a la regresión softmax, la función de coste resultante es, como esperamos, la entropía cruzada:

$$C = J(\theta) = -\sum_i t_i \log P(t_i \mid x_i) = -\sum_j t_j \log y_j$$

Resumiendo

- Hemos definido una función de hipótesis
- Se tiene definida una función de costo
- Se extiende la regresión para clasificación (logística)
- Extendemos regresión logística para clasificación multi-clase.
- Softmax (regresión logística multimodal) y cross-entropy como función de costo