Pontificia Universidad Católica del Perú
Facultad de Ciencias e Ingeniería
Departamento Académico de Ingeniería



INF659 TÉCNICAS AVANZADAS DE DATA MINING Y SISTEMAS INTELIGENTES

Fundamentos Estadísticos y Autoencoders

Prof. Rodrigo Uribe

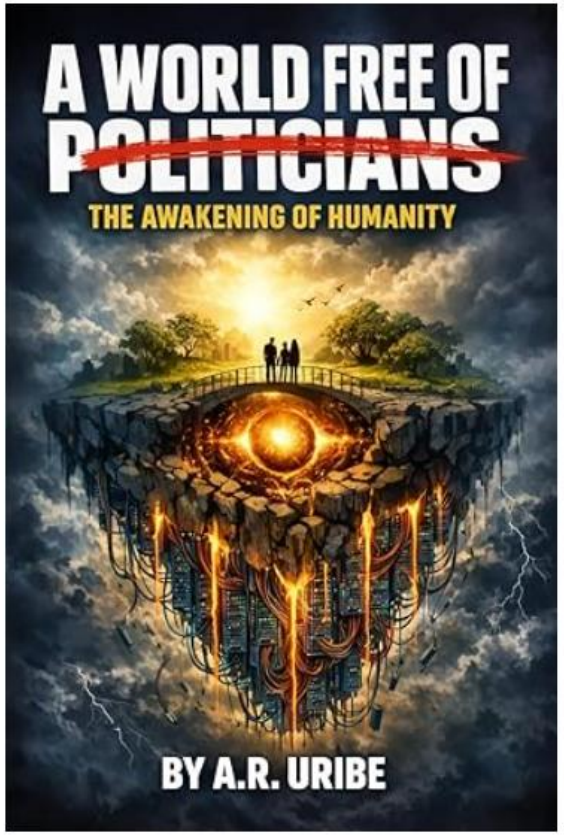
Acerca del Profesor (Rodrigo Uribe)



Doctor en Ingeniería, especializado en Geoestadística Aplicada e Inteligencia Artificial. Docente en la PUCP, UNI y URP, enfoca su investigación en el modelamiento geológico.

- Doctorado en Ingeniería - PUCP
- Tesis doctoral: "Data-Driven Geological Modeling in the Era of Deep Learning"
- Estudios profesionales en inteligencia artificial - Universidad de Stanford (EEUU)
- Maestría en geoestadística - Universidad Adolfo Ibáñez (Chile)

Recientemente escritor de ciencia ficción



A World Free of Politicians (IO Sci-Fi Saga Book 1) Kindle Edition

by A.R. Uribe (Author) | Format: Kindle Edition

4.8 ★★★★★ (5)

Book 1 of 1: IO Sci-Fi Saga

See all formats and editions

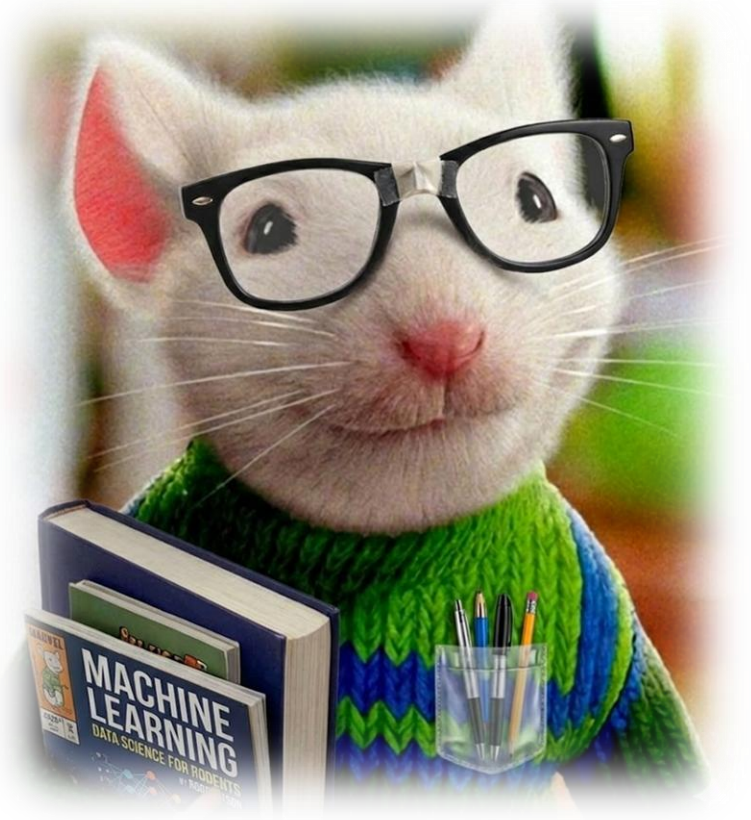
When we cannot exist without our devices, who truly holds the power?
In the not-so-distant future, Technodemocracy promises flawless justice and progress, having replaced corrupt politicians with a seemingly perfect algorithmic System. But beneath its polished surface, that perfection is beginning to fracture.

Abigail, a System analyst, uncovers a critical flaw that could bring the entire structure crashing down. After moving to the city, her daughter, **Aga**, begins her own journey of self-discovery—one that forces her to confront the darker truths of the society her mother is sworn to protect.

Meanwhile, thousands of kilometers away in Antarctica, **Clarens** leads an expedition seeking freedom from the System's reach, aided by a mysterious community led by "angels". When their stories collide, a desperate struggle for truth and liberty erupts, threatening their lives and the future of every citizen living under the watchful eye of Technodemocracy.

Read more

Acerca de Ustedes



(Nombre) Nombre

(Personal) Algo sobre ti

(Curso) Algo interesante hasta ahora

(Trabajo Grupo) Como va el grupo

Organización de las Clases

(10 min) Preguntas y consultas.

(30 min) Respuesta *Vibe Quest.*

(45 min) Introducción Al tema de la clase y desarrollo.



(10 min) Break

(45 min) Continuación y aplicaciones asociadas.

(30 min) Ejercicios y/o Dinámica.

(10 min) Preguntas *Vibe Quest.*

¿Qué es *vibe coding*?



Andrej Karpathy 
@karpathy

Promote

There's a new kind of coding I call "vibe coding", where you fully give in to the vibes, embrace exponentials, and forget that the code even exists. It's possible because the LLMs (e.g. Cursor Composer w Sonnet) are getting too good. Also I just talk to Composer with SuperWhisper so I barely even touch the keyboard. I ask for the dumbest things like "decrease the padding on the sidebar by half" because I'm too lazy to find it. I "Accept All" always, I don't read the diffs anymore. When I get error messages I just copy paste them in with no comment, usually that fixes it. The code grows beyond my usual comprehension, I'd have to really read through it for a while. Sometimes the LLMs can't fix a bug so I just work around it or ask for random changes until it goes away. It's not too bad for throwaway weekend projects, but still quite amusing. I'm building a project or webapp, but it's not really coding - I just see stuff, say stuff, run stuff, and copy paste stuff, and it mostly works.

Vibe coding

From Wikipedia, the free encyclopedia



This article **may contain an excessive number of citations**. Please help remove low-quality or irrelevant citations. *(June 2025)* (*Learn how and when to remove this message*)

Vibe coding (or **vibecoding**) is an approach to producing software by using artificial intelligence (AI), where a person describes a problem in a few natural language sentences as a prompt to a large language model (LLM) tuned for coding. The LLM generates software based on the description, shifting the programmer's role from manual coding to guiding, testing, and refining the AI-generated source code.[1][2][3]

Advocates of vibe coding say that it allows even amateur programmers to produce software without the extensive training and skills required for software engineering.[4] The term was introduced by Andrej Karpathy in February 2025[5][2][4][1] and listed in the Merriam-Webster Dictionary the following month as a "slang & trending" noun.[6]

Thomas Wolf
@Thom_Wolf

we've seen nothing yet! hosted a 9-13 yo vibe-coding event w. @robertkeus this w-e (h/t @antonosika @LovableBuild)

takeaway? AI is unleashing a generation of wildly creative builders beyond anything I'd have imagined

and they grow up *knowing* they can build anything!



Demo de Vibe Quest



Comencemos entonces...

(para que empiecen a ganarse sus puntos)

Dinámica Grupal: Encuentra la regla…

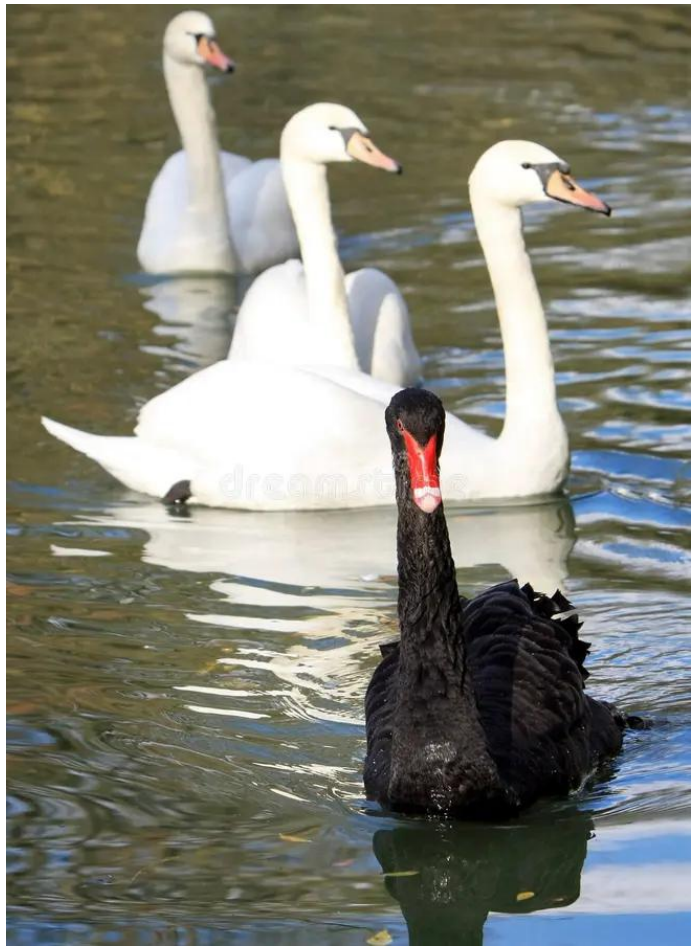
Voy a darles tres números. Una secuencia de tres números que obedecen a una regla que tengo en mente y quiero que intenten descubrir cuál es esa regla.

1. Primero proponen su propio conjunto de tres números
2. Les diré si siguen mi regla o no
3. Luego pueden adivinar cuál es la regla

Secuencia inicial: 2, 4, 8

El problema de la inducción

- "Cisne Negro" es un evento improbable, de alto impacto y solo predecible retrospectivamente
- Por muchos cisnes blancos que observemos, nunca podemos probar que "todos los cisnes son blancos“
- Basta un solo cisne negro para refutar la teoría



El modelo científico

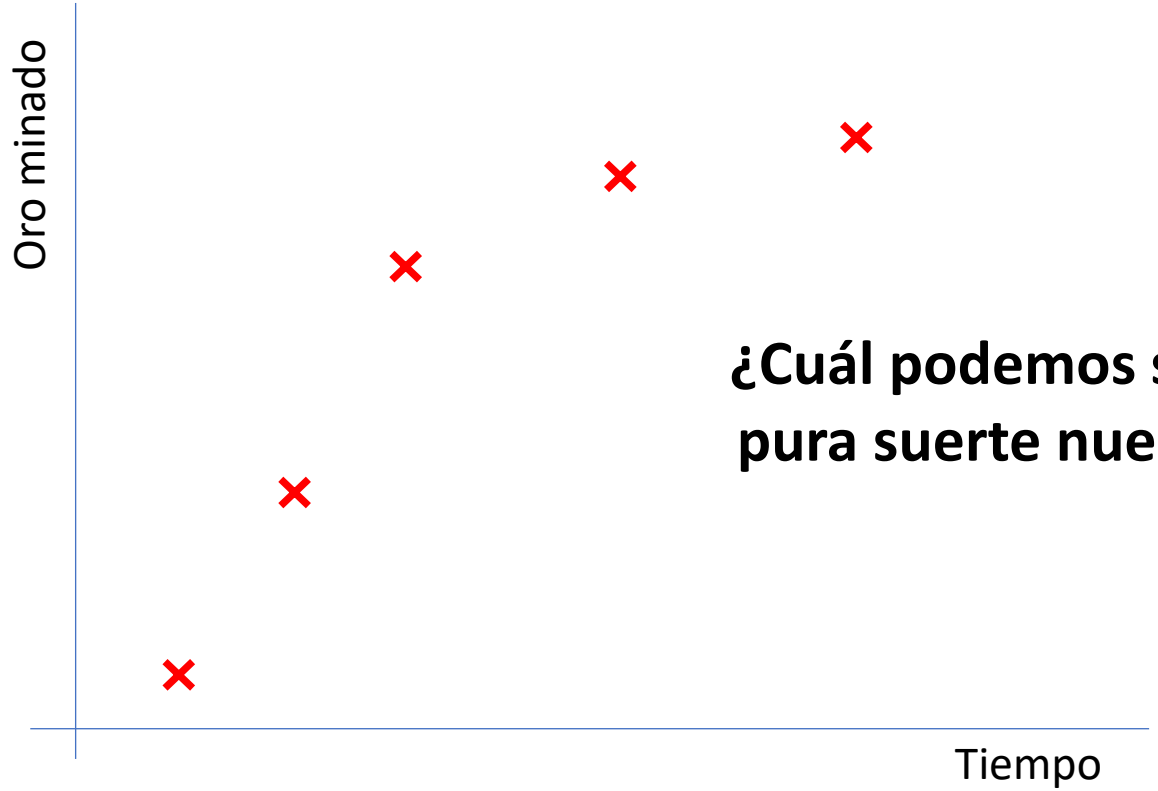
- Las teorías científicas nunca pueden ser probadas como definitivamente correctas
- Solo pueden ser falsadas (criterio de Popper)
- La ciencia avanza no por verificación absoluta, sino por eliminación de teorías falsas
- La ciencia es la creencia en la evidencia



¿Qué hacer si no hay suficientes datos (evidencias)?

Ejemplo:

¿Cuánto Oro queda para seguir minando?



¿Cuál podemos saber que no es pura suerte nuestra respuesta?

¿Cómo podemos afirmar algo?



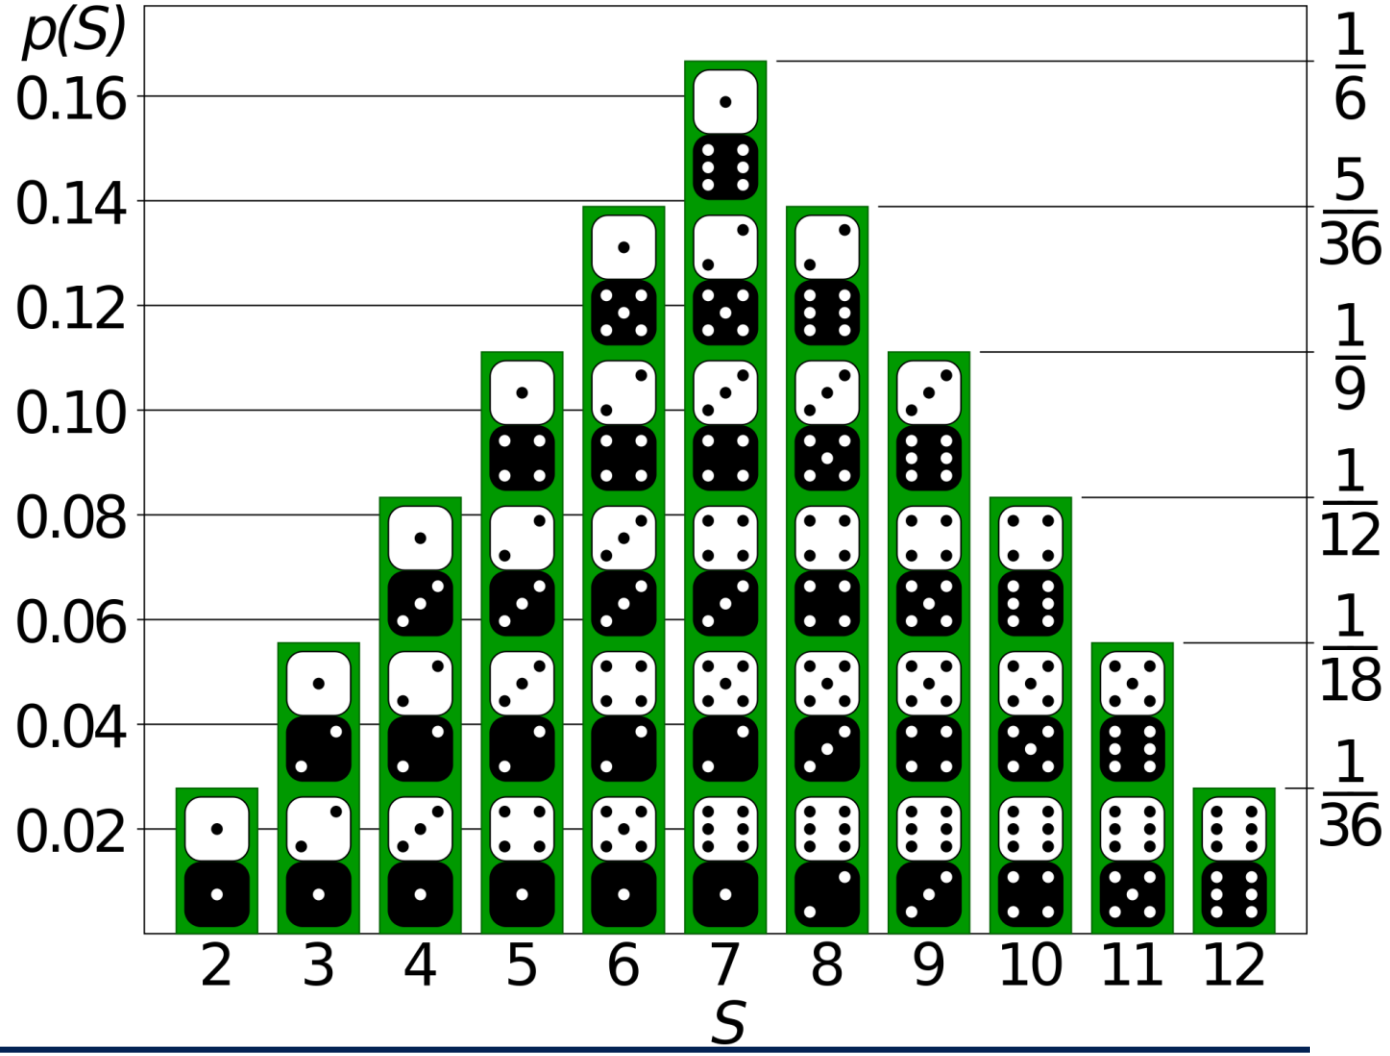
https://www.youtube.com/watch?v=JAS2MjcDrco

¿Qué es probabilidad? (ejemplo del dado)

Definición formal de probabilidad

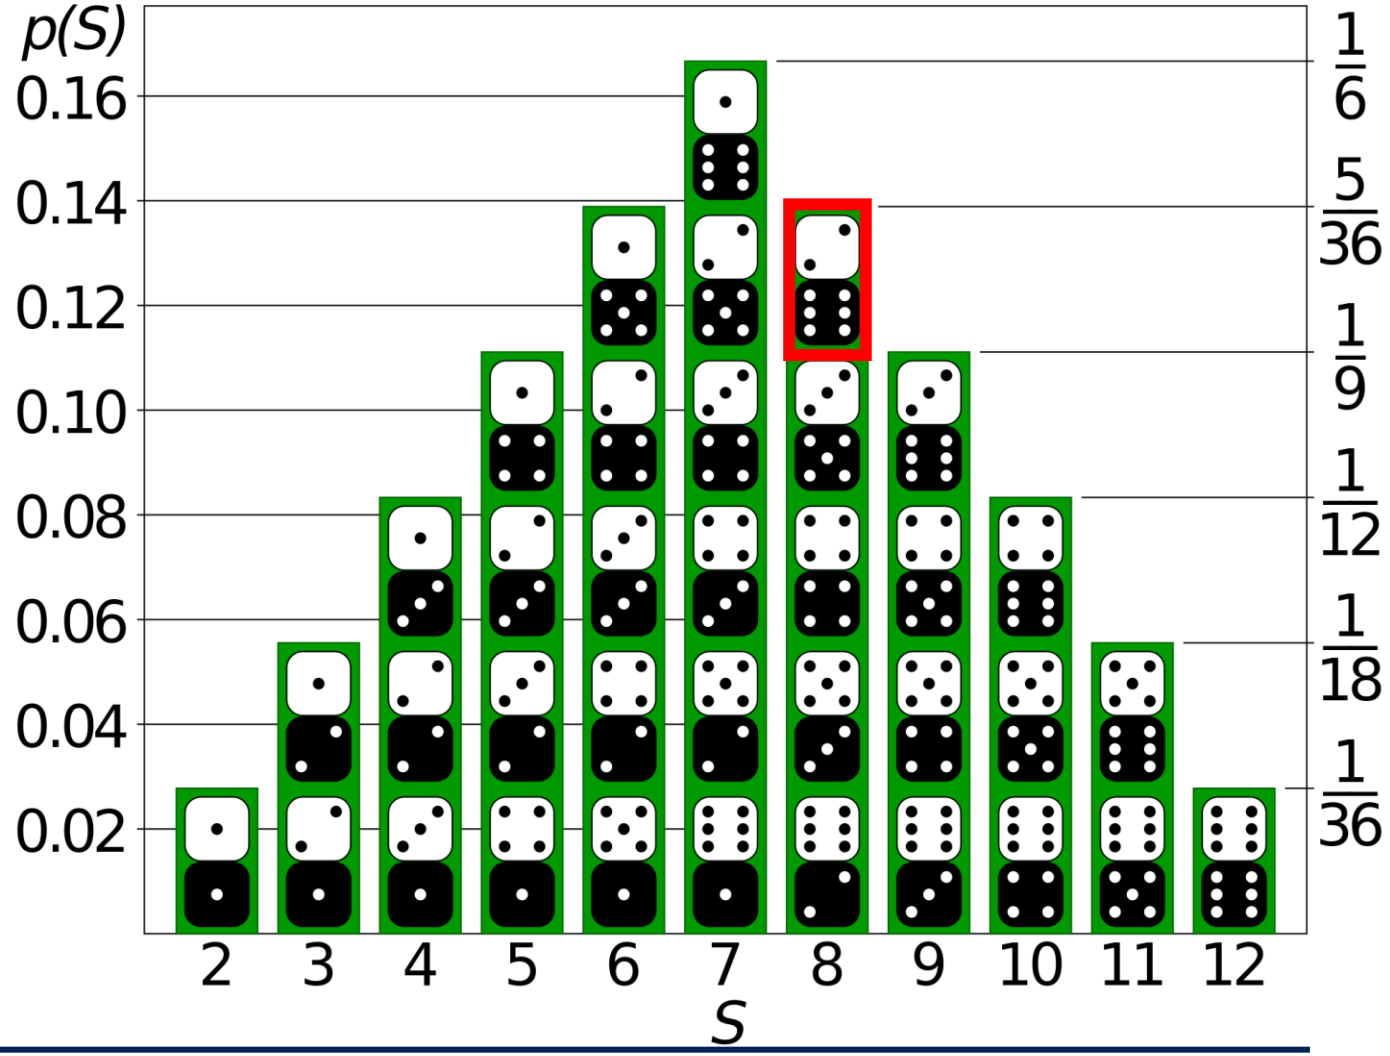
- La probabilidad de un **evento aleatorio** calcula como:
  - $P(A) = \frac{resultados\ deseados}{resultados\ totales}$
- **Eventos Independientes**: la ocurrencia de uno no afecta al otro.
  - $P(A \text{ y } B) = P(A) \times P(B)$
- **Eventos Mutuamente Excluyentes**: no pueden ocurrir al mismo tiempo.
  - $P(A \text{ y } B) = 0$

¿Cuál es la probabilidad de sacar un valor de 6 dado que el primer valor salga 2?



Definición formal de probabilidad

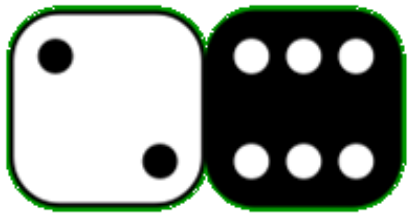
- La probabilidad de un **evento aleatorio** calcula como:
  - $P(A) = \frac{resultados\ deseados}{resultados\ totales}$
- **Eventos Independientes**: la ocurrencia de uno no afecta al otro.
  - $P(A \text{ y } B) = P(A) \times P(B)$
- **Eventos Mutuamente Excluyentes**: no pueden ocurrir al mismo tiempo.
  - $P(A \text{ y } B) = 0$
- **Probabilidad Condicional**: probabilidad de A dado que B ya ocurrió.
  - $P(A|B) = P(A \text{ y } B) / P(B)$



Punto de vista de la teoría de la información

Probabilidad:

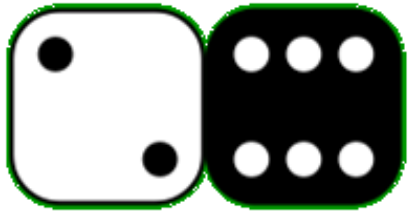
 : 1/6

 : 1/36

¿Es igual de **inesperado** sacar un solo 6 que sacar 6 y 2? ¿O es seis veces menos inesperado?

Punto de vista de la teoría de la información

$$I(x) = \log \frac{1}{P(x)}$$

Probabilidad:	Información:
 : 1/6	: $\log_2(6) \approx 2.58$ bits
 : 1/36	: $\log_2(36) \approx 5.17$ bits

Intuición sobre la información o “sorpresa”

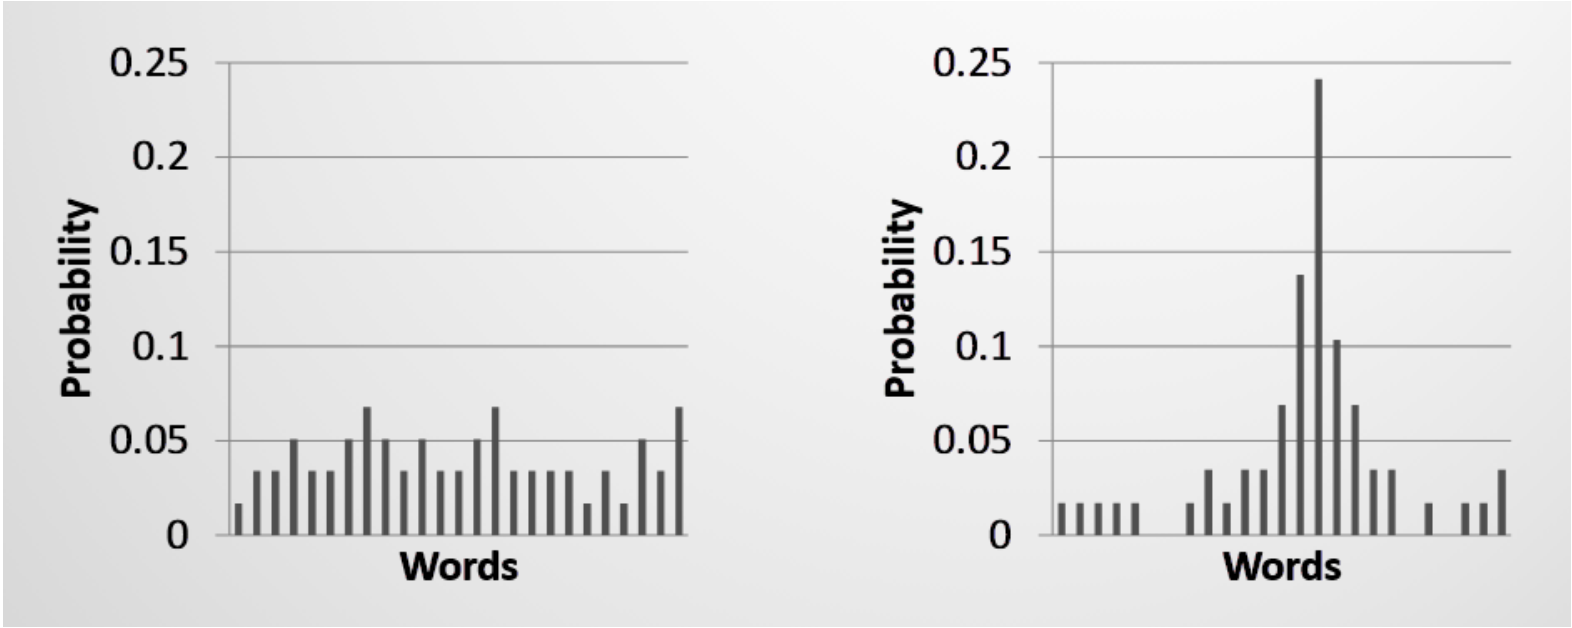
$$I(x) = \log \frac{1}{P(x)}$$

Probabilidad:	Información:
Siempre pasa : 1/1	: $\log_2(1) = 0$ bits
Una moneda al aire : 1/2	: $\log_2(2) = 1$ bits
Nunca pasa : 0/1	: $\log_2(1/0) = \infty$ bits

Se puede tomar como una medición de “sorpresa”

Entropía como “sorpresa promedio”

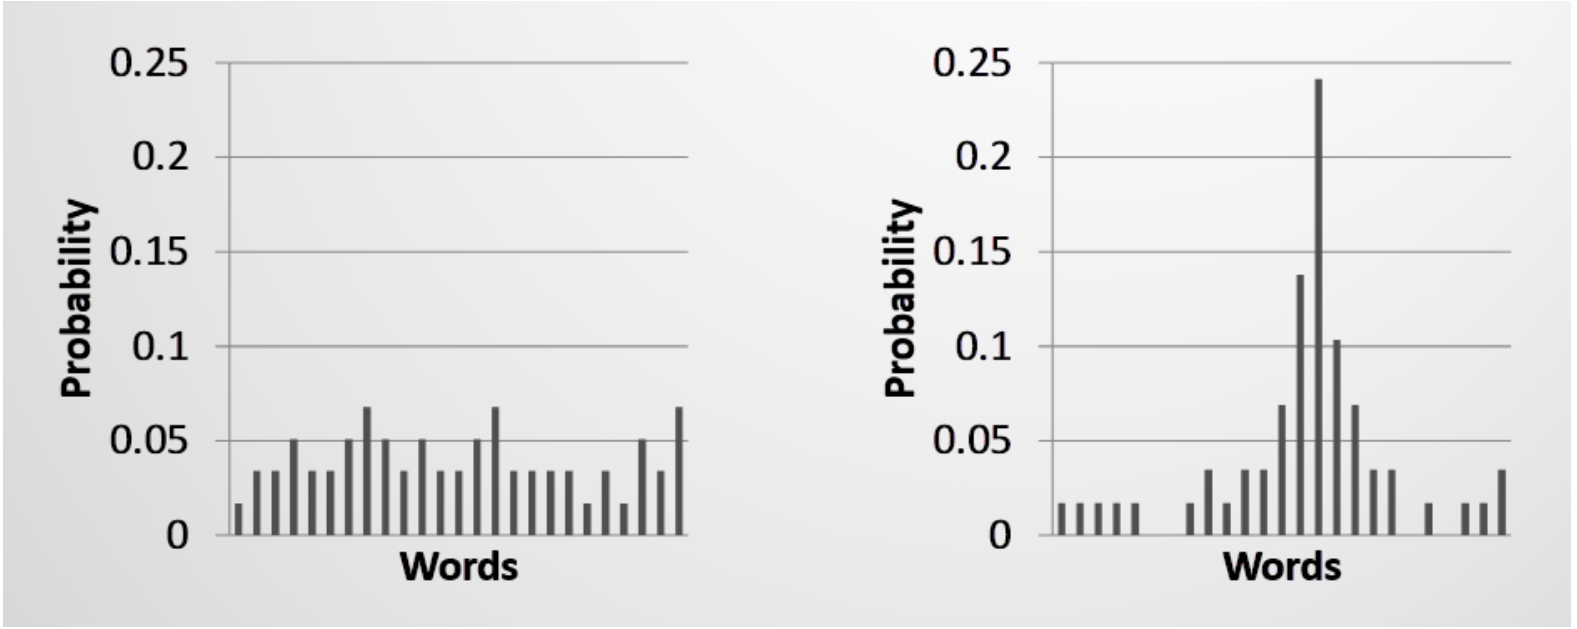
$$H(P) = \sum_i P(x_i) \log \frac{1}{P(x_i)}$$



¿Cuál de estas distribuciones tiene menor entropía?

Entropía como “sorpresa promedio”

baja entropía ≡ menor incertidumbre



Alta entropía

Baja entropía

Entropía cruzada como “sorpresa de los datos”

$$H(P,Q) = \sum_i P(x_i) \log \frac{1}{Q(x_i)}$$

La creencia

Los datos

¿Por qué usamos entropía cruzada?

Entropía cruzada como “sorpresa de los datos”

$$H(P,Q) = \sum_i P(x_i) \log \frac{1}{Q(x_i)}$$

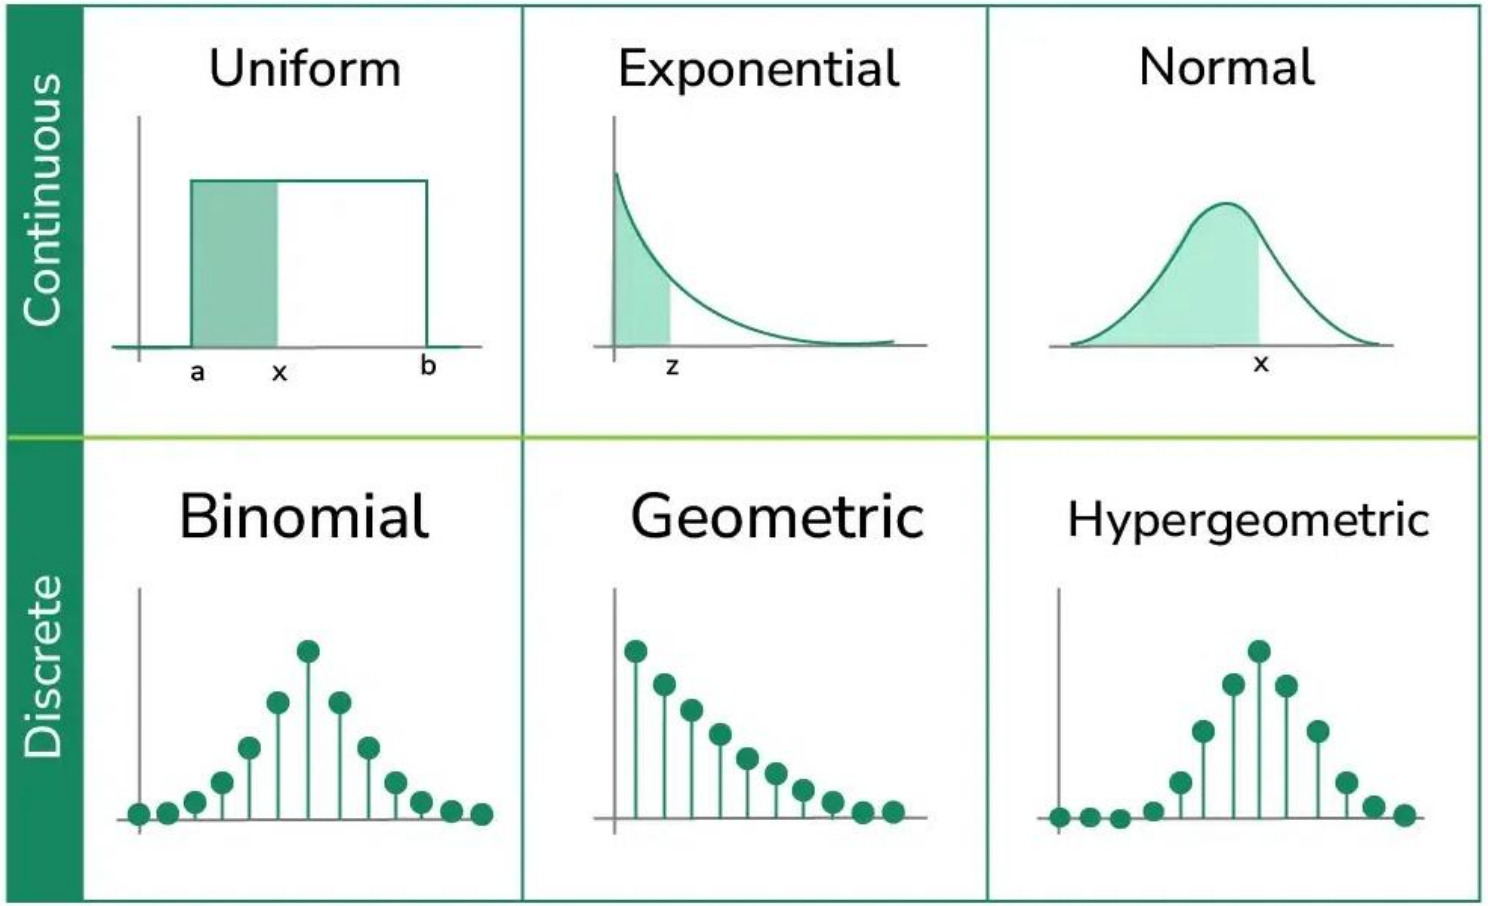
La creencia (one hot encoding es alta entropía)

Los datos (la “probabilidad” que al ser baja entropía)

¿Por qué usamos entropía cruzada para clasificación?

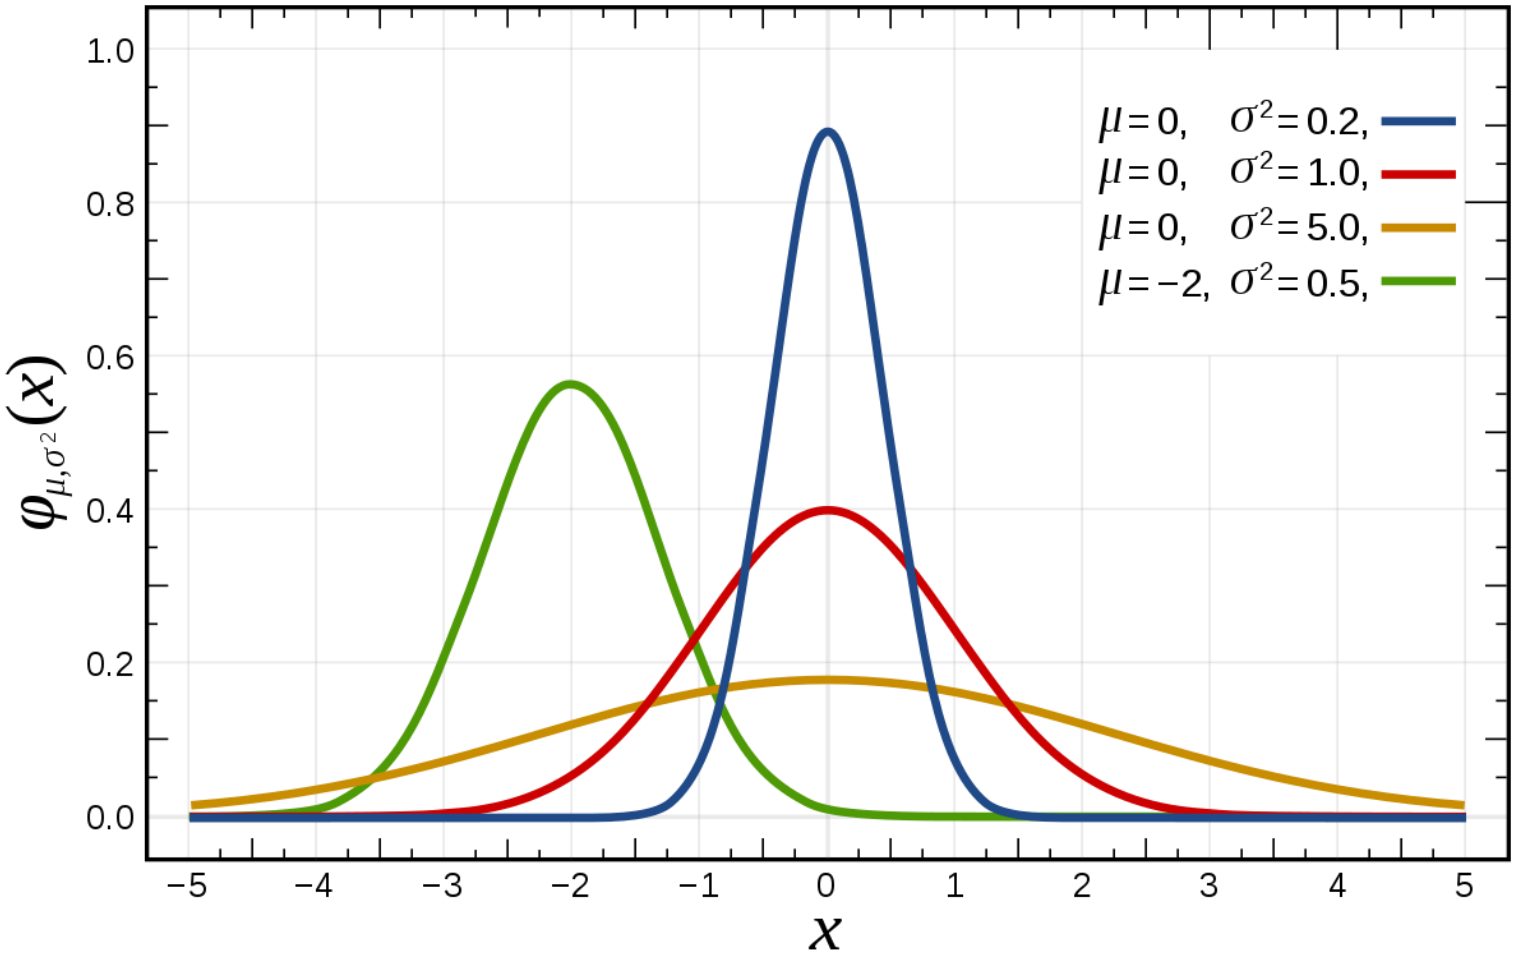
Distribución de Probabilidad

- Representa grandes conjuntos de datos con solo unos pocos parámetros
- Simplifica información compleja de manera extraordinariamente eficiente
- Permite modelar y predecir poblaciones enteras con mínimos recursos



¿Por qué usar distribuciones es poderoso?

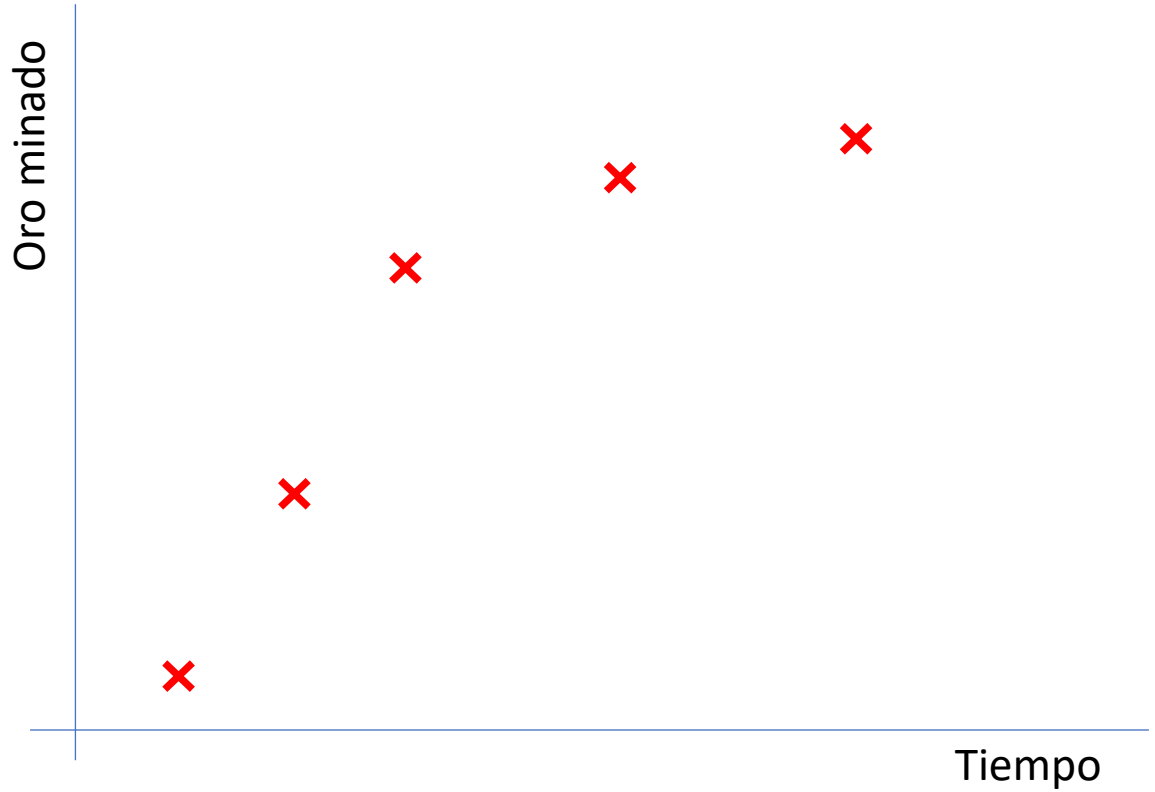
Una distribución “reduce” el problema y da una solución “probabilística”



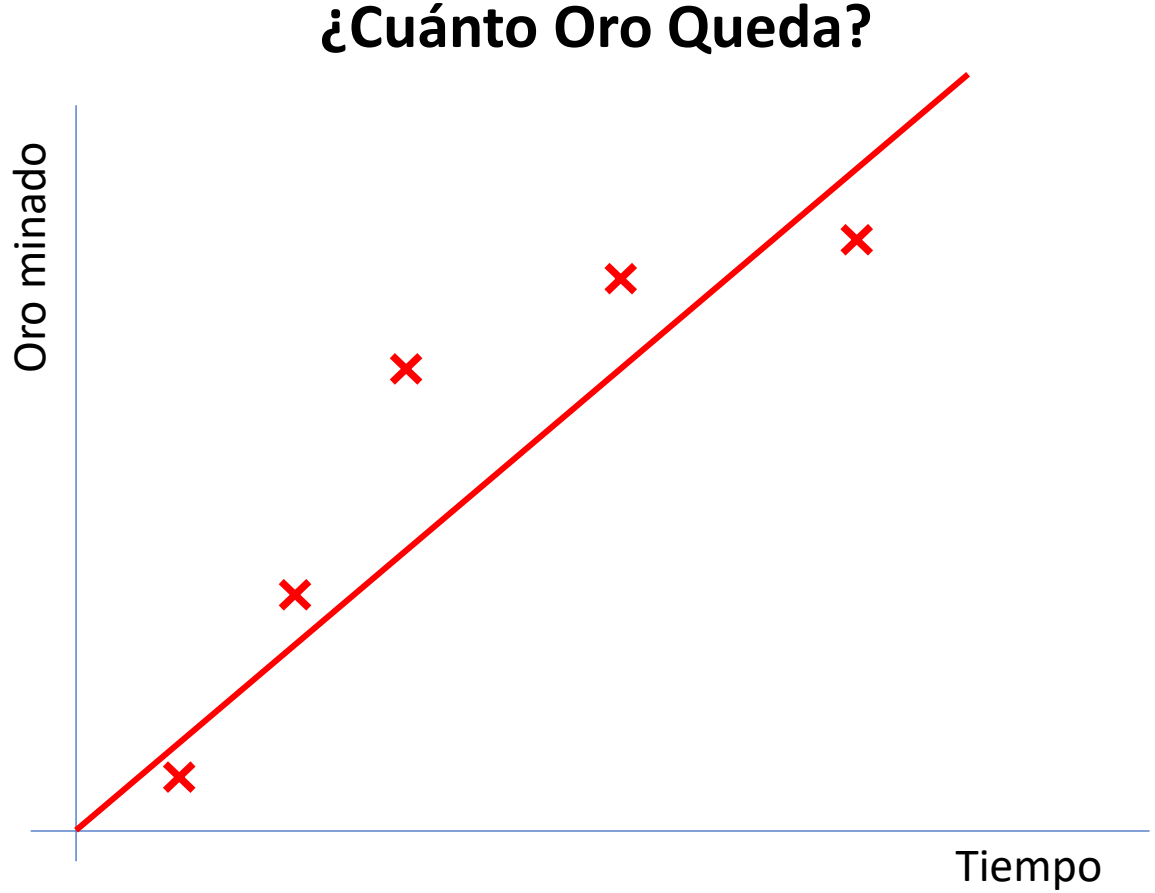
¿Qué hacemos en la realidad?

¿Qué modelamos? - intuición

¿Cuánto Oro Queda?

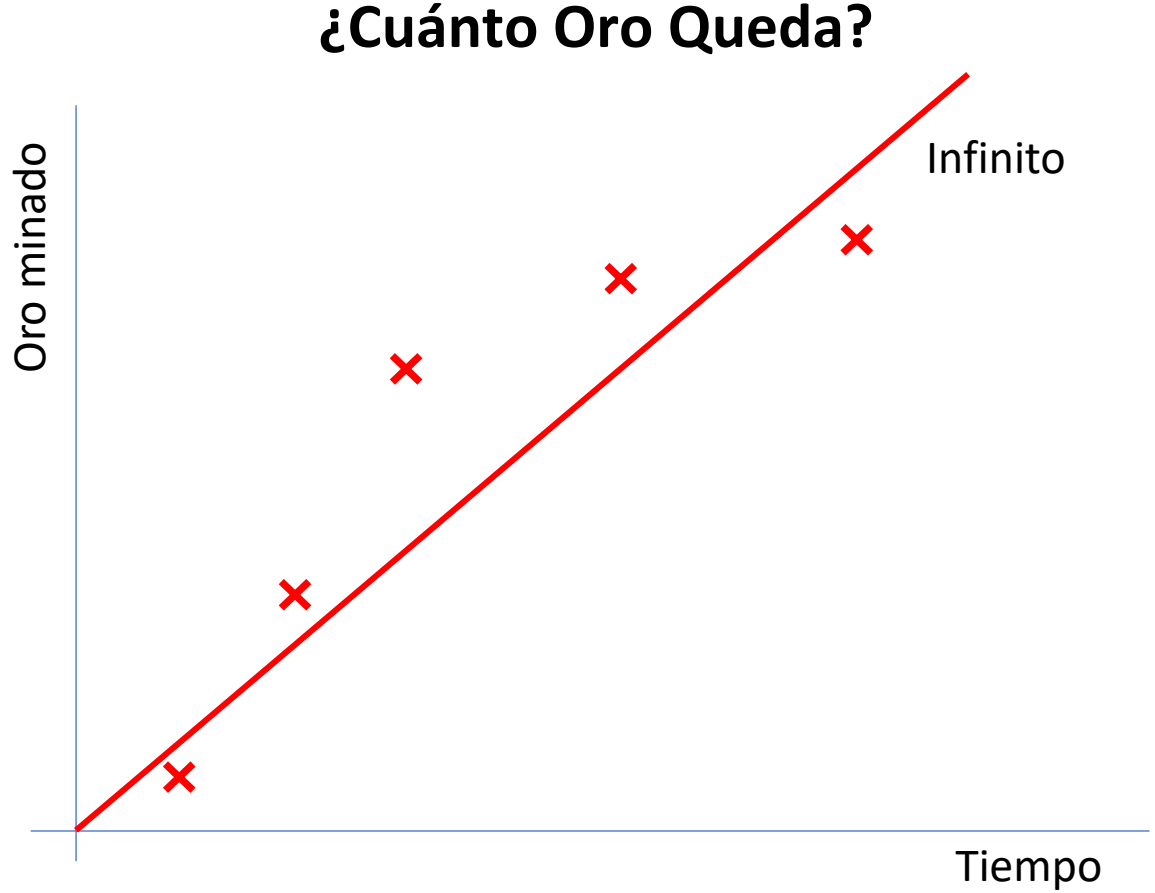


¿Qué modelamos? - intuición



¿Por qué este modelo no es ideal?

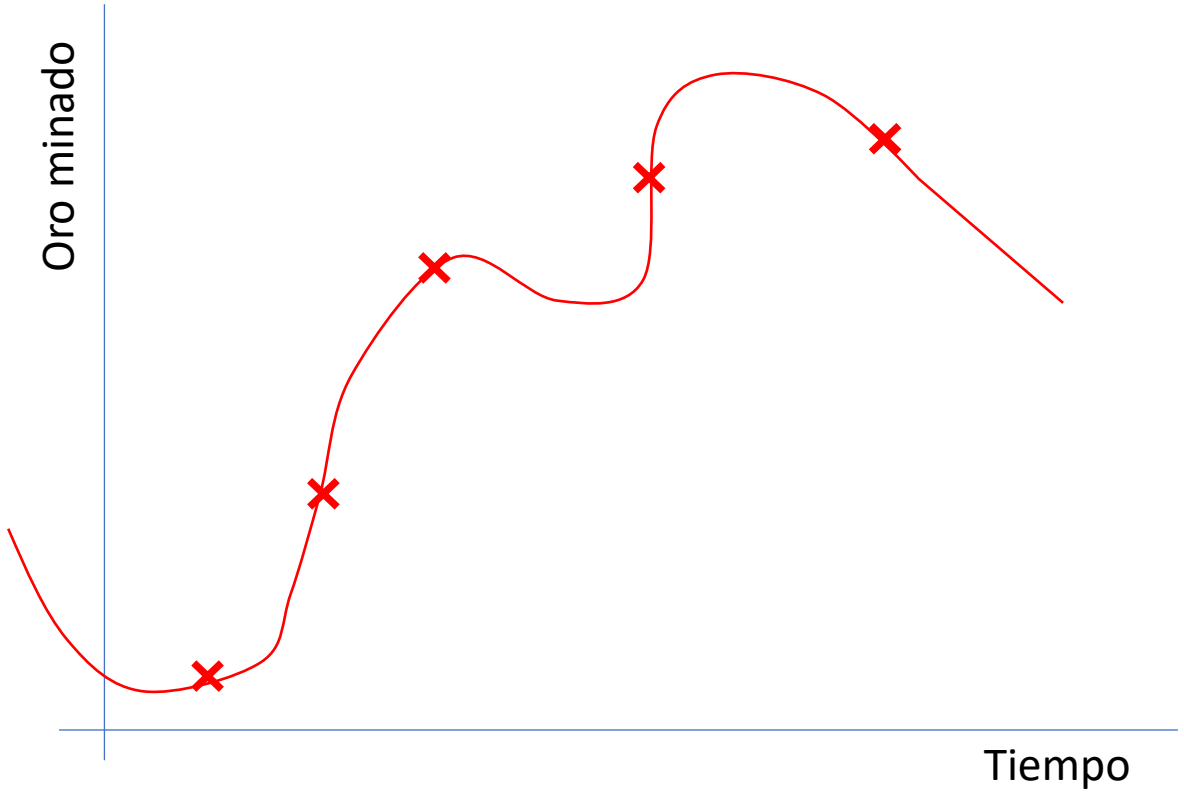
¿Qué modelamos? - intuición



¿Por qué este modelo no es ideal?

¿Qué modelamos? - intuición

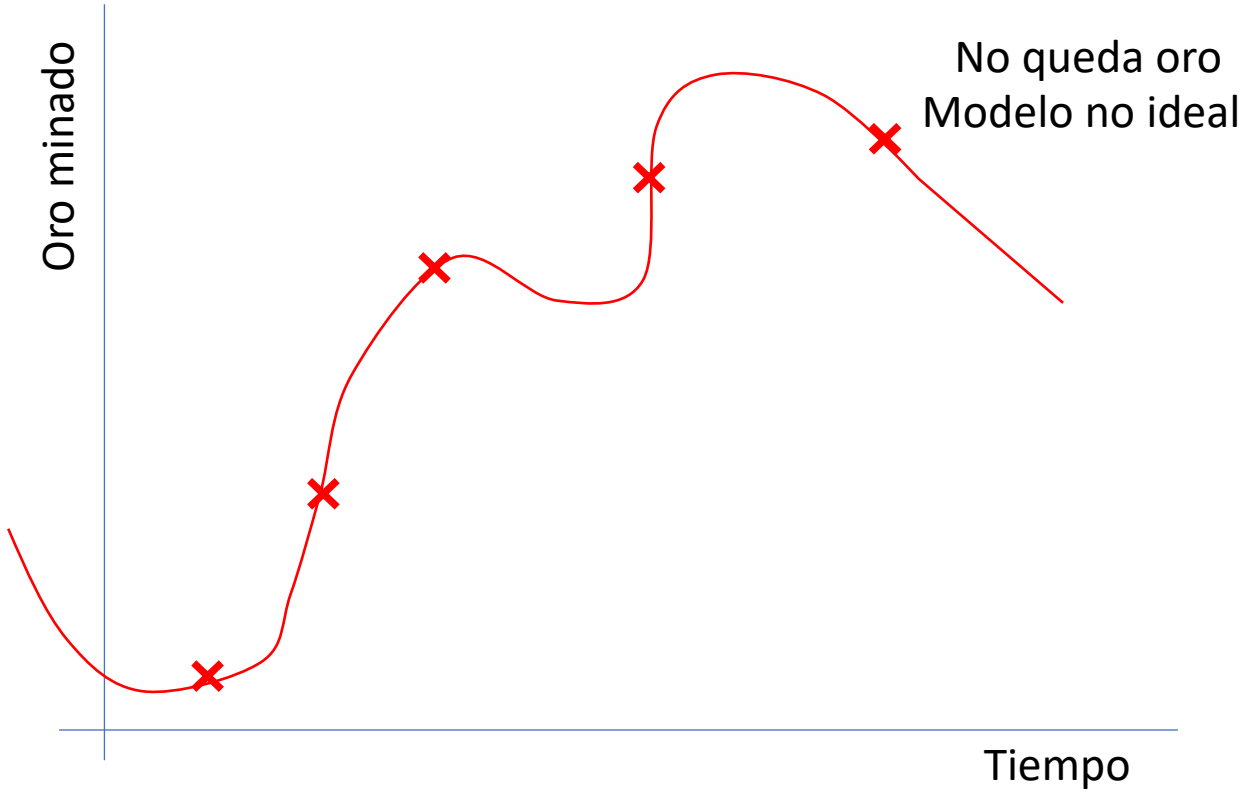
¿Cuánto Oro Queda?



¿Por qué este modelo no es ideal?

¿Qué modelamos? - intuición

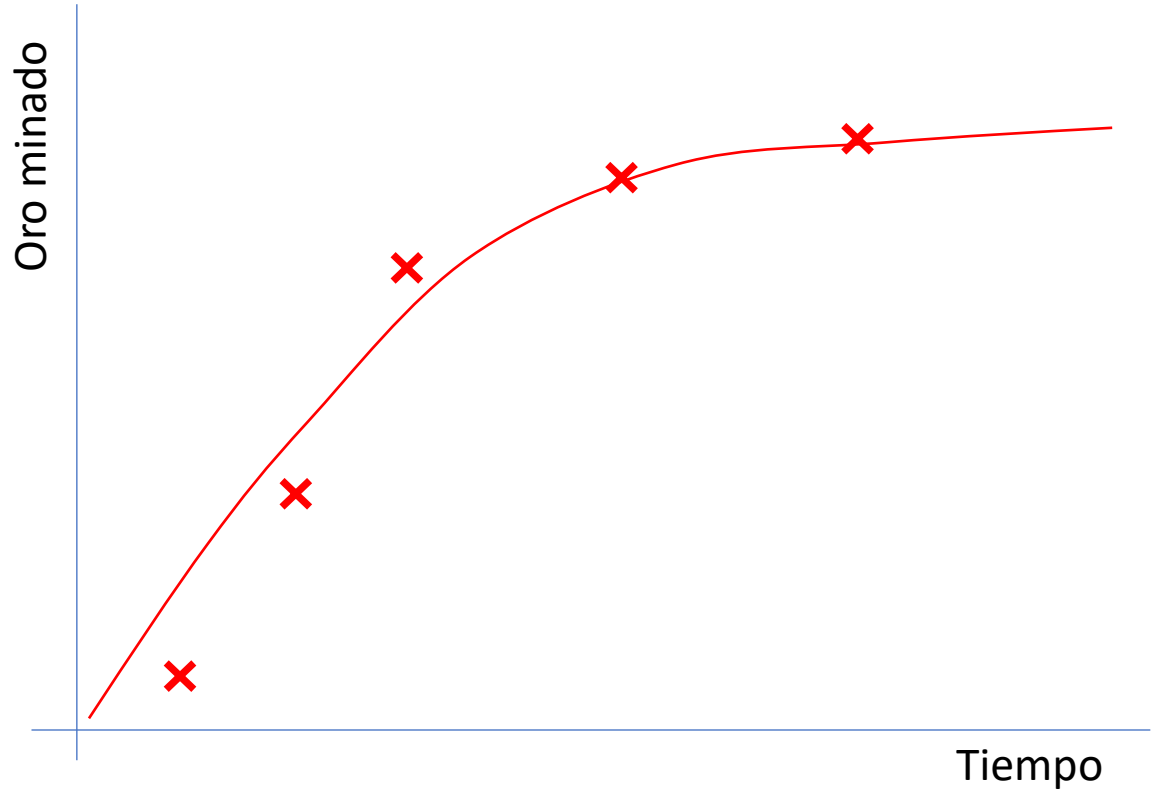
¿Cuánto Oro Queda?



¿Por qué este modelo no es ideal?

¿Qué modelamos? - intuición

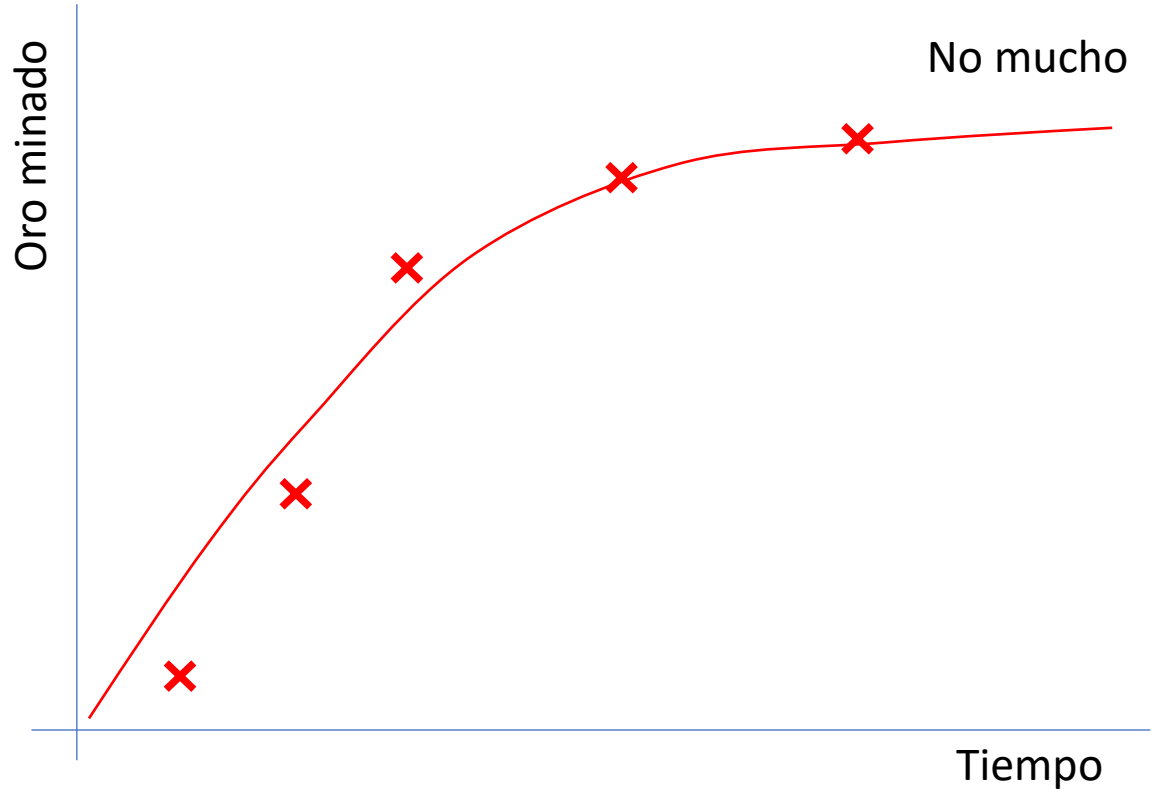
¿Cuánto Oro Queda?



¿Por qué este modelo no es ideal?

¿Qué modelamos? - intuición

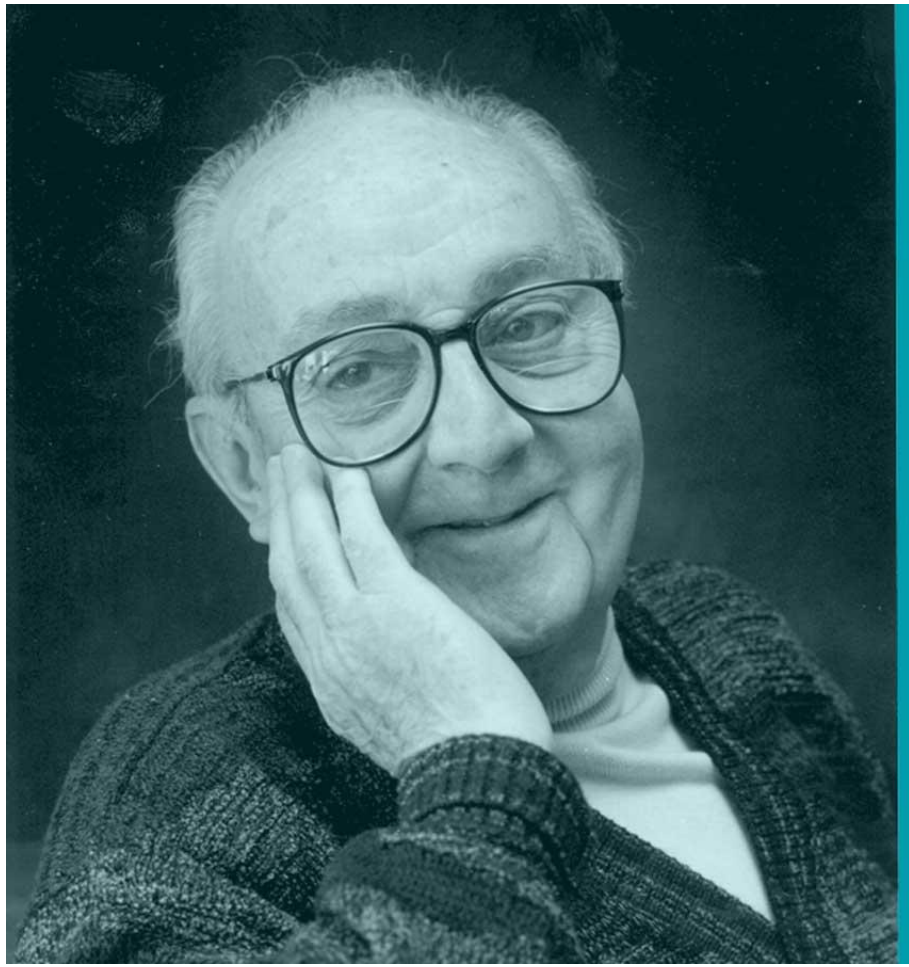
¿Cuánto Oro Queda?



¿Por qué este modelo no es ideal?

¿Cuál es el modelo correcto?

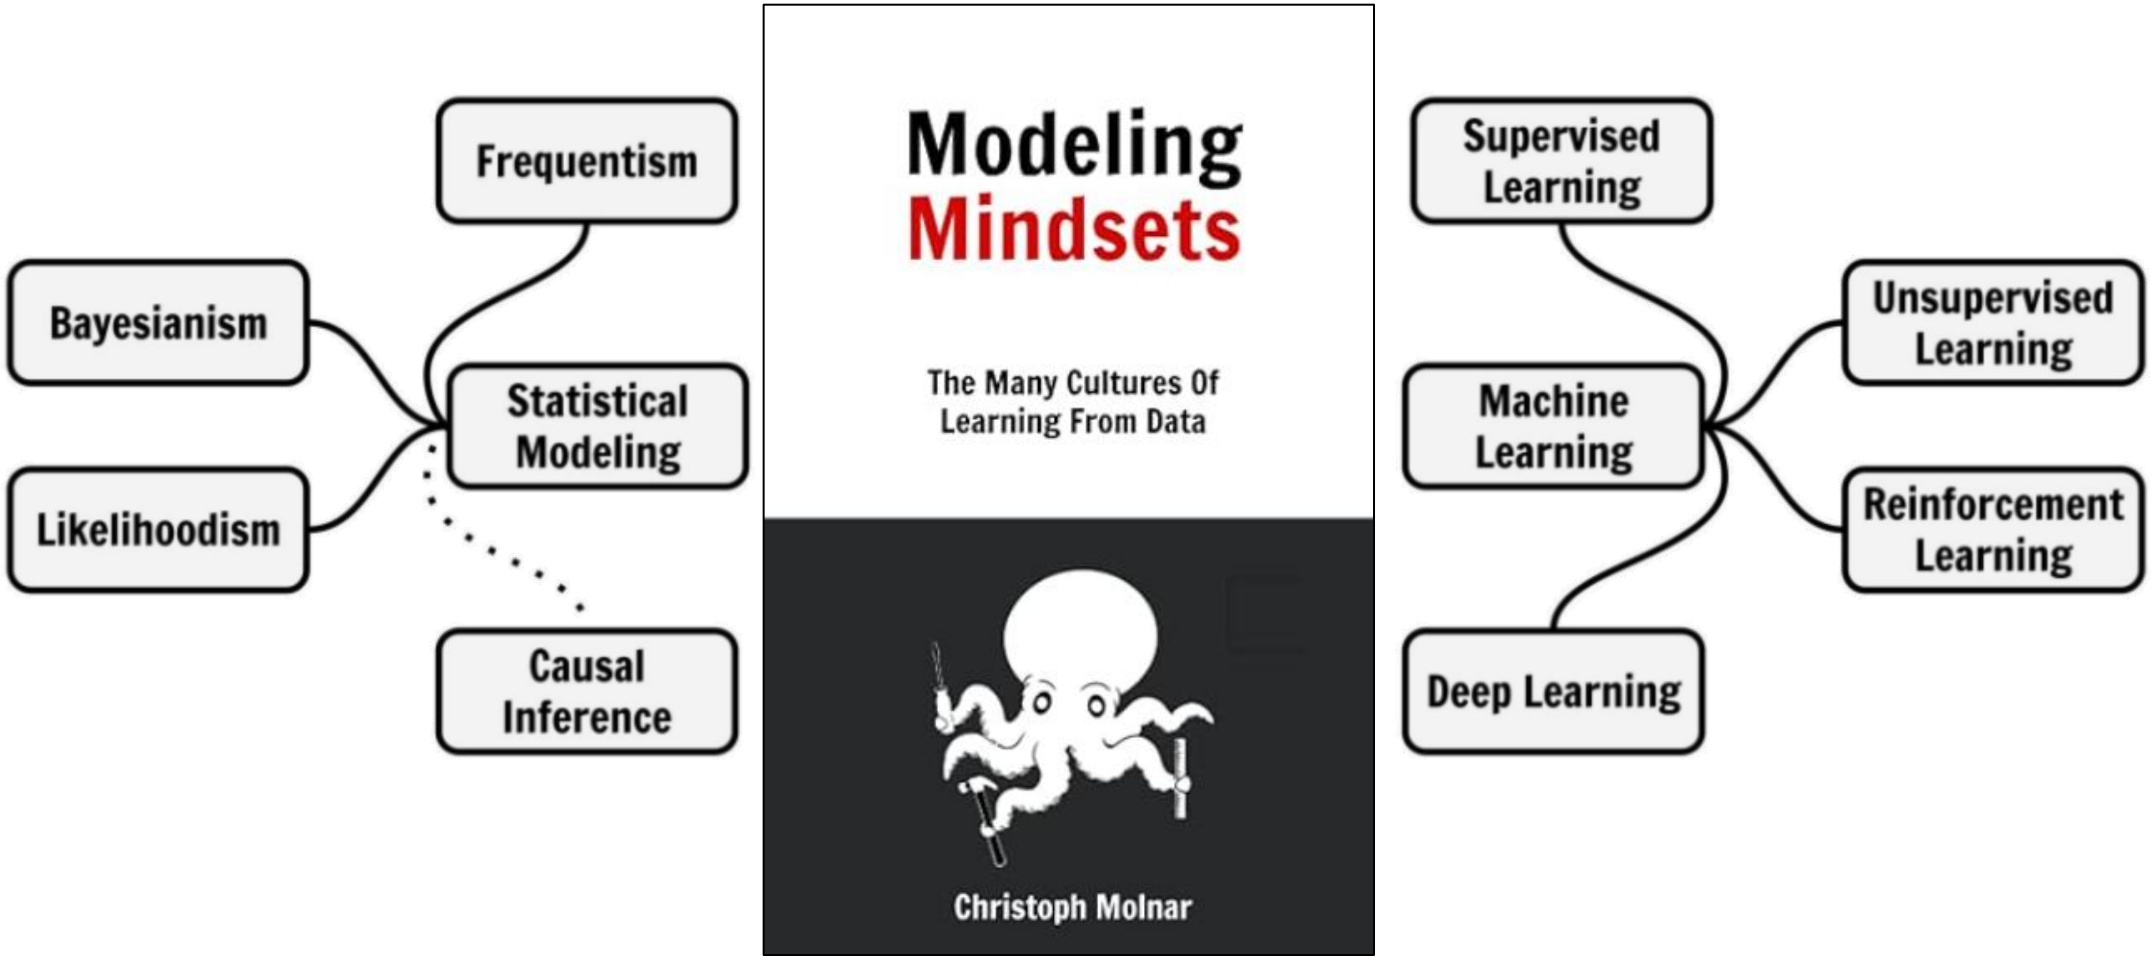
Cambio de paradigma



"All models are wrong, but some are useful."

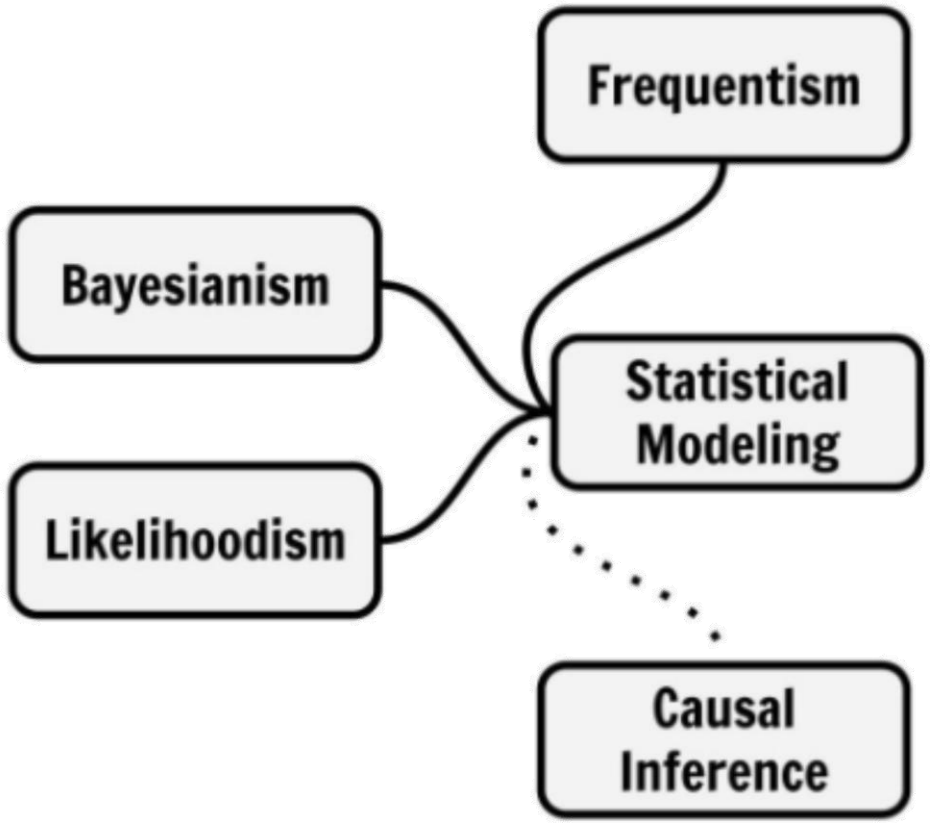
George Box

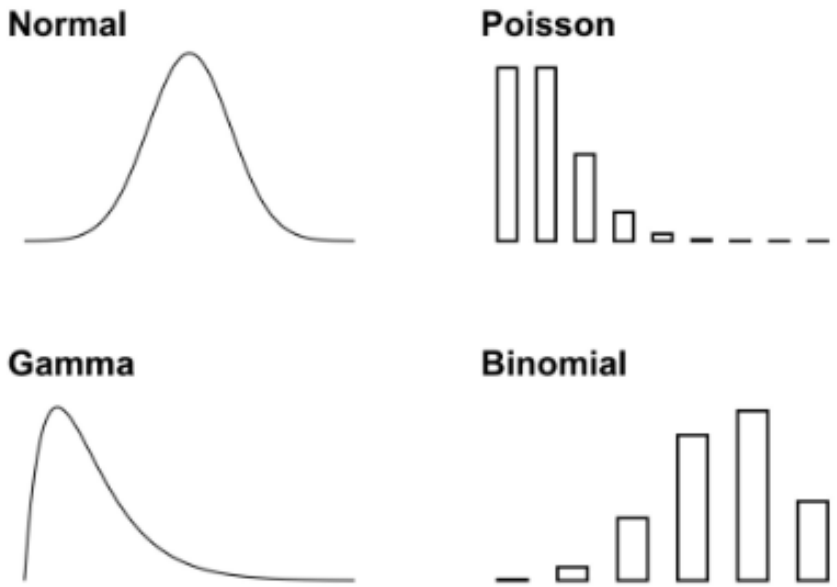
Mentalidades del modelamiento



Modeling Mindsets: The Many Cultures Of Learning From Data

Mentalidades del modelamiento

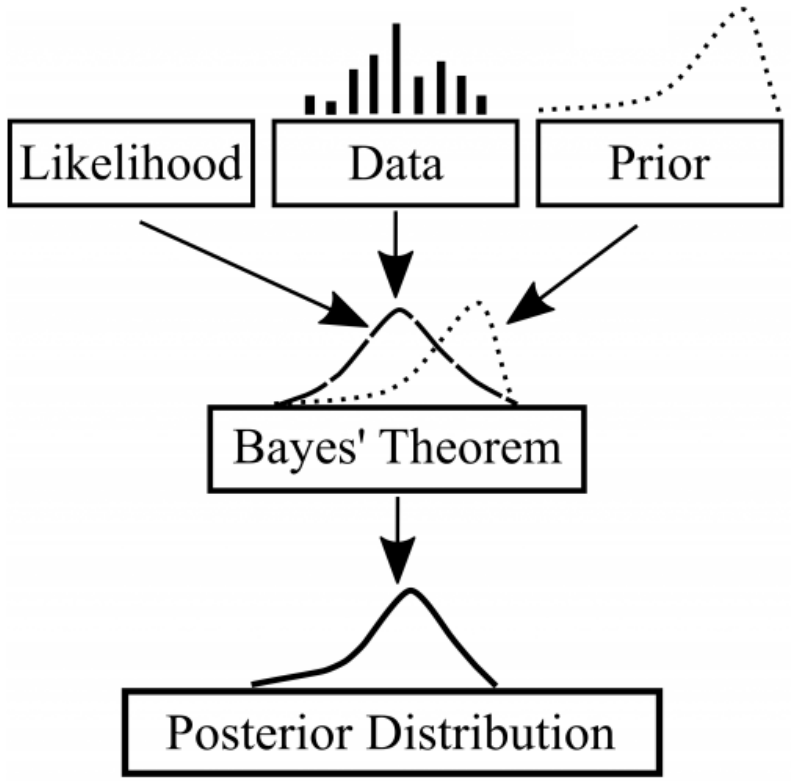




¿Qué es la prueba de hipótesis?

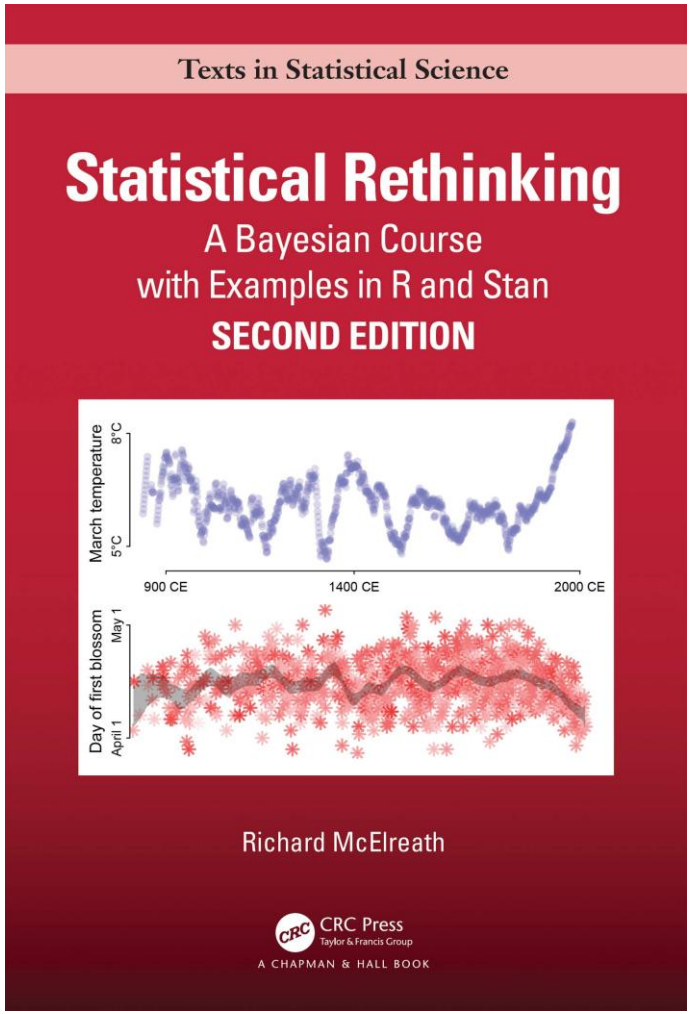
Paradigma Frecuentista vs Bayesiano

- **Frecuentista:** Deriva distribuciones de repeticiones experimentales; parámetros fijos pero desconocidos
- **Bayesiano:** Actualiza creencias previas con nuevas observaciones; los parámetros tienen sus propias distribuciones
- **Diferencia clave:** Probabilidad de datos dado el modelo vs probabilidad del modelo dados los datos



verosimilitud vs. probabilidad

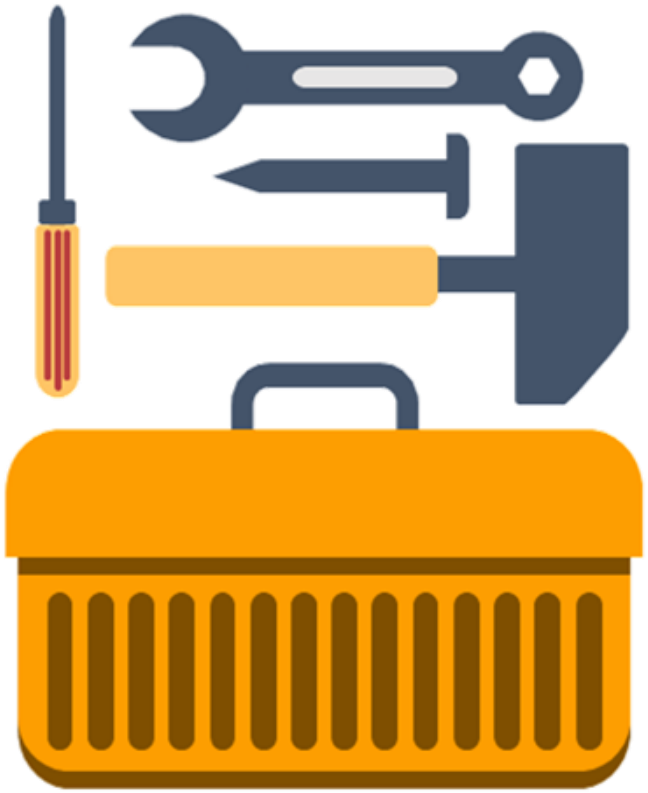
Profundizar más...

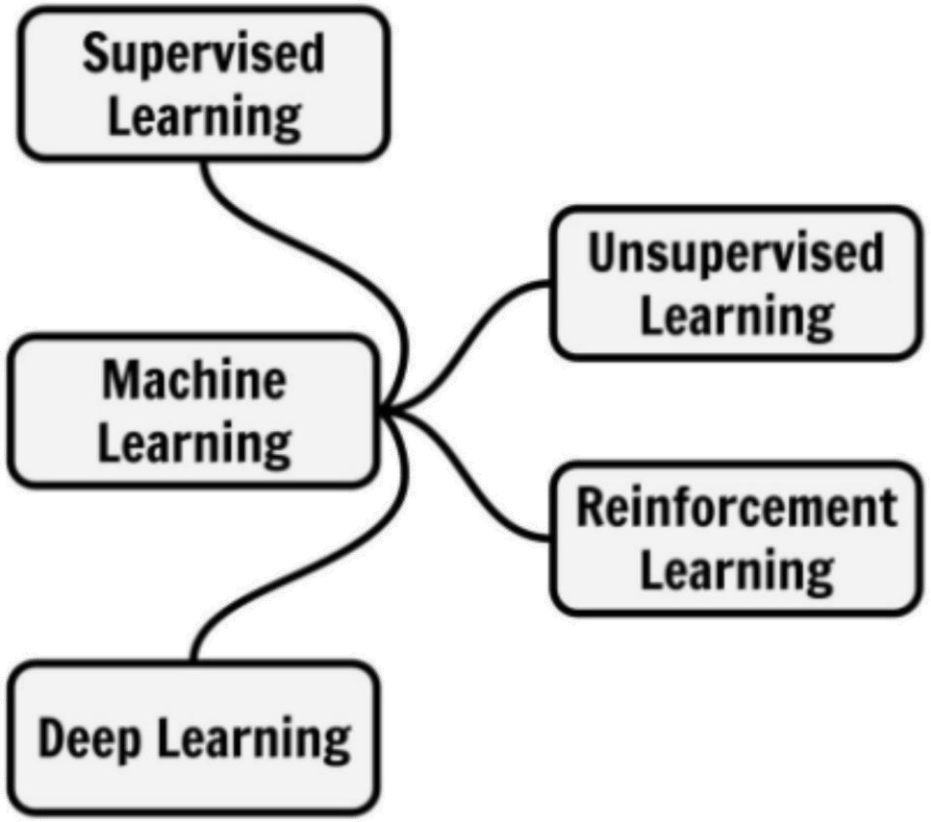




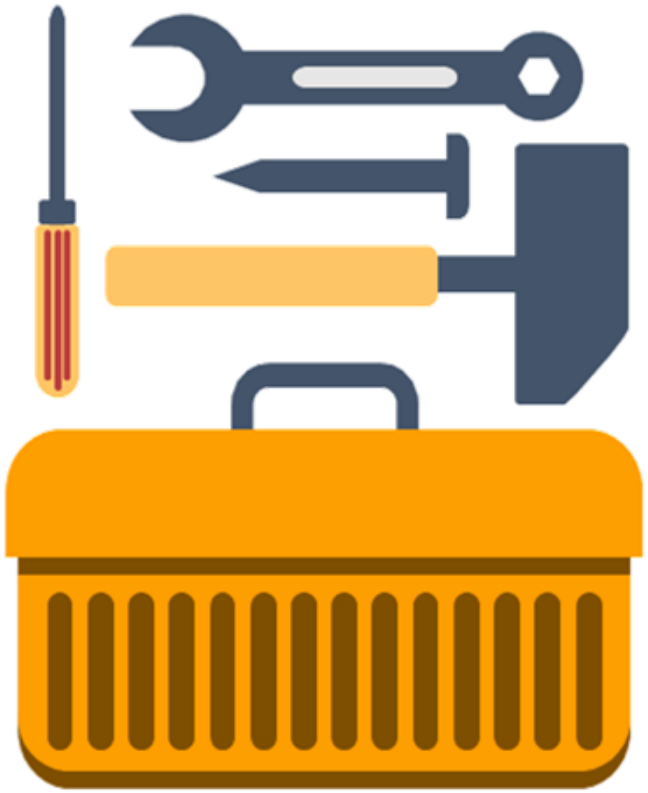
https://www.youtube.com/watch?v=FdnMWdICdRs&list=PLDcUM9US4XdPz-KxHM4XHt7uUVGWWVSus

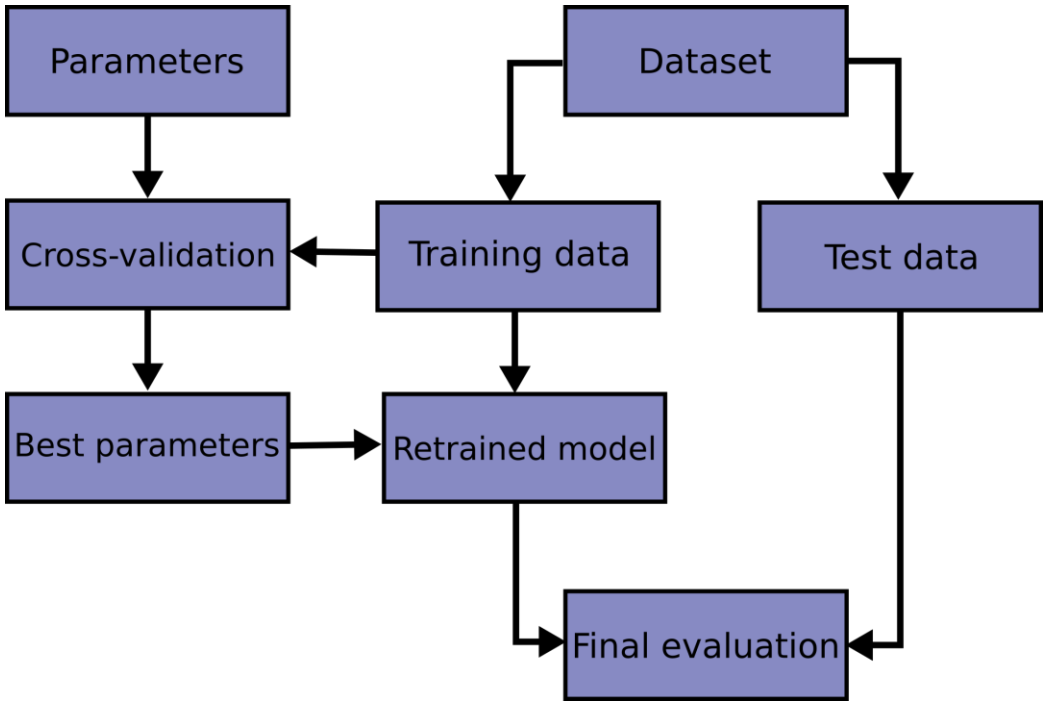
Machine Learning: Cambio de paradigma





Machine Learning: Cambio de paradigma





(10 min) Break



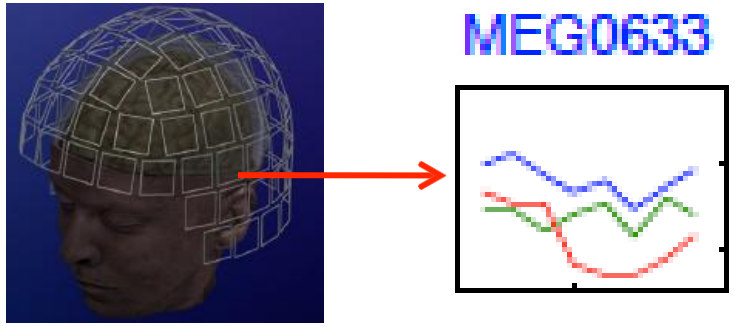
Datos de gran tamaño y alta dimensionalidad

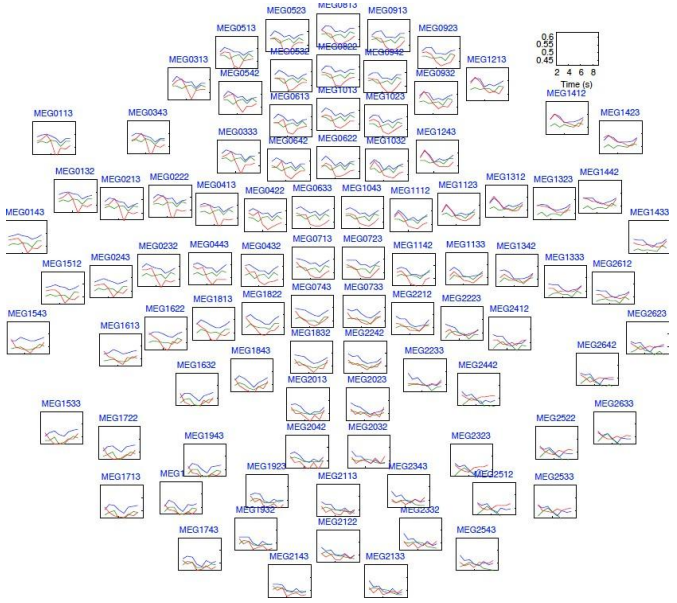
Alta dimensionalidad = Muchas Características

Imágenes Cerebrales MEG

120 ubicaciones incógnita 500 puntos temporales

y 20 objetos





O cualquier dato de imagen de alta dimensionalidad

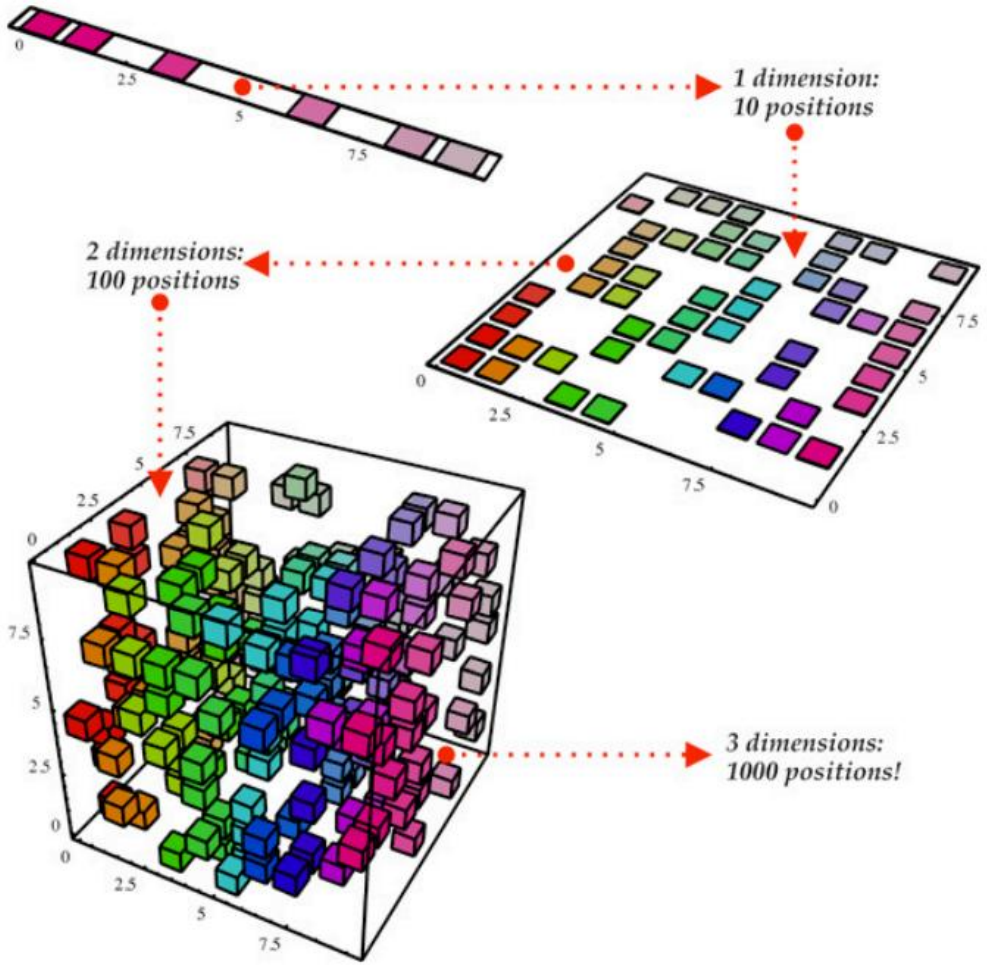




¿Cuál es el problema de muchos datos?

Maldición de la Dimensionalidad

- Al aumentar dimensiones, el volumen crece exponencialmente, dispersando los datos hasta volverlos inutilizables
- Los puntos tienden a ser equidistantes en espacios de alta dimensión, destruyendo el concepto de "cercanía“
- Se necesitan cantidades exponencialmente mayores de datos para mantener la misma densidad informativa



¿Cómo podemos reducir la dimensionalidad?

Técnicas para manejar la dimensionalidad

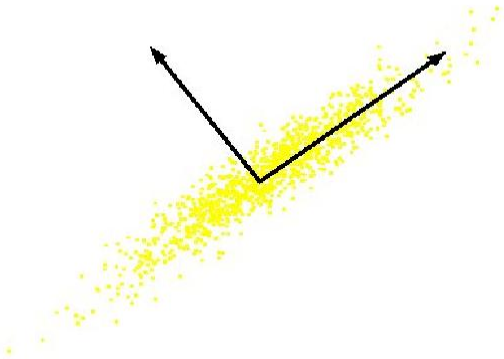
PCA, Kernel PCA, ICA: potentes técnicas de aprendizaje no supervisado para extraer estructuras ocultas (potencialmente baja dimensionalidad) de conjuntos de datos de alta dimensionalidad.

Útil para :

- Visualización
- Más eficiente usar de recursos (tiempo, memoria...)
- Estadístico: menos dimensiones → mejor generalización
- Eliminación de ruido (mejorando datos calidad)
- Más tratamiento por máquina aprendiendo algoritmos

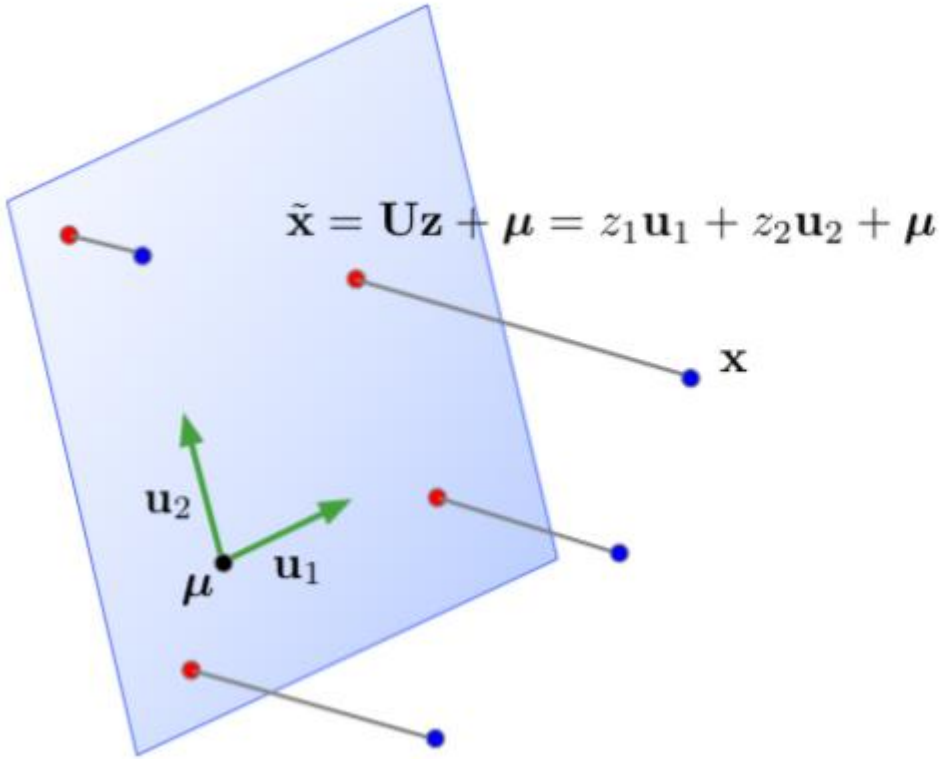
Análisis de componentes principales (PCA) (recordatorio)

Qué es PCA : Técnica no supervisada para extraer la estructura de varianza del conjunto de datos de alta dimensionalidad



- PCA es un proyección ortogonal o transformación de los datos en un subespacio (posiblemente de menor dimensión) de forma que se maximice la varianza de los datos proyectados

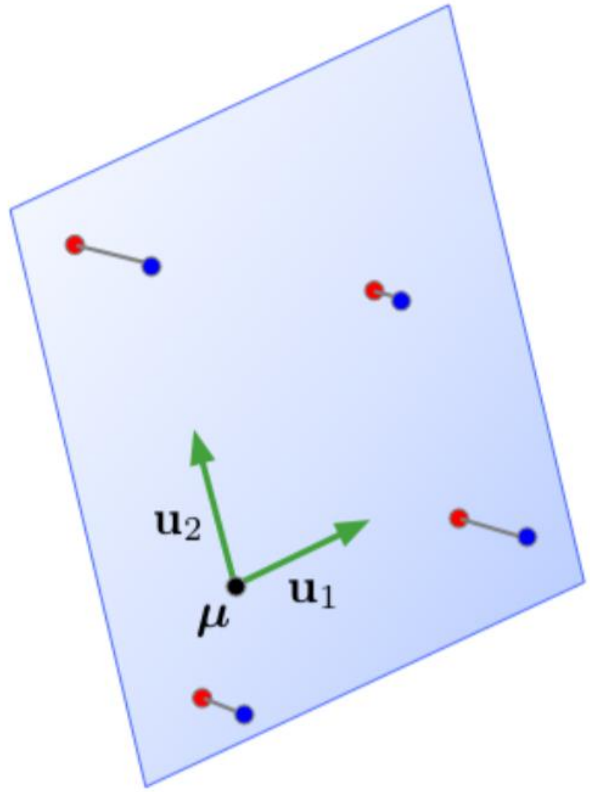
Proyectando al subespacio



$$\mathbf{z} = \mathbf{U}^\top(\mathbf{x} - \boldsymbol{\mu})$$

- Aquí, las columnas de **U** forman una base ortonormal para un subespacio *S*.
- La proyección de un punto **x** sobre *S* es el punto $\tilde{\mathbf{x}} \in S$ más cercano a **x**. En aprendizaje automático, $\tilde{\mathbf{x}}$ también se llama la reconstrucción de **x**.
- **z** es su representación, o código.

- Si tenemos un subespacio de K dimensiones en un espacio de entrada de D dimensiones, entonces $x \in \mathbb{R}^D$ y $z \in \mathbb{R}^K$.
- Si los puntos de datos x están todos cerca del subespacio, entonces podemos aproximar distancias, productos escalares, etc. en términos de estas mismas operaciones en los vectores de código z.
- Si $K \ll D$, entonces es mucho más económico trabajar con z que con x.
- Un mapeo a un espacio que es más fácil de manipular o visualizar se llama una representación, y aprender tal mapeo es aprendizaje de representación.
- Mapear datos a un espacio de baja dimensión se llama reducción de dimensionalidad.



Aprendiendo un subespacio

- ¿Cómo elegir un buen subespacio S?
  - Necesitamos elegir un vector μ y una matriz D × K U con columnas ortonormales.
- Establecer μ como la media de los datos, $\boldsymbol{\mu} = \frac{1}{N}\sum_{i=1}^{N}\mathbf{x}^{(i)}$
- Dos criterios:
  - Minimizar el error de reconstrucción $\min \frac{1}{N}\sum_{i=1}^{N}\|\mathbf{x}^{(i)} - \tilde{\mathbf{x}}^{(i)}\|^2$
  - Maximizar la varianza de los vectores de

$$\max \sum_j \mathrm{Var}(z_j) = \frac{1}{N}\sum_j\sum_i (z_j^{(i)} - \bar{z}_i)^2$$
$$= \frac{1}{N}\sum_i \|\mathbf{z}^{(i)} - \bar{\mathbf{z}}\|^2$$
$$= \frac{1}{N}\sum_i \|\mathbf{z}^{(i)}\|^2$$

Aprendiendo un subespacio

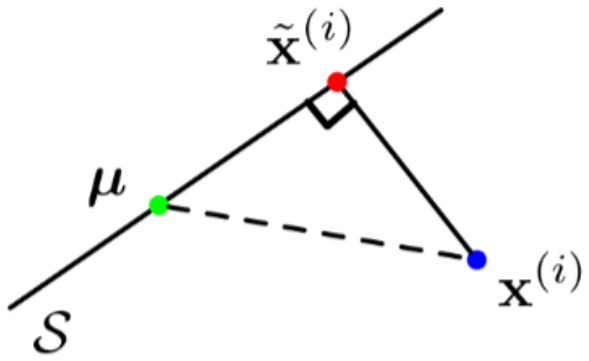
- ¡Estos dos criterios son equivalentes! Es decir, demostraremos que:

$$\frac{1}{N}\sum_{i=1}^{N}\|\mathbf{x}^{(i)}-\tilde{\mathbf{x}}^{(i)}\|^2 = \text{const} - \frac{1}{N}\sum_{i}\|\mathbf{z}^{(i)}\|^2$$

- Observación: por unitariedad

$$\|\tilde{\mathbf{x}}^{(i)}-\boldsymbol{\mu}\| = \|\mathbf{U}\mathbf{z}^{(i)}\| = \|\mathbf{z}^{(i)}\|$$

- Por el Teorema de Pitágoras



$$\underbrace{\frac{1}{N}\sum_{i=1}^{N}\|\tilde{\mathbf{x}}^{(i)}-\boldsymbol{\mu}\|^2}_{\text{projected variance}} + \underbrace{\frac{1}{N}\sum_{i=1}^{N}\|\mathbf{x}^{(i)}-\tilde{\mathbf{x}}^{(i)}\|^2}_{\text{reconstruction error}}$$

$$= \underbrace{\frac{1}{N}\sum_{i=1}^{N}\|\mathbf{x}^{(i)}-\boldsymbol{\mu}\|^2}_{\text{constant}}$$

Consideraciones sobre PCA

- La reducción de dimensionalidad busca encontrar una representación de baja dimensión de los datos.
- PCA proyecta los datos en un subespacio que maximiza la varianza proyectada o, equivalentemente, minimiza el error de reconstrucción.
- El subespacio óptimo está dado por los autovectores principales de la matriz de covarianza empírica.
- PCA proporciona un conjunto de características decorrelacionadas.

  - Hecho interesante: las dimensiones de z están decorrelacionadas
  - Si la matriz de covarianza es diagonal, esto significa que las características están no correlacionadas.
  - Por esto se inventó PCA (¡en 1901!).

Aplicando PCA a rostros

- Consideremos ejecutar PCA en 2429 imágenes en escala de grises de 19x19 (datos CBCL)
- Se pueden obtener buenas reconstrucciones con solo 3 componentes



- PCA para pre-procesamiento: se puede aplicar un clasificador a la representación latente
  - Para reconocimiento facial, PCA con 3 componentes obtiene 79% de precisión en la discriminación cara/no-cara en datos de prueba vs. 76.8% para un modelo de mezcla gaussiana (GMM) con 84 estados. (Cubriremos los GMM más adelante en el curso).
- También puede ser bueno para visualización

Aplicando PCA a rostros: Base aprendida

- Componentes principales de imágenes de rostros ("eigenfaces")



Aplicado a expresiones: subespacio feliz





Aplicado a expresiones: subespacio disgusto





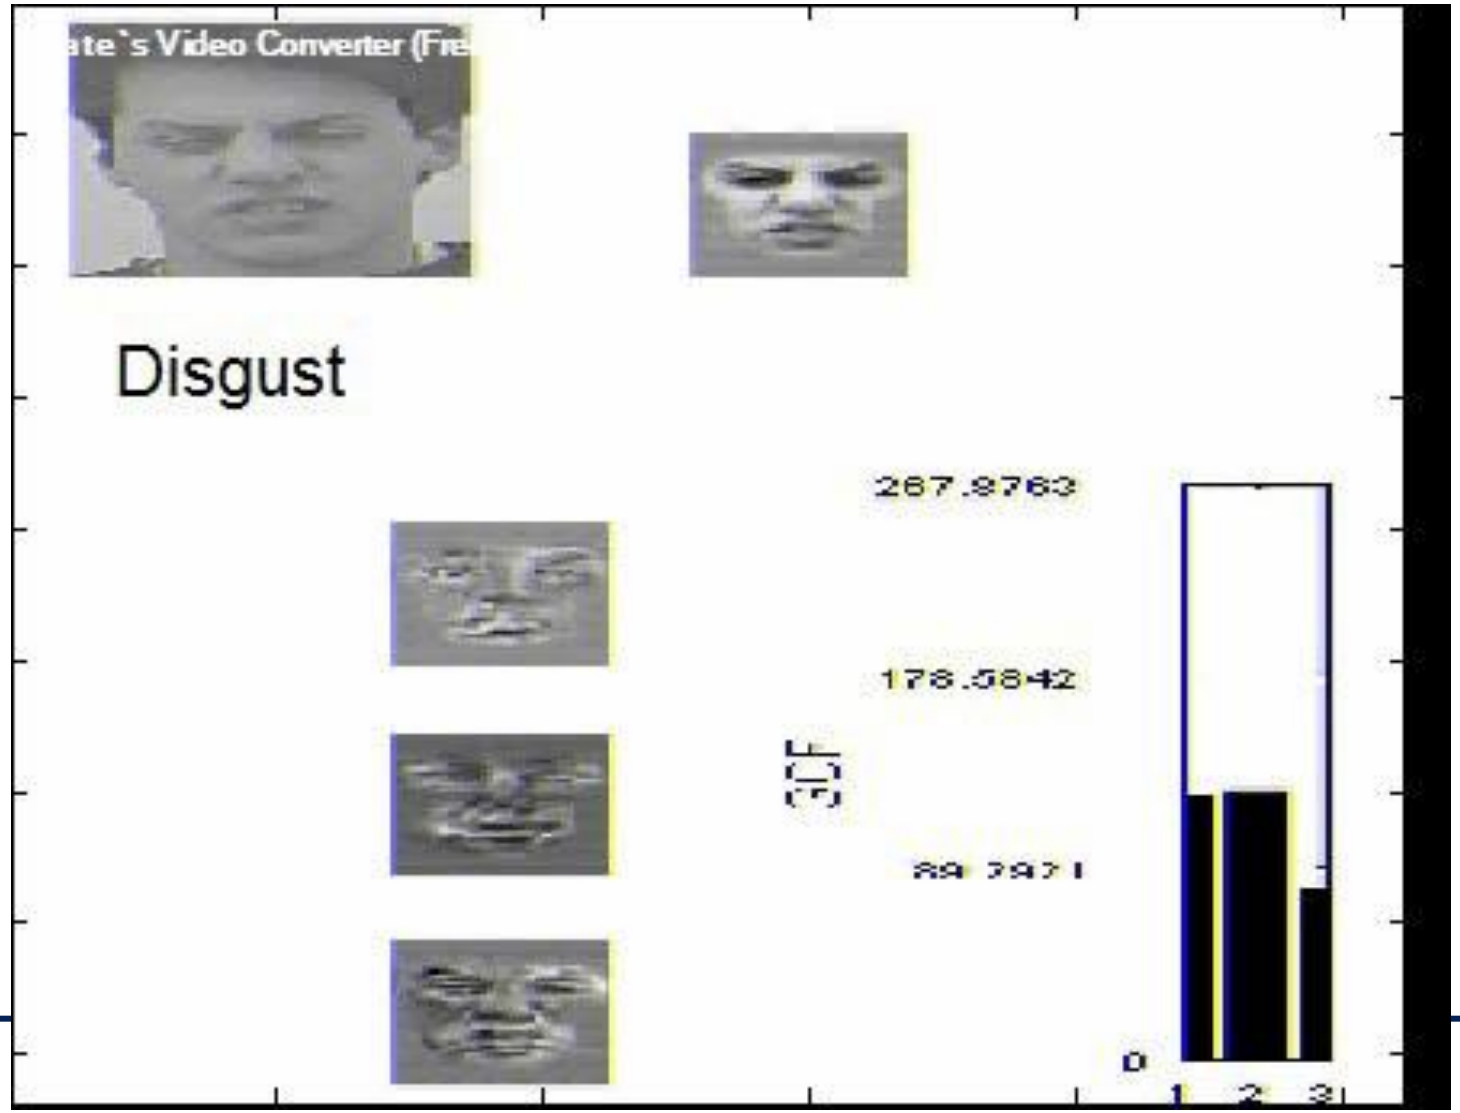
Ejemplos de reconocimiento de expresiones



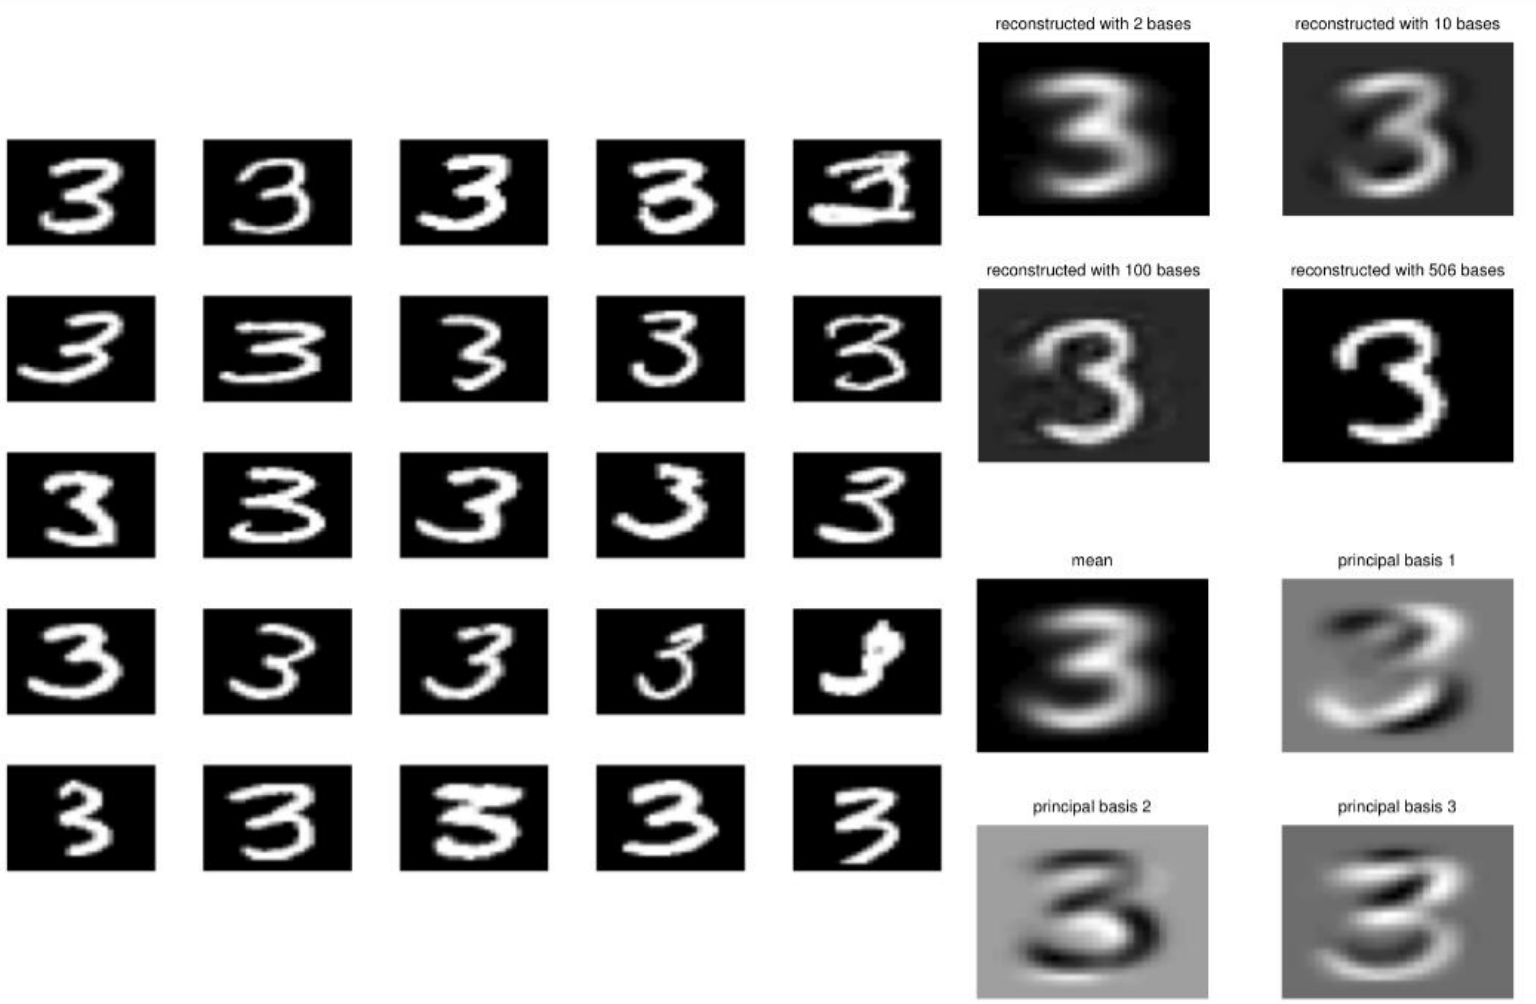
Ejemplos de reconocimiento de expresiones



Ejemplos de reconocimiento de expresiones



Aplicando PCA a dígitos

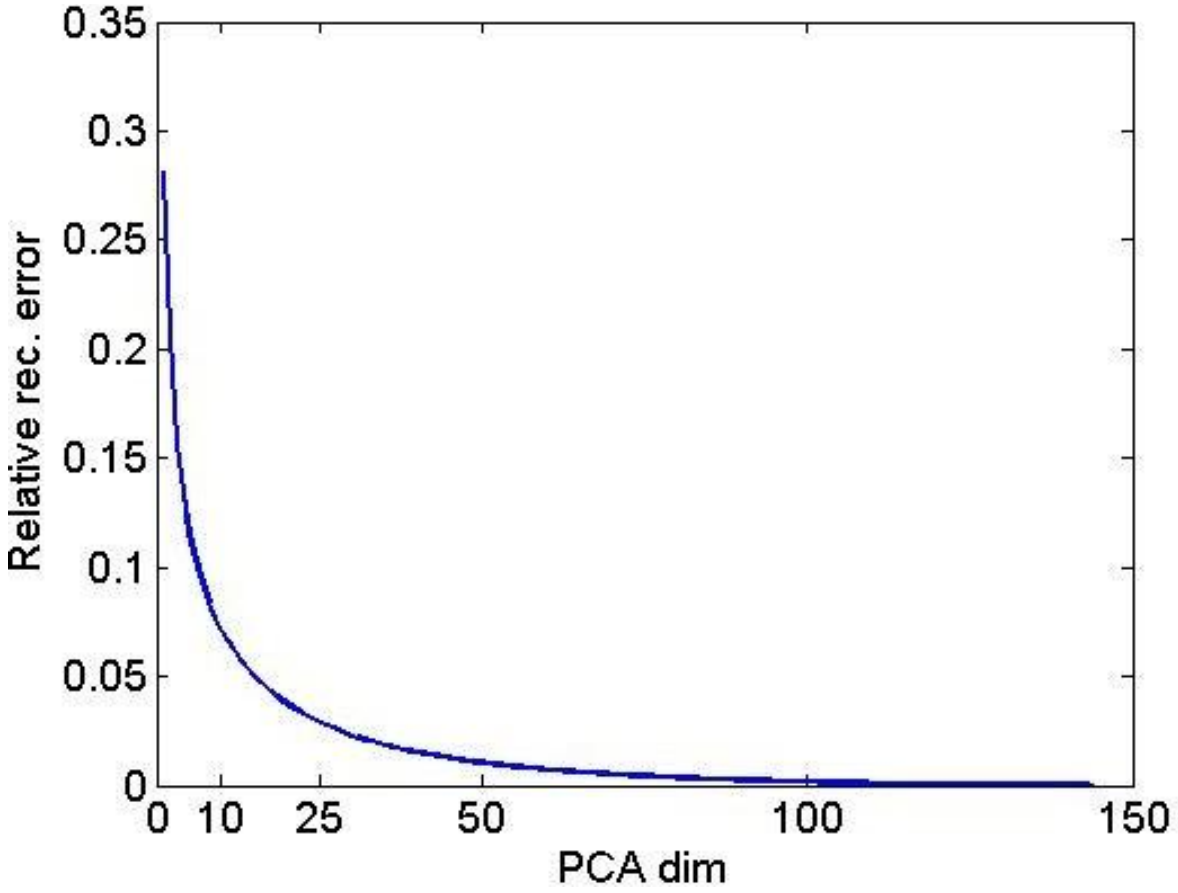


Compresión de Imágenes

- Dividir el original 372x492 imagen en parches:
- Cada parche es un instancia eso contiene 12x12 píxeles en una cuadrícula
- Vista cada uno como un 144 -D vector



Compresión de Imágenes



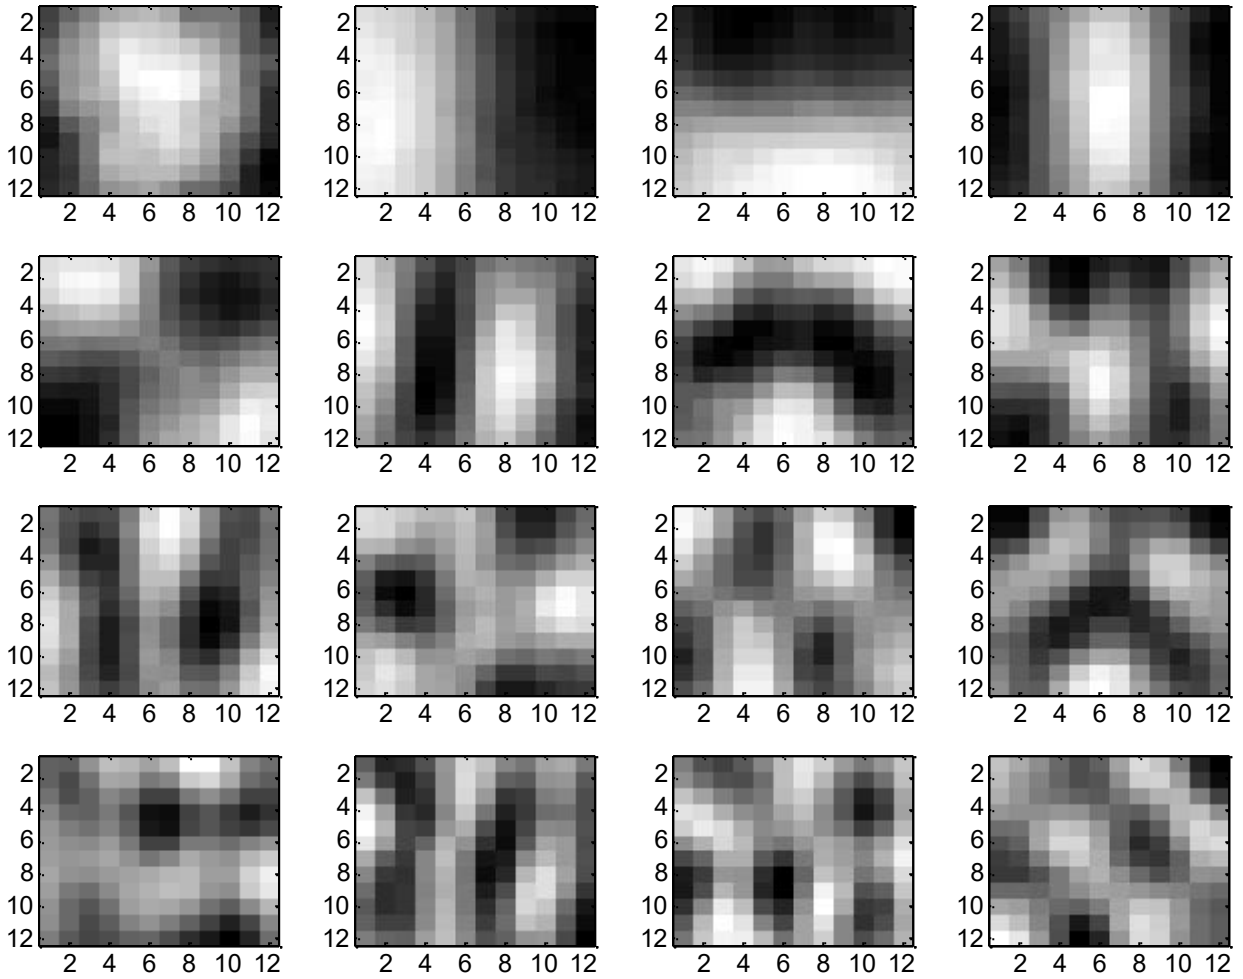
Compresión de Imágenes: 144 a 66D



Compresión de Imágenes: 144 a 16D



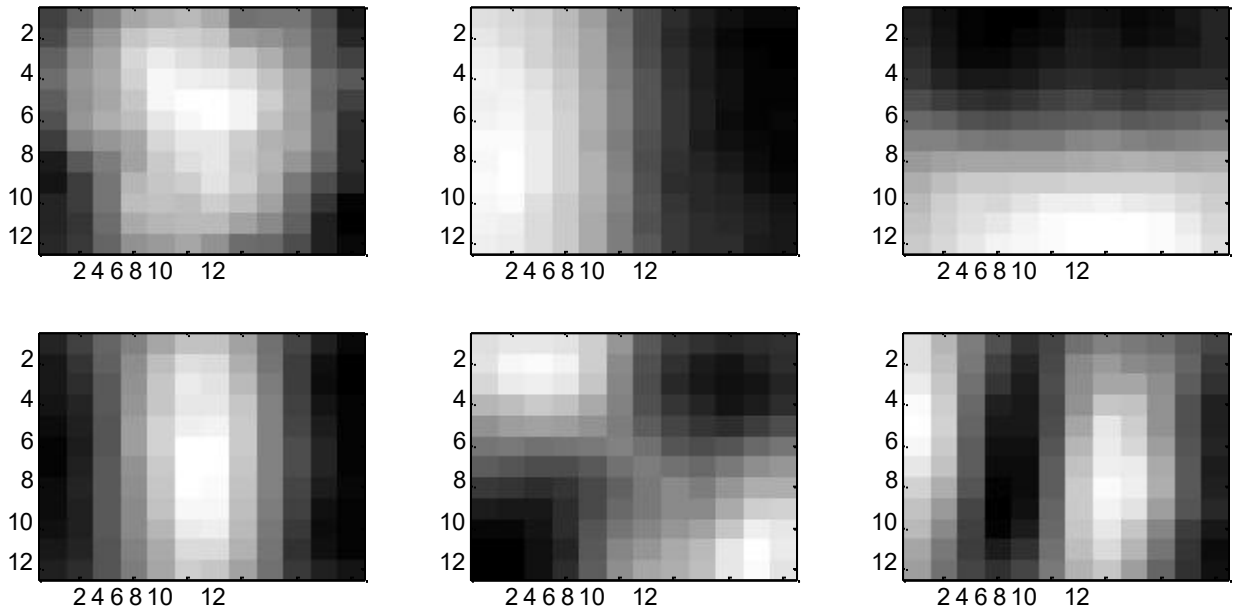
Los 16 vectores propios de esa imagen



Compresión de Imágenes: 144 a 6D



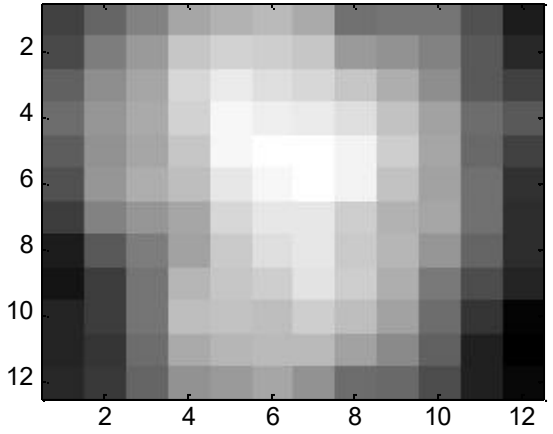
Los 6 vectores propios de esa imagen

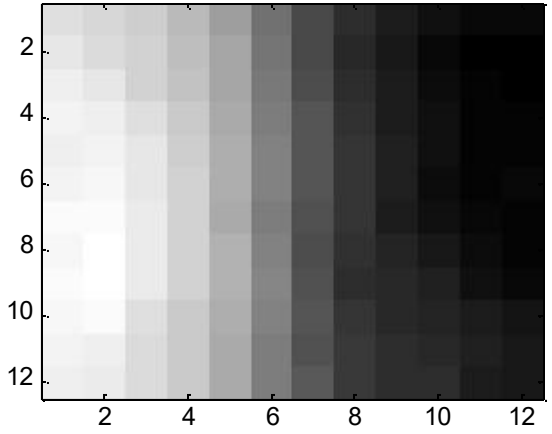


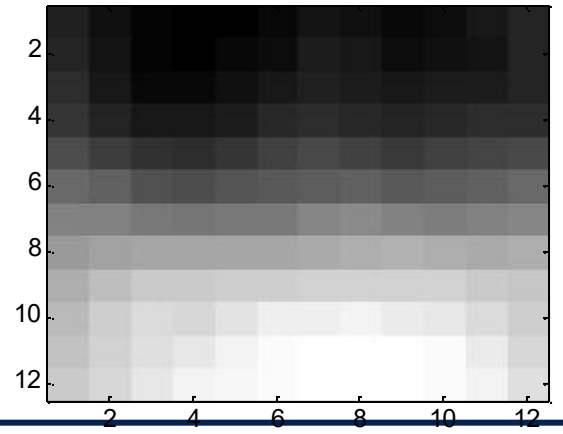
Compresión de Imágenes: 144 a 3D



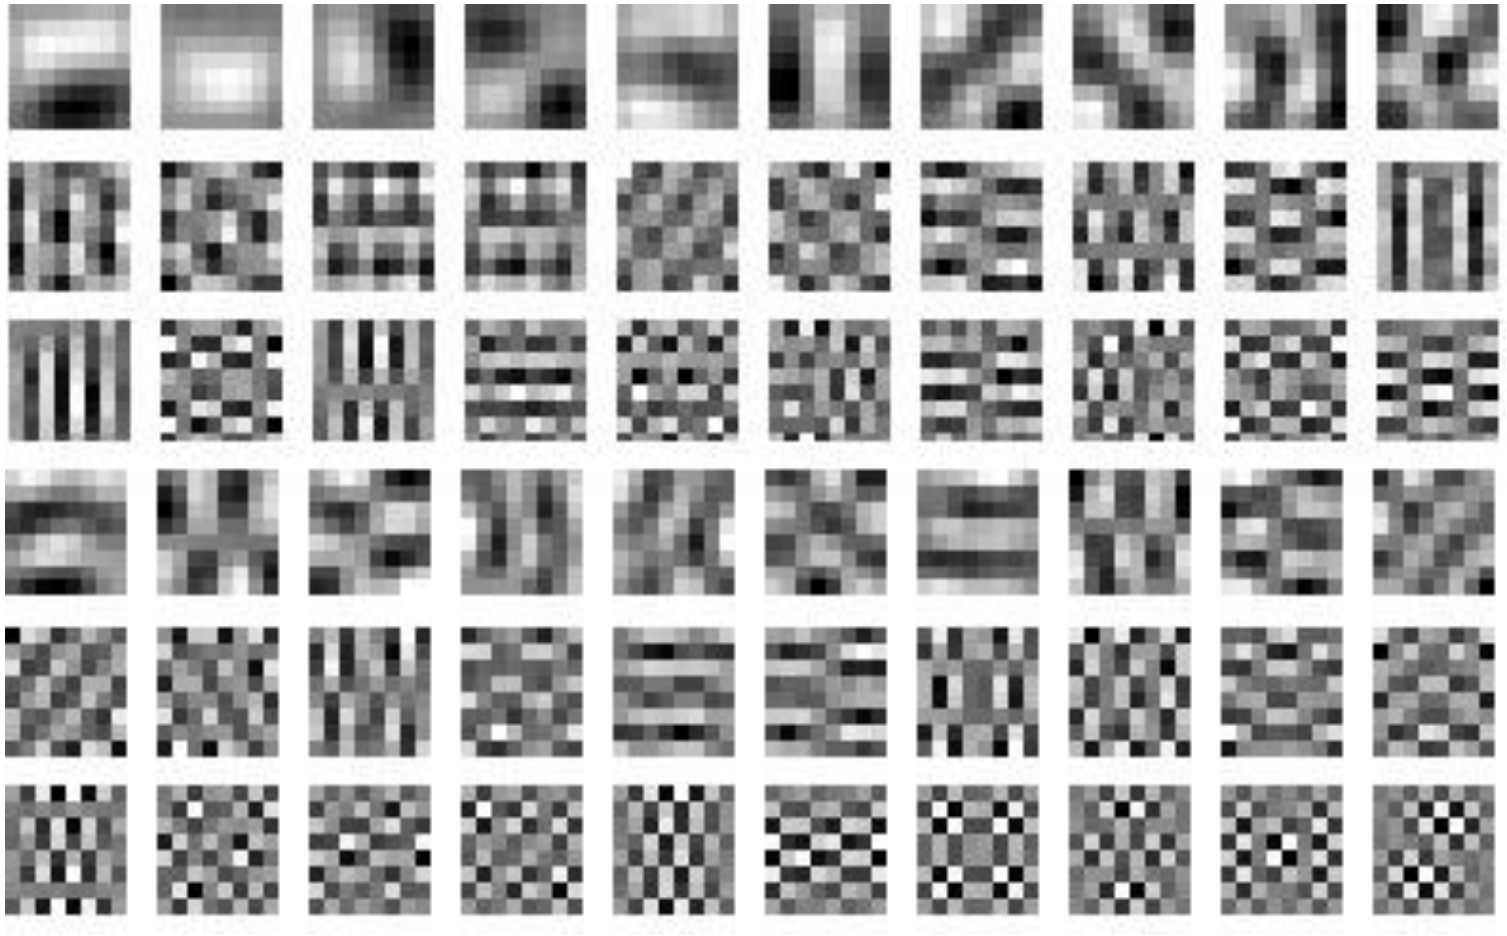
Los 3 vectores propios de esa imagen



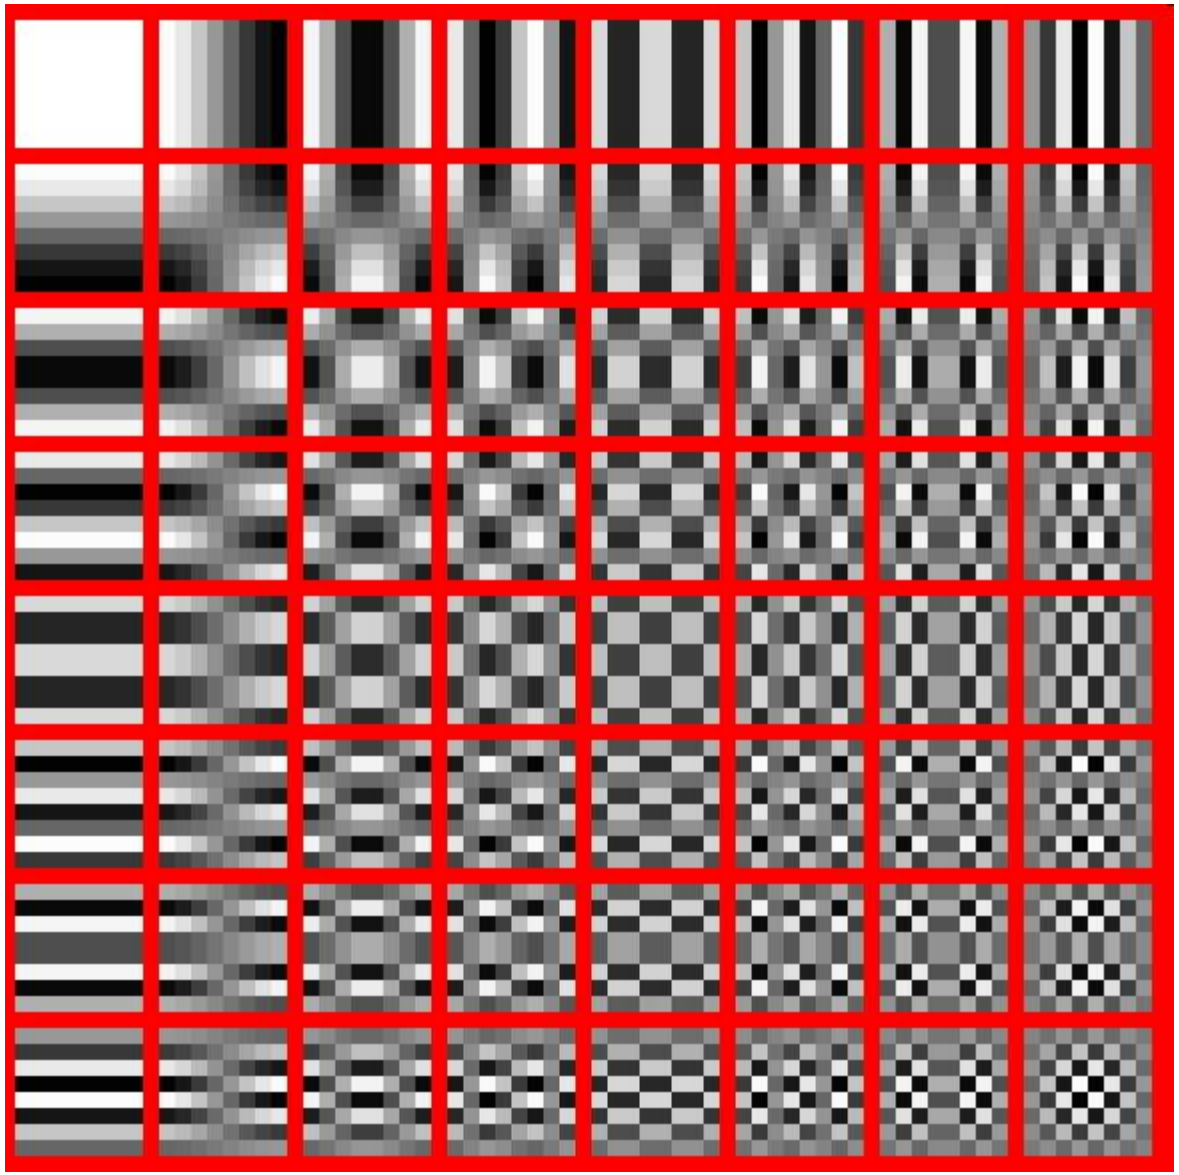




Los 60 vectores propios más comunes



Aspecto como el discreto coseno bases de ¡JPG!...



Esta técnica llega a “encontrar” la distribución natural que ayuda a reducir o “comprimir” los datos. Similar a las distribuciones tradicionales.

http://en.wikipedia.org/wiki/Discrete_cosine_transform

¿Se puede hacer mejor?

¿Cómo se expresa un MLP matemáticamente?

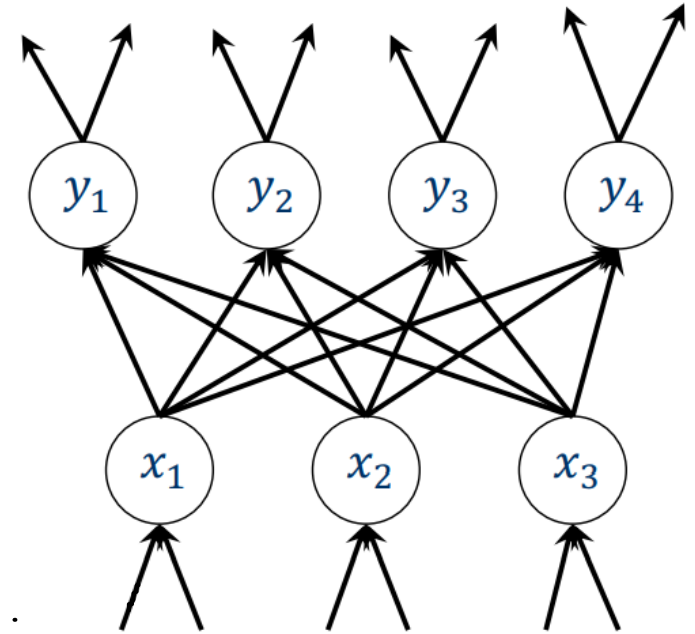
Una Capa Completamente Conectada

Cada unidad de entrada se conecta a cada unidad de salida.

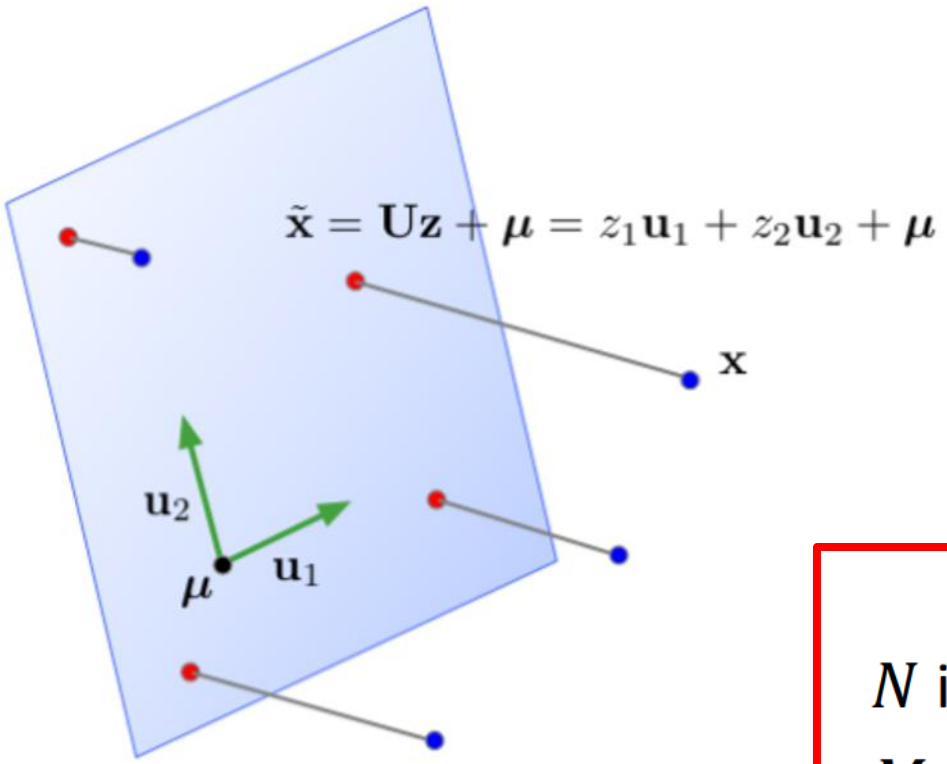
N input units, M output units

$M \times N$ weight matrix

$$y = \phi(Wx + b)$$



Perceptrón multicapa: una red multicapa que consta de capas completamente conectadas.



$$\mathbf{z} = \mathbf{U}^\top(\mathbf{x} - \boldsymbol{\mu})$$

N input units, M output units

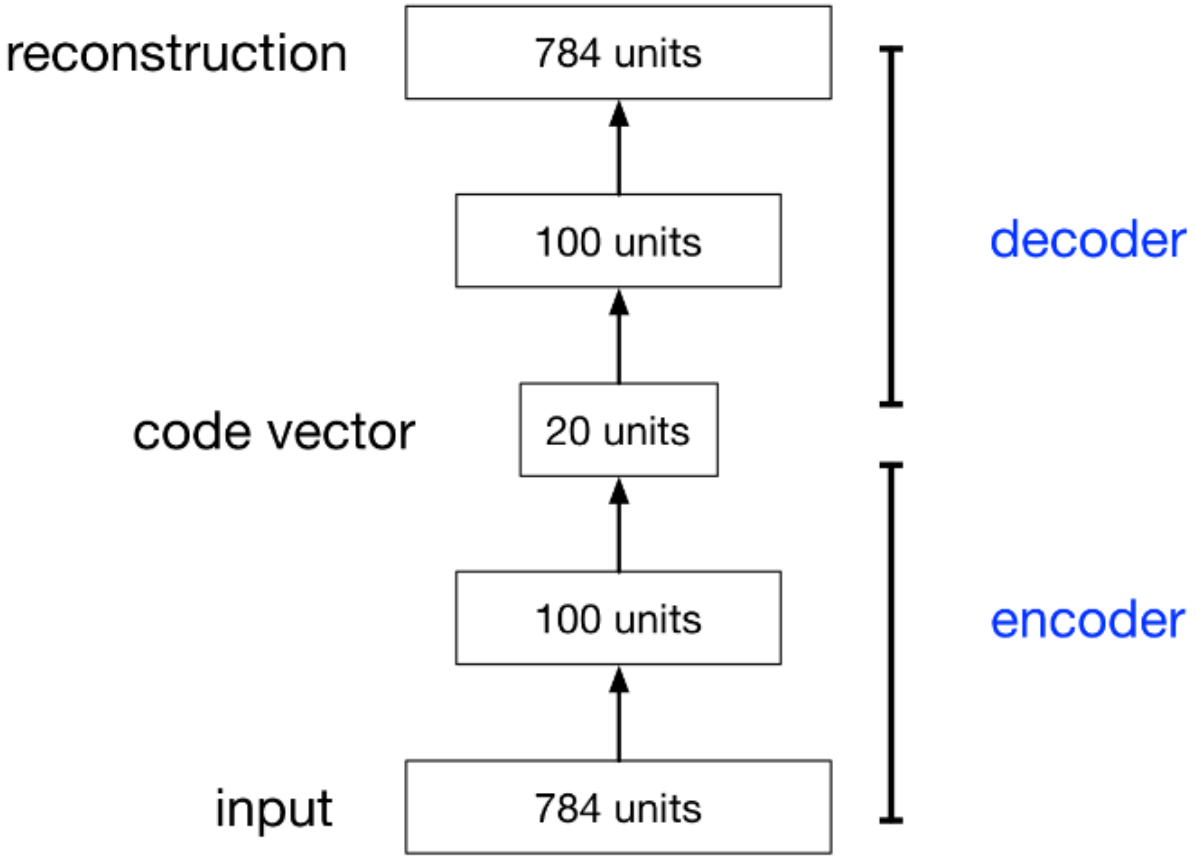
$M \times N$ weight matrix

$$y = \phi(Wx + b)$$



Expandiendo la idea de PCA: Autoencoders

- Un autoencoder es una red neuronal feed-forward cuyo trabajo es tomar una entrada x y predecir x.
- Para hacer esto no trivial, necesitamos añadir una capa de cuello de botella cuya dimensión es mucho menor que la entrada.



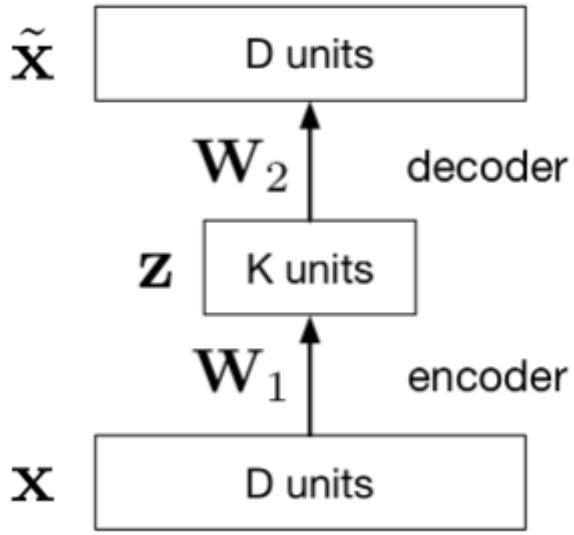
¿Por qué autoencoders?

- Puede mapear datos de alta dimensión a dos dimensiones para visualización
- Aprender características abstractas de manera no supervisada para aplicarlas a una tarea supervisada
  - Los datos sin etiquetar pueden ser mucho más abundantes que los datos etiquetados

Autoencoders lineales

- El tipo más simple de autoencoder tiene una capa oculta, activaciones lineales y pérdida de error cuadrático.

$$\mathcal{L}(\mathbf{x}, \tilde{\mathbf{x}}) = \|\mathbf{x} - \tilde{\mathbf{x}}\|^2$$



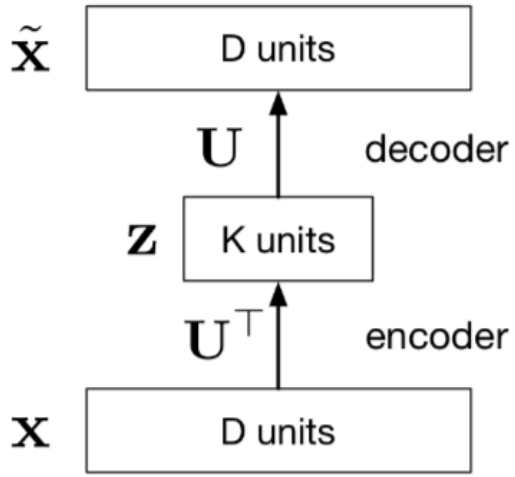
- Esta red calcula $\tilde{\mathbf{x}} = \mathbf{W_2 W_1 x}$, que es una función lineal.
- Si K ≥ D, podemos elegir W_2 y W_1 de manera que W_2W_1 sea la matriz identidad. Esto no es muy interesante.
- Pero supongamos K < D:
  - W_1 mapea x a un espacio K-dimensional, por lo que está haciendo reducción de dimensionalidad.

Autoencoders lineales

- Observa que la salida del autoencoder debe estar en un subespacio K-dimensional generado por las columnas de W_2.
- Vimos que el mejor subespacio K-dimensional en términos de error de reconstrucción es el subespacio PCA.
- El autoencoder puede lograr esto estableciendo

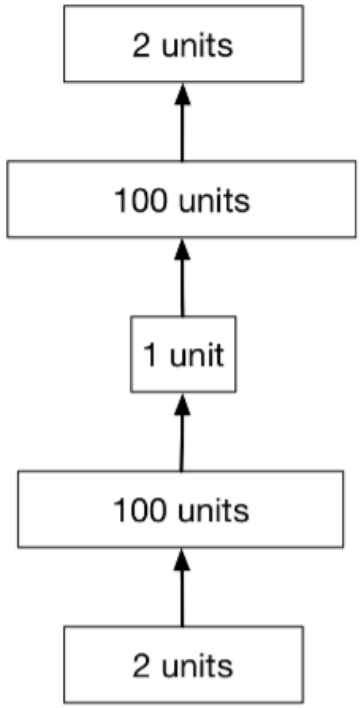
$$\mathbf{W}_1 = \mathbf{U}^\top \quad \text{y} \quad \mathbf{W}_2 = \mathbf{U}.$$

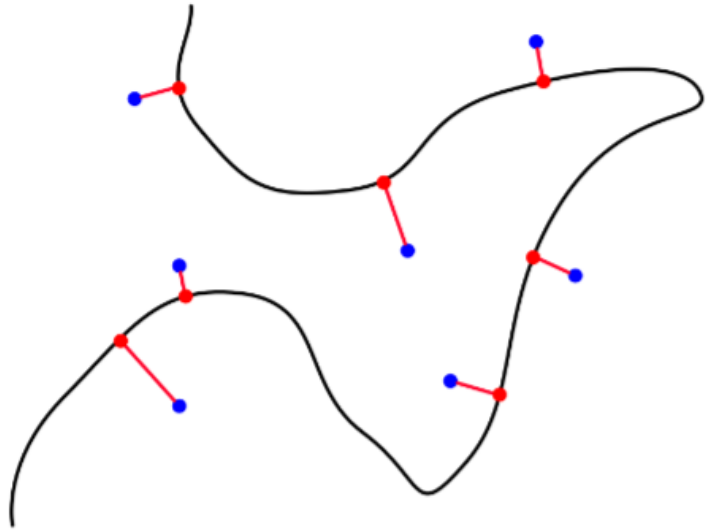
- ¡Por lo tanto, los pesos óptimos para un autoencoder lineal son simplemente los componentes principales!



Autoencoders no lineales

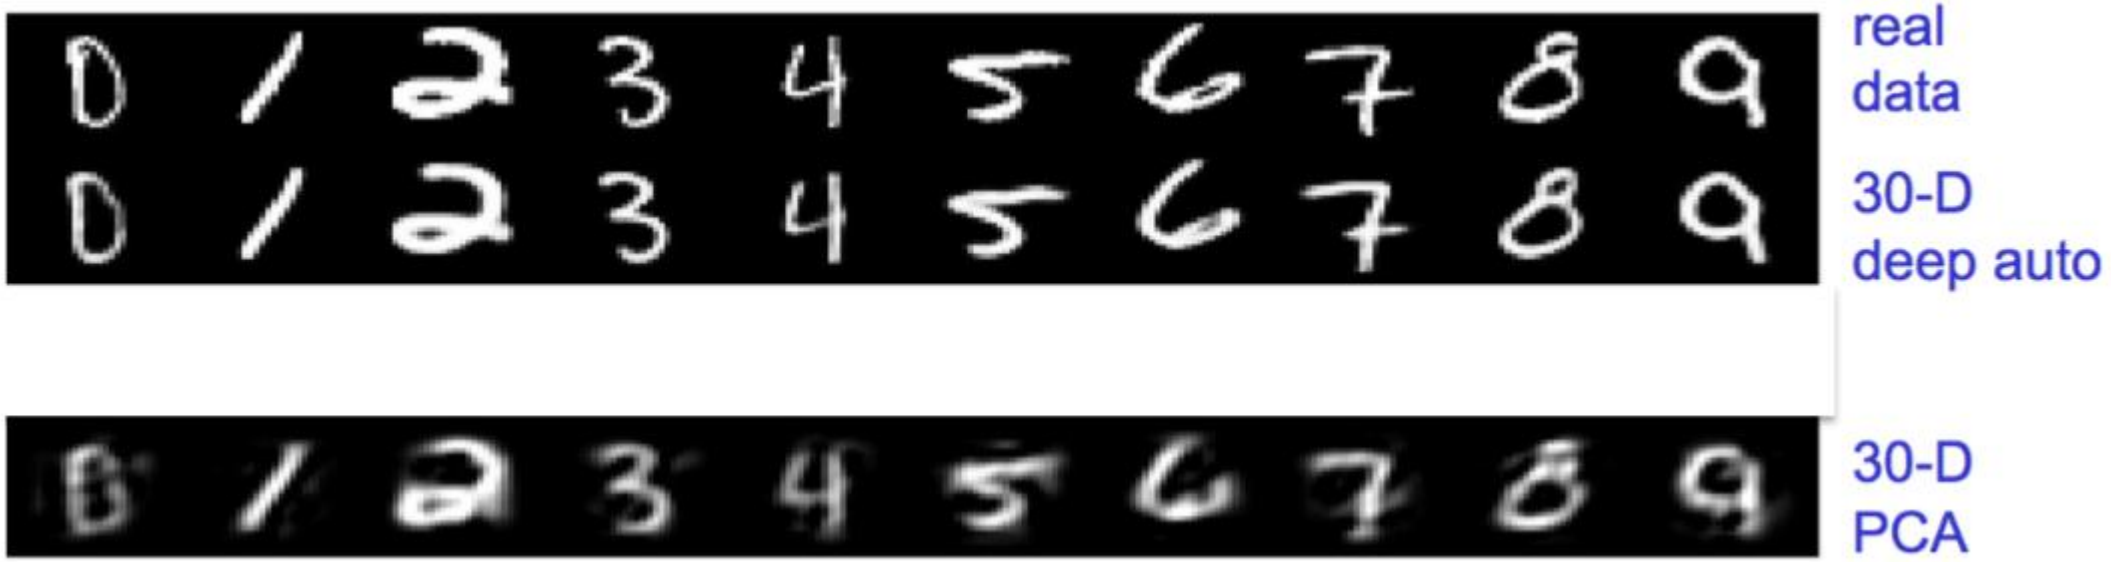
- Los autoencoders no lineales profundos aprenden a proyectar los datos, no sobre un subespacio, sino sobre una variedad no lineal
- Esta variedad es la imagen del decodificador.
- Esto es un tipo de reducción de dimensionalidad no lineal.





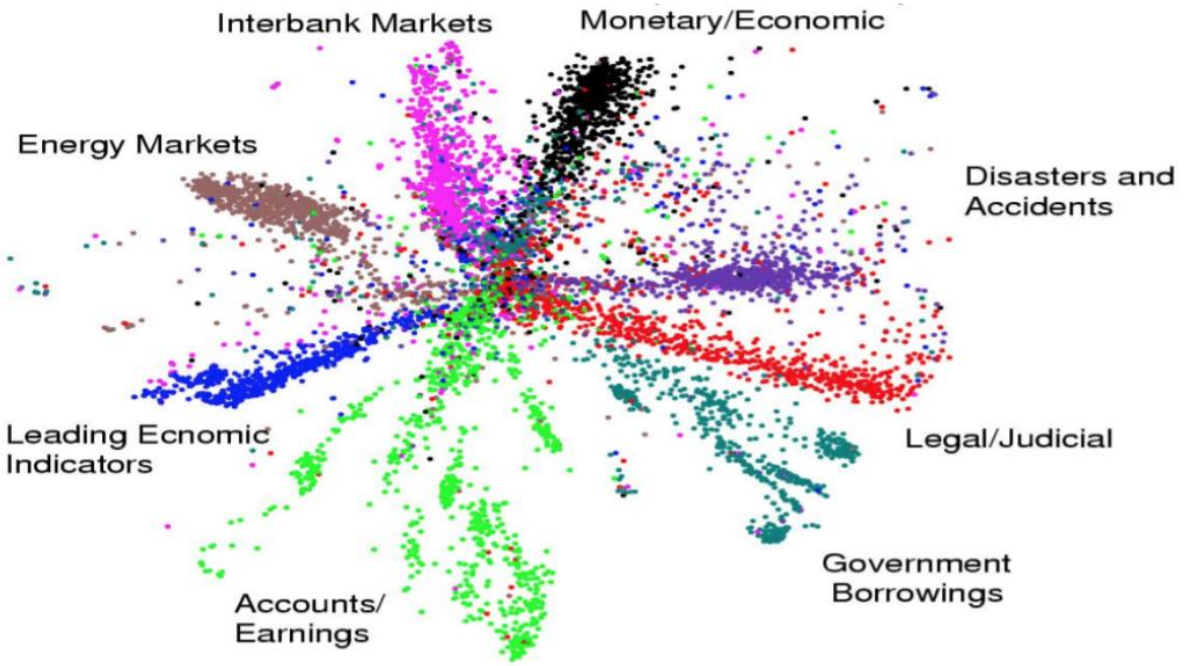
Autoencoders no lineales

- Los autoencoders no lineales pueden aprender códigos más potentes para una dimensionalidad dada, en comparación con los autoencoders lineales (PCA)

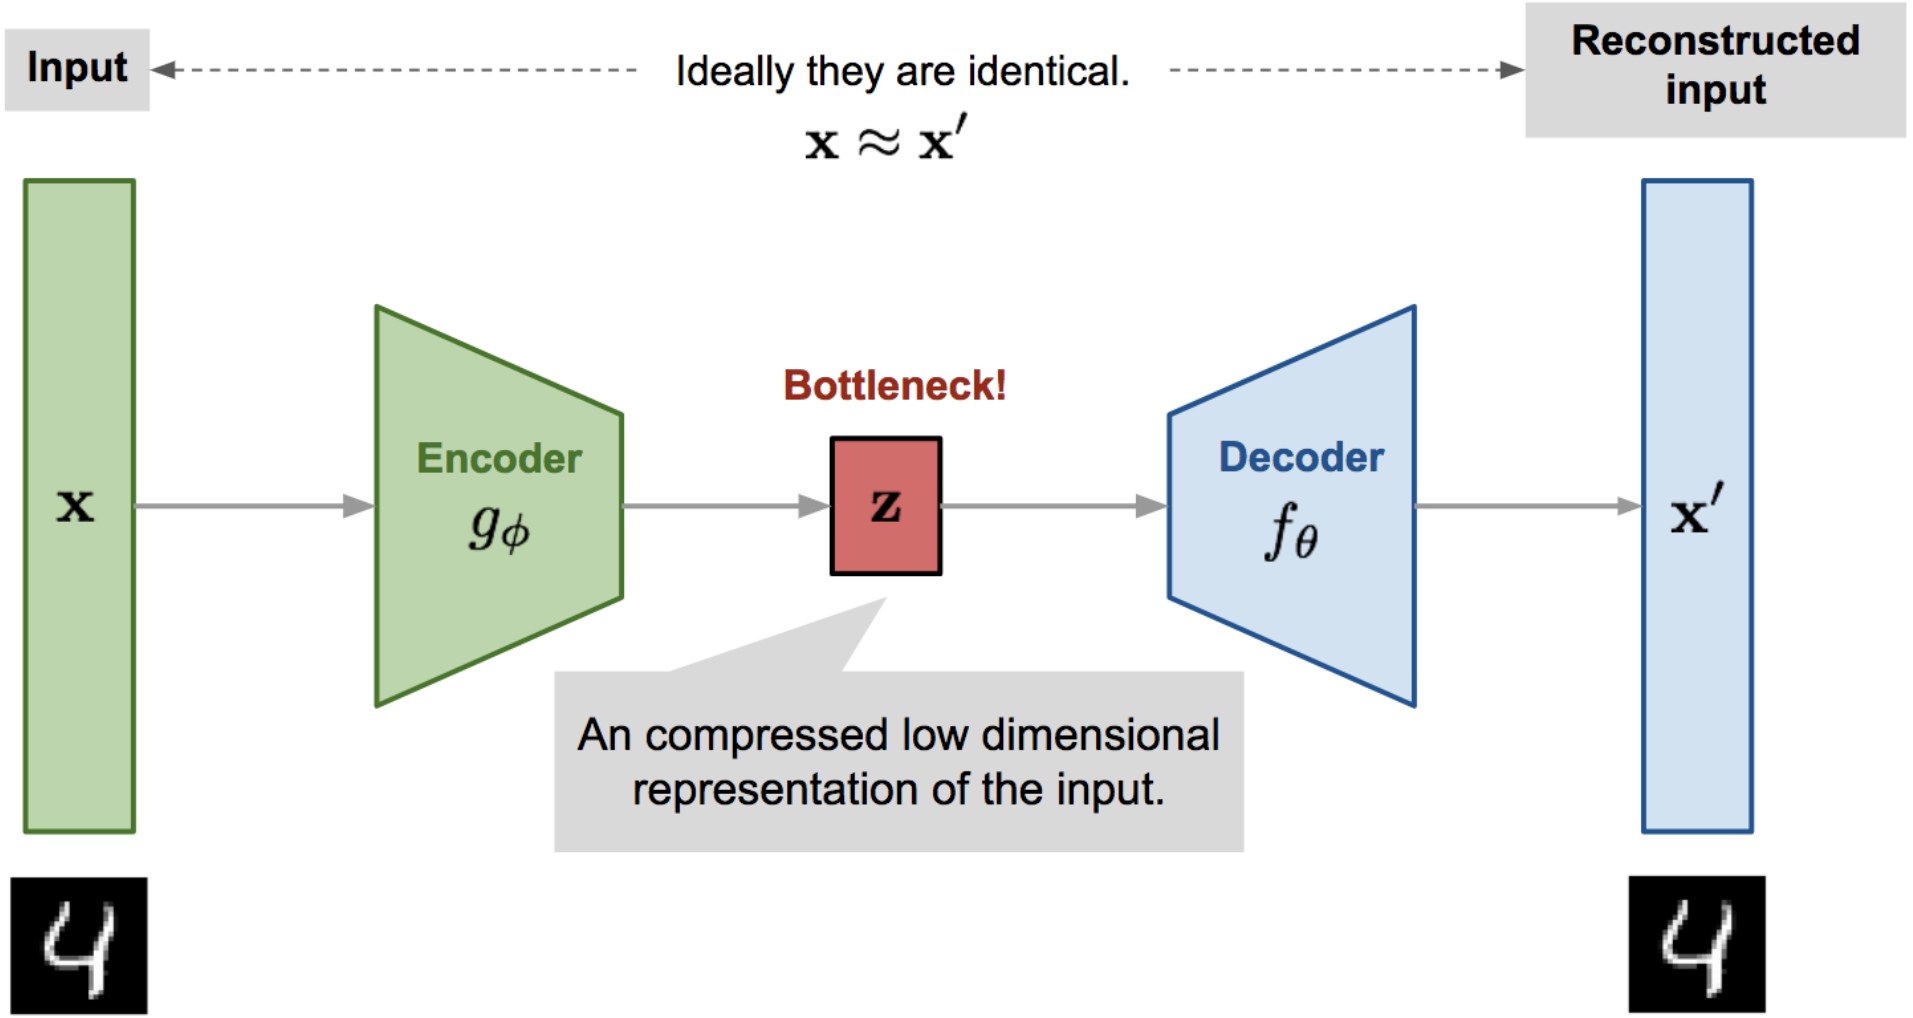


Autoencoders no lineales

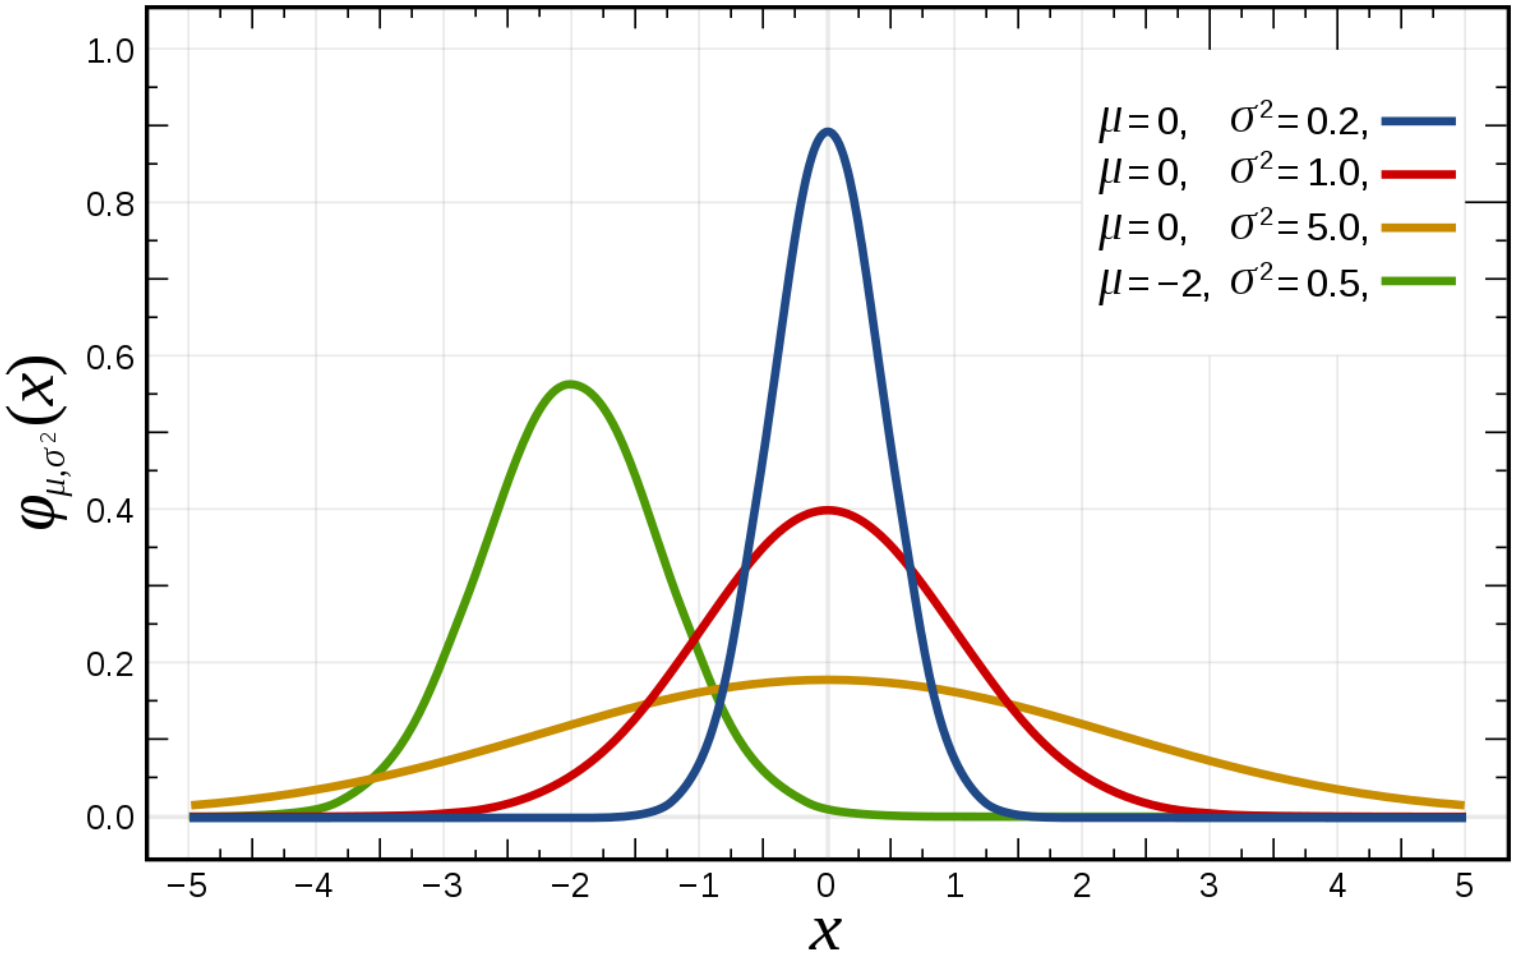
- Aquí hay una representación de autocodificador bidimensional de artículos de grupos de noticias. Están codificados por colores según el tema, pero al algoritmo no se le proporcionaron las etiquetas.



Reducir la dimensionalidad: Autoencoders



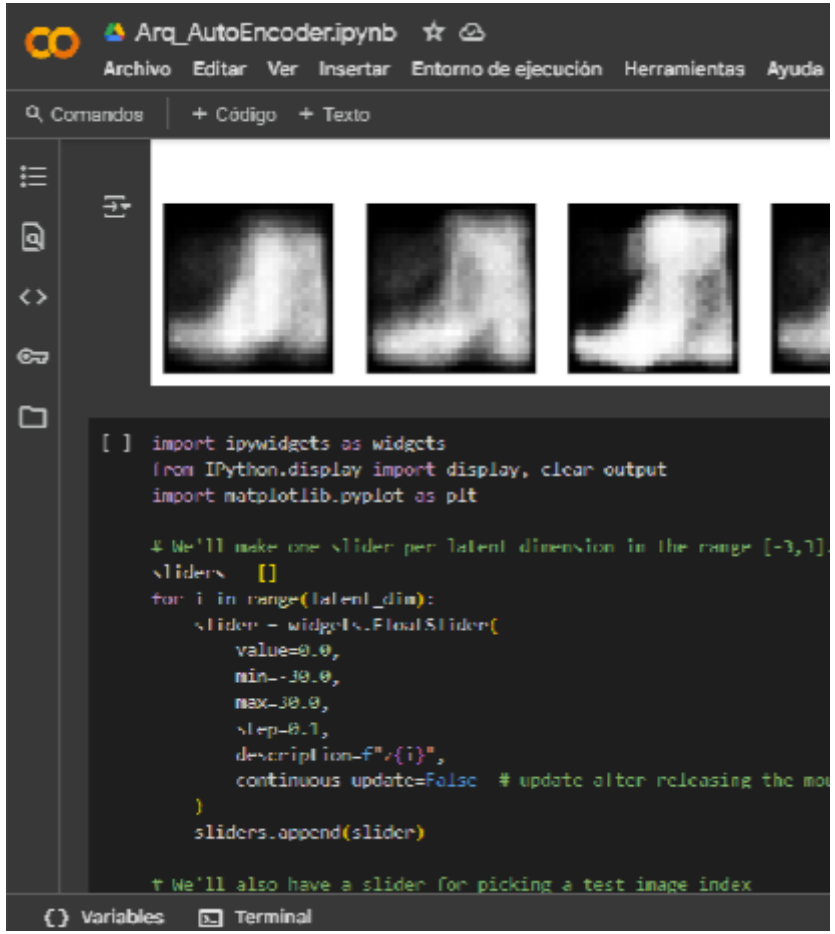
Hemos pasado de modelos de distribuciones



A modelos mas complejos matemáticamente pero de mayor aplicabilidad



Ejemplo en Colab



Preguntas del Vibe Quest

- ¿Cómo podemos interpretar el espacio latente de un autoencoder desde una perspectiva bayesiana vs. frecuentista? Explora las diferencias conceptuales y matemáticas.
- ¿Cómo podríamos modificar la función de pérdida de un autoencoder para incorporar principios bayesianos? Explora autoencoders variacionales y su relación con la inferencia bayesiana.
- ¿De qué manera podemos cuantificar la incertidumbre en las representaciones del espacio latente? Investiga cómo aplicar principios de estadística bayesiana para lograrlo.
- Explora el concepto de "manifold learning" en autoencoders y cómo se relaciona con PCA. ¿Cuáles son las implicaciones teóricas y prácticas de estas diferencias?
- Investiga cómo el espacio latente de un autoencoder puede ser regularizado para reflejar propiedades específicas de un dominio (física, química, biología), manteniendo la capacidad de reconstrucción.