Pontificia Universidad Católica del Perú
Facultad de Ciencias e Ingeniería
Departamento Académico de Ingeniería



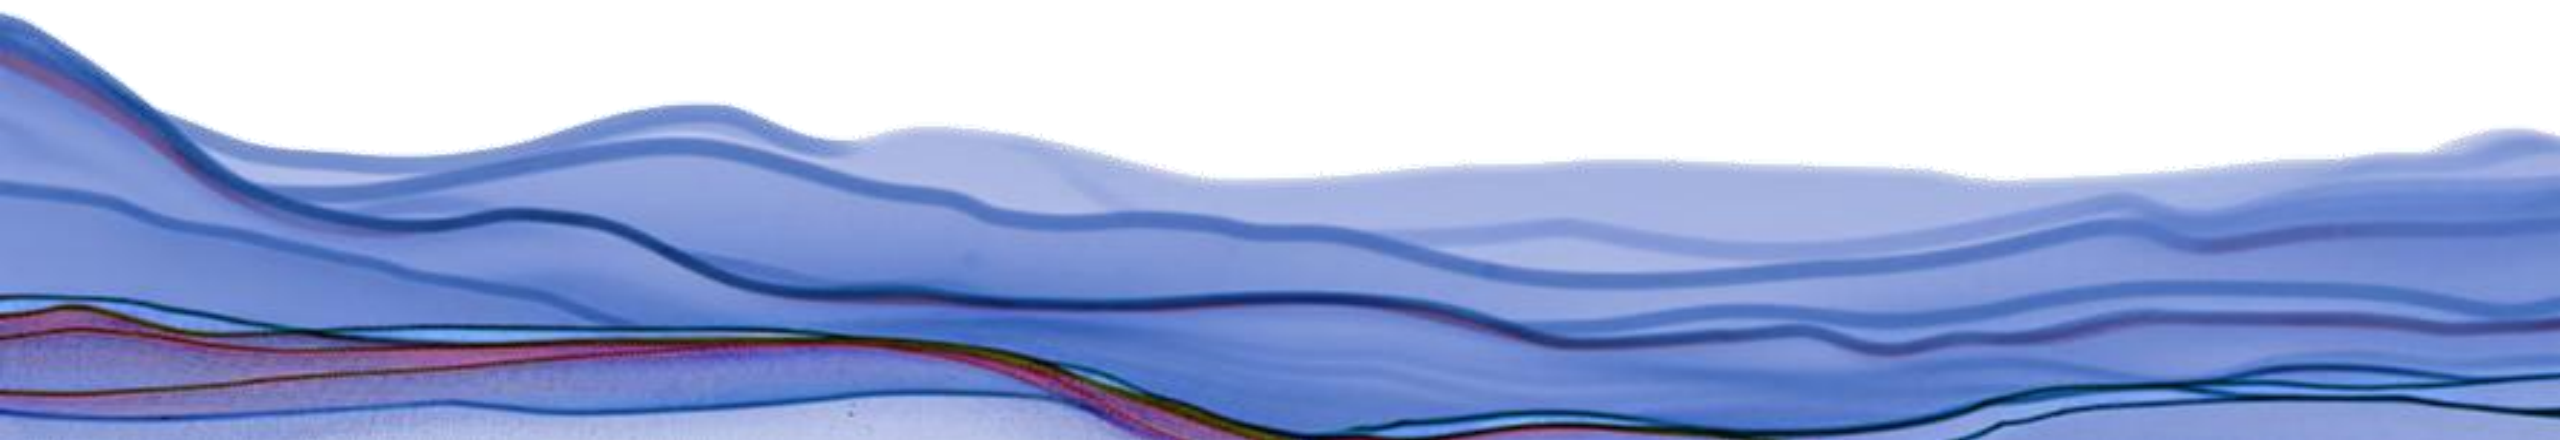
INF659 TÉCNICAS AVANZADAS DE DATA MINING Y SISTEMAS INTELIGENTES

Redes Neuronales Recurrentes

Prof. Rodrigo Uribe

Outline

- Introduciendo RNN
- Retropropagación a Través del Tiempo
- Aplicaciones de RNN
- Gradientes Explosivos y Desvanecientes



Respuestas del Vibe Quest

- Considerando los diversos métodos presentados para aprender representaciones de datos (como los autoencoders lineales que se relacionan con PCA, los autoencoders no lineales que aprenden variedades, y el objetivo de los embeddings de capturar relaciones semánticas como en el ejemplo de "rey" - "hombre" + "mujer" = "reina"): ¿Cuáles son las consideraciones arquitectónicas (por ejemplo, tipos de capas, funciones de activación, dimensionalidad del espacio latente) y las funciones de pérdida (más allá de la simple reconstrucción) más críticas al diseñar un sistema específicamente para generar embeddings que no solo compriman la información, sino que estructuren el espacio latente de manera que las distancias y direcciones reflejen relaciones semánticas útiles y transferibles a tareas posteriores?
- Considerando los avances en autoencoders variacionales (VAEs) y su capacidad para modelar distribuciones de datos complejas: ¿Cuáles son los desafíos y las oportunidades más significativos al intentar escalar los VAEs para generar datos de altísima dimensionalidad y fidelidad (por ejemplo, videos fotorrealistas o secuencias genómicas completas) manteniendo al mismo tiempo un espacio latente interpretable y controlable?
- La presentación discute la polisemanticidad y los esfuerzos por lograr características monosemánticas mediante autoencoders en modelos grandes. ¿De qué manera la capacidad emergente de "dirigir" o influenciar el comportamiento de modelos de lenguaje extensos, manipulando estas características internas, podría transformar las metodologías de auditoría, alineación y detección de sesgos en la inteligencia artificial, y qué nuevos riesgos éticos plantea esta capacidad de intervención detallada?
- Más allá de la similitud semántica básica que capturan los embeddings actuales en bases de datos vectoriales: ¿Cómo podrían evolucionar las técnicas de embedding y las arquitecturas de bases de datos vectoriales para representar y consultar eficientemente relaciones más complejas, como la causalidad, la jerarquía conceptual o la lógica argumentativa, directamente dentro del espacio vectorial?



¿Cuál es el problema con las CNN o los autoencoders?

Sus limitaciones…



ARTICLE:

-lrb- cnn -rrb- an officer , responding to reports of a suspicious person , shot and killed an unarmed man who was running around in a metro atlanta apartment complex naked . the officer fired two shots when the man charged at him , said cedric alexander , the public safety director of dekalb county . but given that the man was not carrying a weapon , the police department immediately turned over the case to the georgia bureau of investigations for an independent probe . `` what i have requested here -lsb- is -rsb- a result of what 's going on currently across this country as it relates to police shootings , '' alexander told reporters . the officer was white ; the deceased man was african-american , alexander said . the incident took place monday afternoon at an apartment complex in chamblee , a suburb of atlanta . someone called 911 to report a man `` acting deranged , knocking on doors and crawling around naked , '' alexander said . when the officer arrived , the man charged at him , alexander said . `` the officer called him to stop while stepping backward , drew his weapon and fired two shots , '' he said . the man , struck twice in the upper body , died . police later learned he was a resident at the complex . `` i can only reasonably assume that if he was running around the apartment complex naked , i believe we can make the assumption there may have been some mental health experience that he might have been having , '' alexander said . dekalb county police officers undergo some degree of training on how to deal with the mentally ill . but this , and other incidents , highlight the need for more , the public safety director said . `` that 's becoming more and more apparent , '' alexander said . `` we have already , as many departments have begun to do , look at how to expand our mental health training when we find it certainly necessary to do so . because it appears that we 're seeing more and more of these cases across the country in which police are engaging with those who appear to be in distress . '' police did not release the officer 's name , but said

PREDICTED SUMMARY:

the officer fired two shots when the man charged at him , said cedric alexander , the public safety director of dekalb county , dekalb county . the man , struck twice in the upper body , died . police later learned he was a resident at the complex .

¿Qué hace esta red?



ARTICLE:

-lrb- cnn -rrb- an officer , responding to reports of a suspicious person , shot and killed an unarmed man who was running around in a metro atlanta apartment complex naked . the officer fired two shots when the man charged at him , said cedric alexander , the public safety director of dekalb county . but given that the man was not carrying a weapon , the police department immediately turned over the case to the georgia bureau of investigations for an independent probe . `` what i have requested here -lsb- is -rsb- a result of what 's going on currently across this country as it relates to police shootings , '' alexander told reporters . the officer was white ; the deceased man was african-american , alexander said . the incident took place monday afternoon at an apartment complex in chamblee , a suburb of atlanta . someone called 911 to report a man `` acting deranged , knocking on doors and crawling around naked , '' alexander said . when the officer arrived , the man charged at him , alexander said . `` the officer called him to stop while stepping backward , drew his weapon and fired two shots , '' he said . the man , struck twice in the upper body , died . police later learned he was a resident at the complex . `` i can only reasonably assume that if he was running around the apartment complex naked , i believe we can make the assumption there may have been some mental health experience that he might have been having , '' alexander said . dekalb county police officers undergo some degree of training on how to deal with the mentally ill . but this , and other incidents , highlight the need for more , the public safety director said . `` that 's becoming more and more apparent , '' alexander said . `` we have already , as many departments have begun to do , look at how to expand our mental health training when we find it certainly necessary to do so . because it appears that we 're seeing more and more of these cases across the country in which police are engaging with those who appear to be in distress . '' police did not release the officer 's name , but said

Ejemplo: Resumir el texto!



Predicción Sequence-to-Sequence

- La predicción secuencia-a-secuencia: entrada y salida son secuencias.
- Predecir secuencias tiene muchas aplicaciones:
    - voz-a-texto, texto-a-voz, subtitulado de imágenes, traducción automática, etc.

¿Qué otros modelos conocen que hacen secuencias?

Modelos Autoregresivos

$p(w_t|w_{t-3}, w_{t-2}, w_{t-1})$: Problema de predicción supervisada:

predecir la distribución de cada palabra dada las K palabras anteriores.

Un modelo autorregresivo utiliza sus propios valores pasados (auto) para predecir valores futuros mediante regresión (regresivo).

auto significa “uno mismo”.

- El modelo utiliza sus salidas/valores anteriores para predecir el siguiente valor. El modelo es autorreferencial.

regresivo se refiere a “regresión”

- La regresión se utiliza para predecir el valor actual en función de los valores pasados.

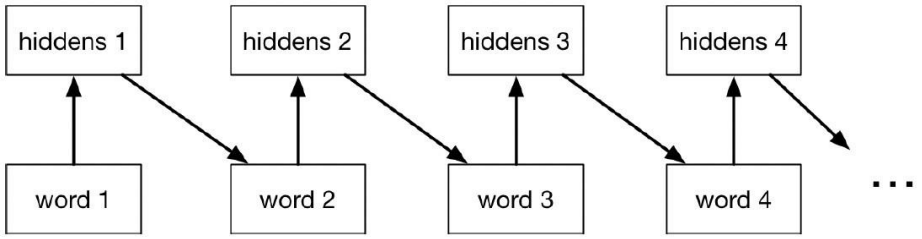
Desafío de Dependencias de Largo Alcance en Modelos Autorregresivos

- El lenguaje real requiere conexiones de larga distancia
  - Ejemplo: "El gato se sentó en la alfombra. Era esponjoso." ("Era" → "gato")
- La suposición de Markov de los modelos autorregresivos limita la comprensión.
  - Solo considera palabras recientes, ignorando contexto anterior crucial
- Consecuencias:
  - Falla en capturar estructuras de oraciones complejas.
  - No puede mantener coherencia a través de textos más largos.
  - Pierde relaciones entre elementos distantes.

RNNs: Añadiendo Memoria para Dependencias a Largo Plazo

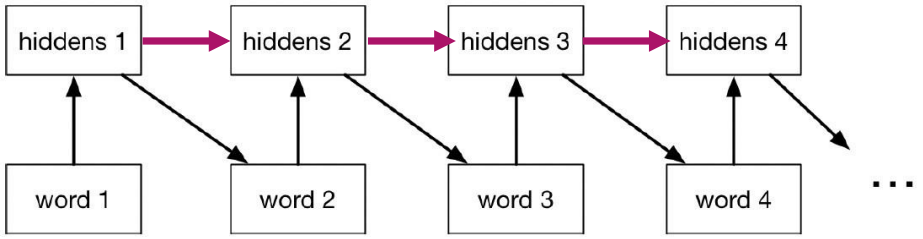
Modelos autorregresivos son sin memoria

- Cada estado oculto solo depende de la entrada actual
- No hay intercambio de información entre estados ocultos



RNNs incorporan memoria

- añaden conexiones (memoria) entre las unidades ocultas
- la información fluye a través de la secuencia



Notas sobre Modelos Autorregresivos versus RNNs

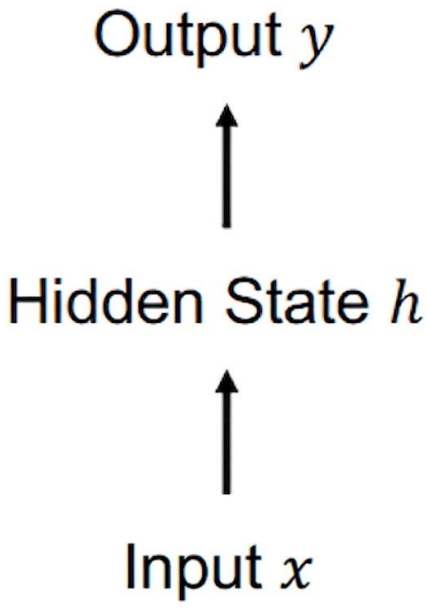
Modelos autorregresivos

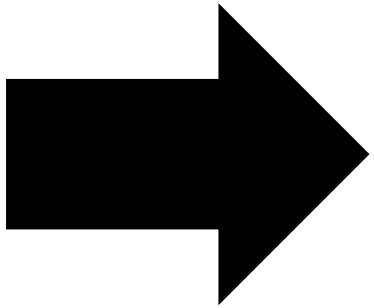
- "sin memoria"
- cada estado oculto depende solo de la palabra de entrada actual
- no hay intercambio de información entre estados ocultos
- cada predicción depende del contexto limitado

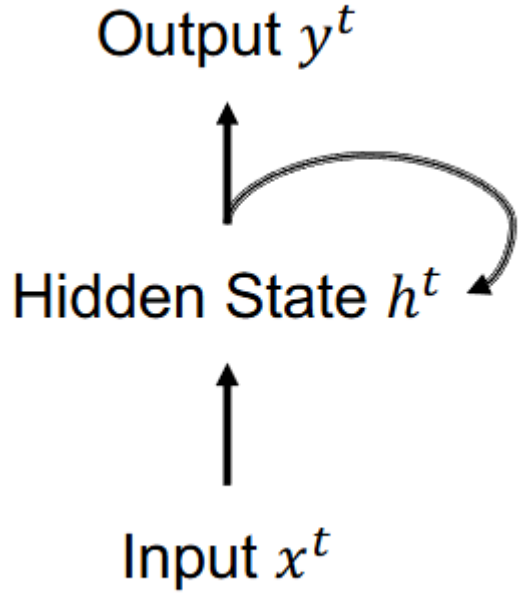
RNNs

- añaden conexiones entre estados ocultos
- la información fluye a través de la secuencia
- las conexiones funcionan como una forma de memoria
- ej. la palabra 1 puede influir en predicciones hasta la palabra 4 y más allá
- mantienen contexto sobre secuencias más largas
- hacen predicciones coherentes basadas en todo el historial

Redes Neuronales Normales vs Recurrentes

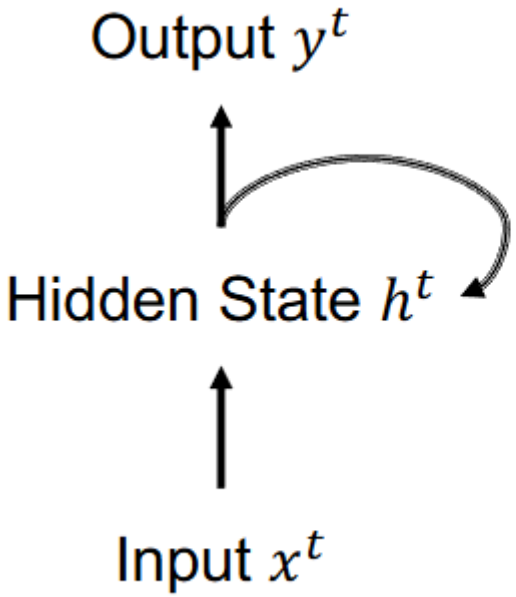


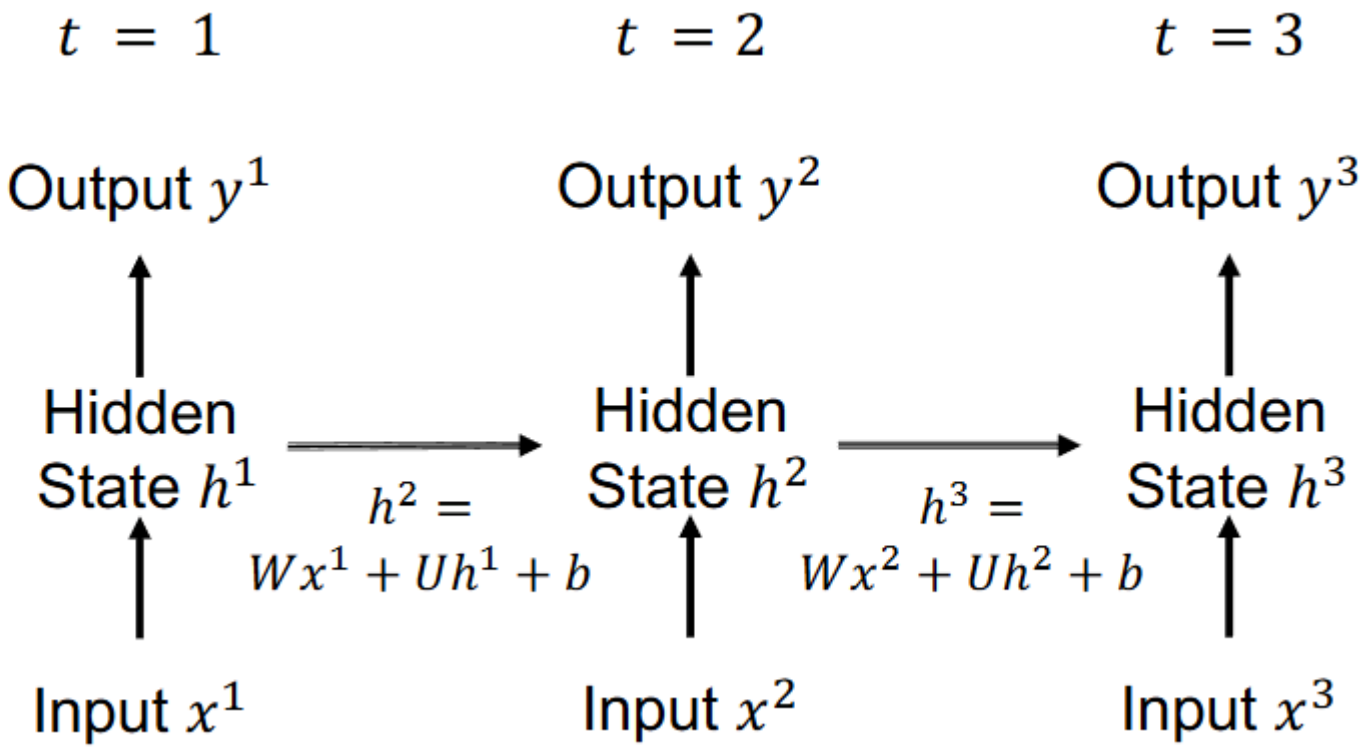




¿Ecuación?

Redes Neuronales Recurrentes





Las RNN pueden entenderse de dos formas

Interpretación 1:

- Como un sistema dinámico con auto-bucles
- Las unidades ocultas se retroalimentan a sí mismas.

Interpretación 2:

- Como una red desplegada
- Representando explícitamente las mismas unidades en diferentes pasos de tiempo

Característica clave de RNN:

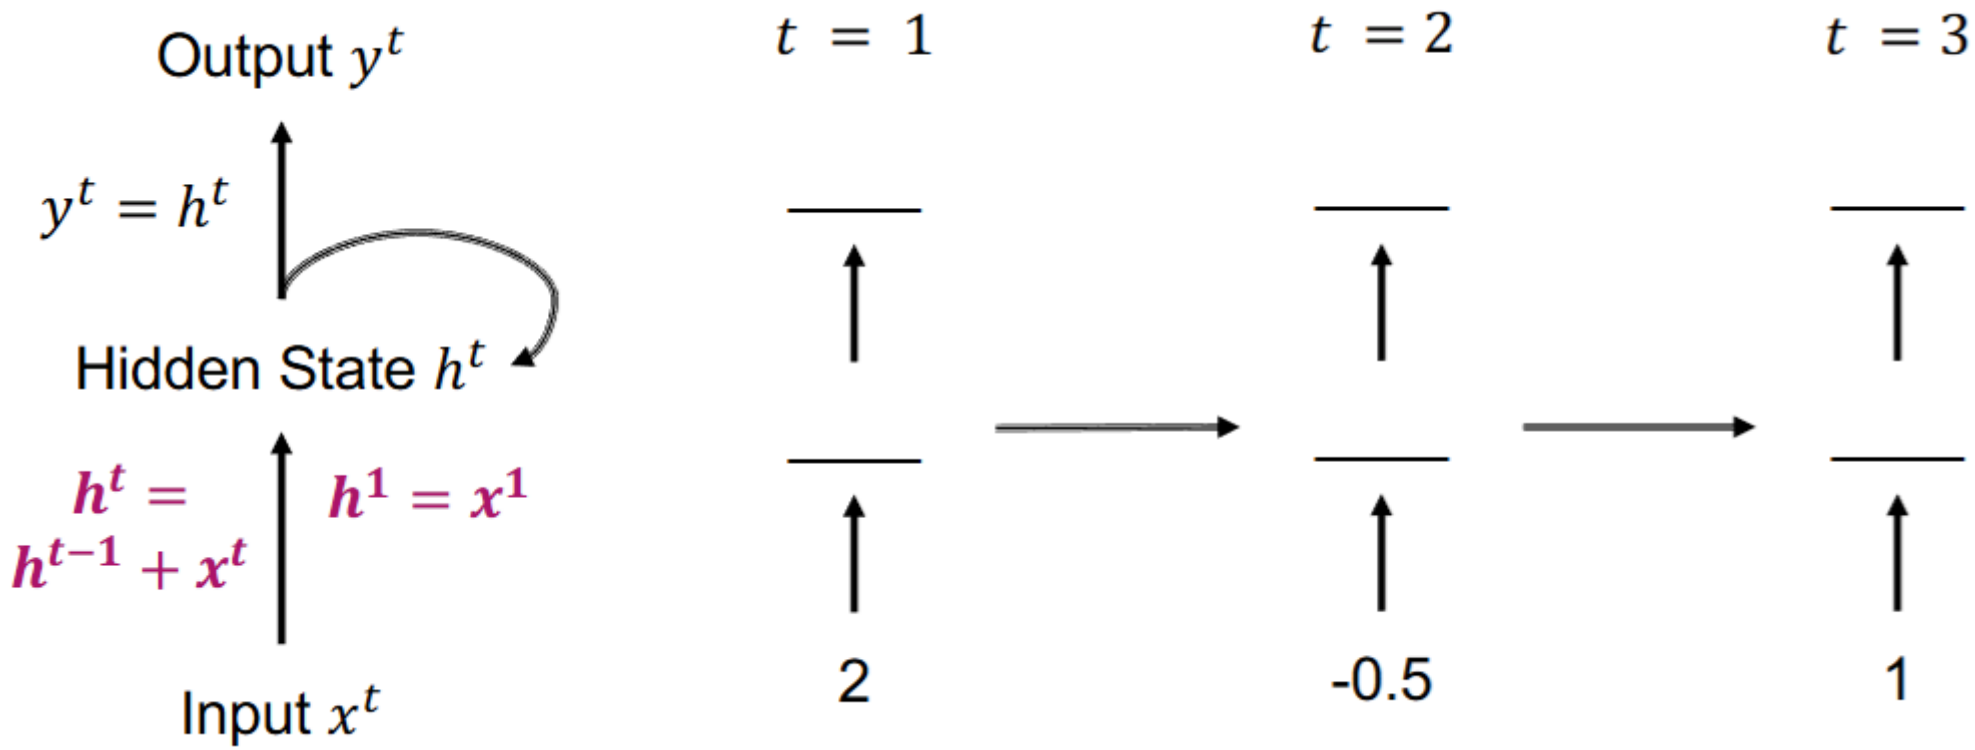
- Los pesos y sesgos se comparten a través de todos los pasos de tiempo (excepto los del primer paso)
- La red aplica la misma transformación en cada paso de tiempo.



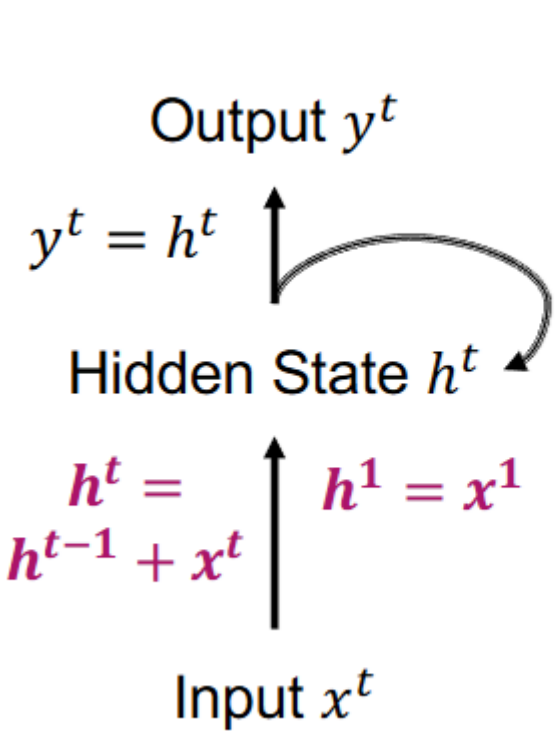
Algunos Ejemplos Juguete de RNNs

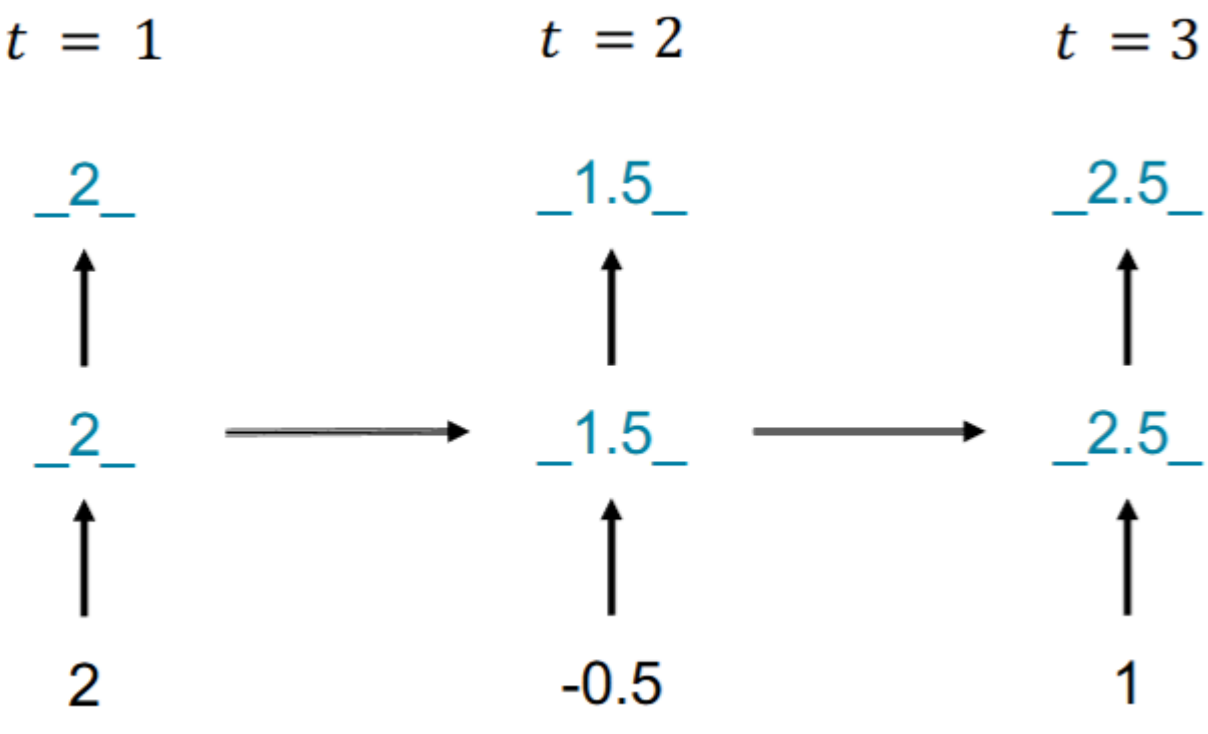
- RNN #1 ???
- RNN #2 ???

RNN #1: ?? ¿Qué hace?



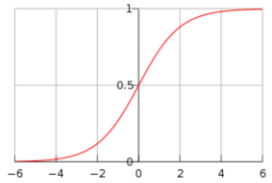
RNN #1 Suma Sus Entradas





RNN #2: ?? ¿Qué hace?

$$f(x) = \frac{1}{1 + e^{-x}}$$



Output y^t

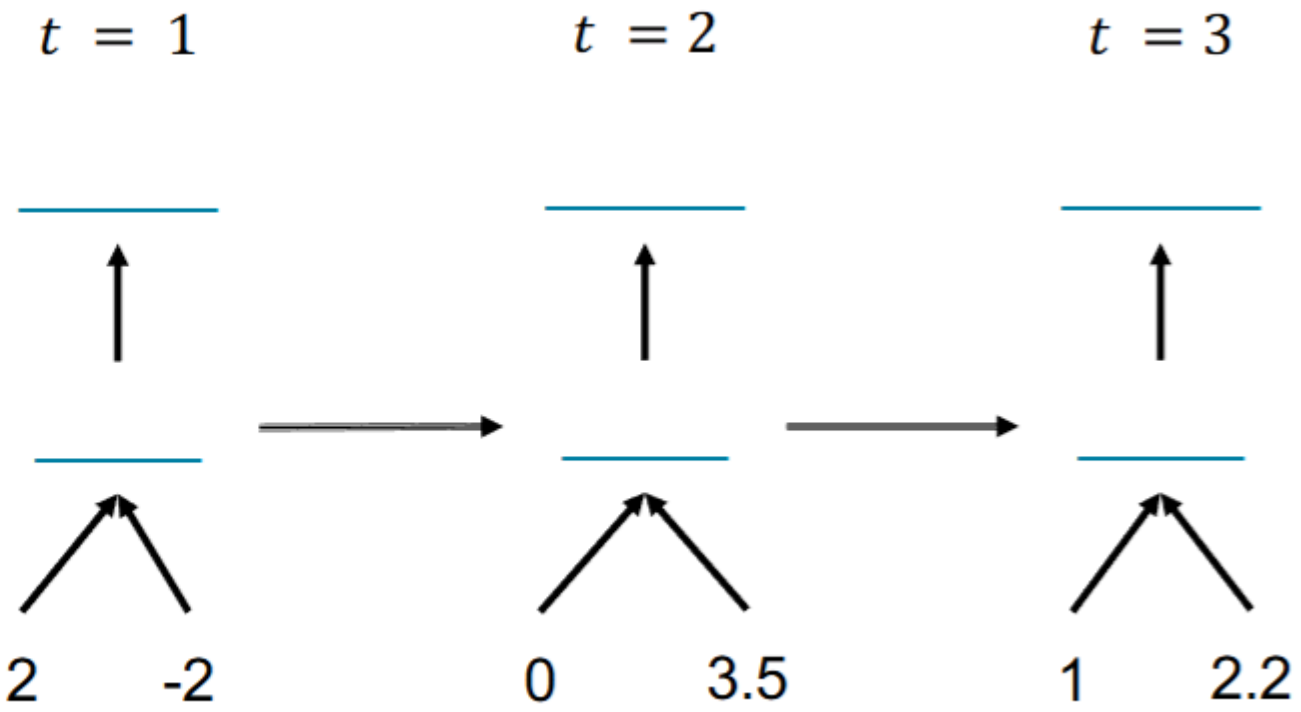
$y^t = \sigma(5h^t)$

Hidden State h^t

$h^t = h^{t-1} + x_1^t - x_2^t$

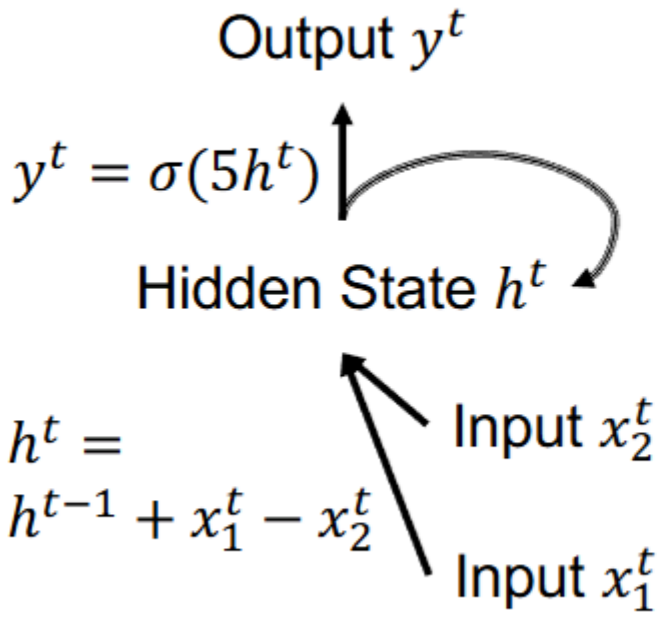
Input x_2^t

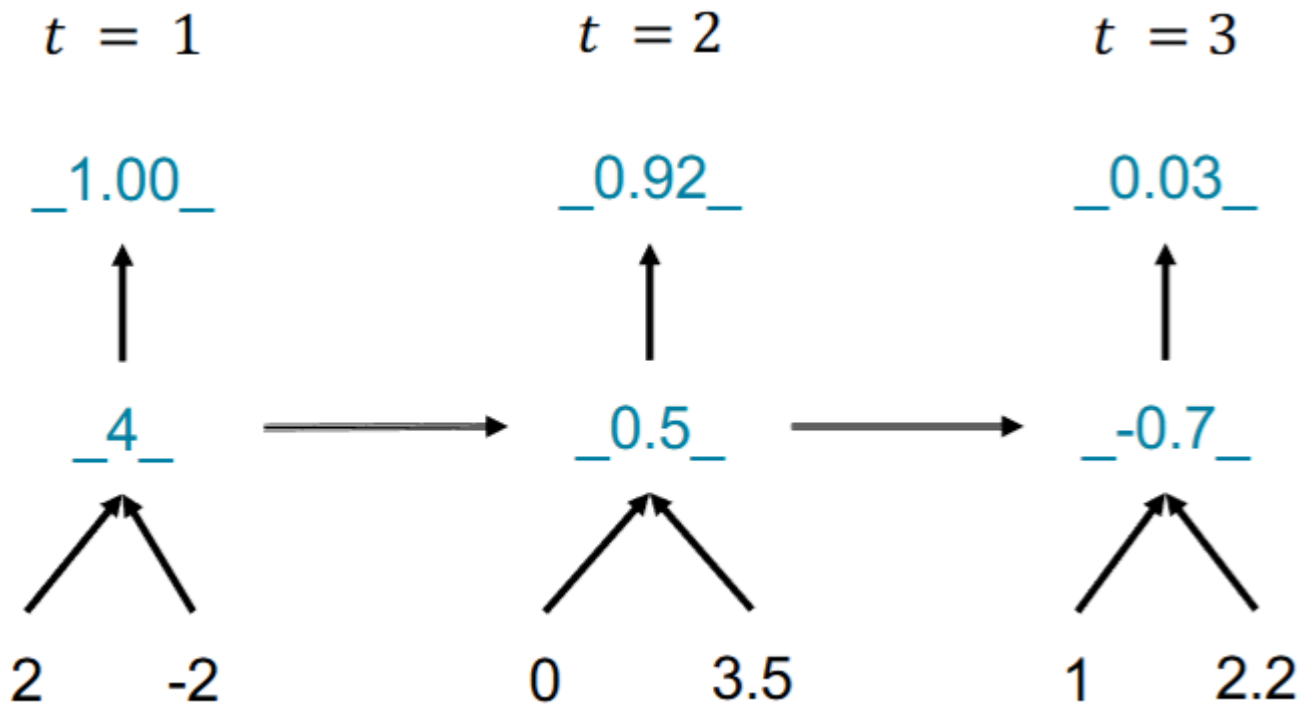
Input x_1^t



RNN #2 Determina Qué Secuencia Tiene una Suma Mayor

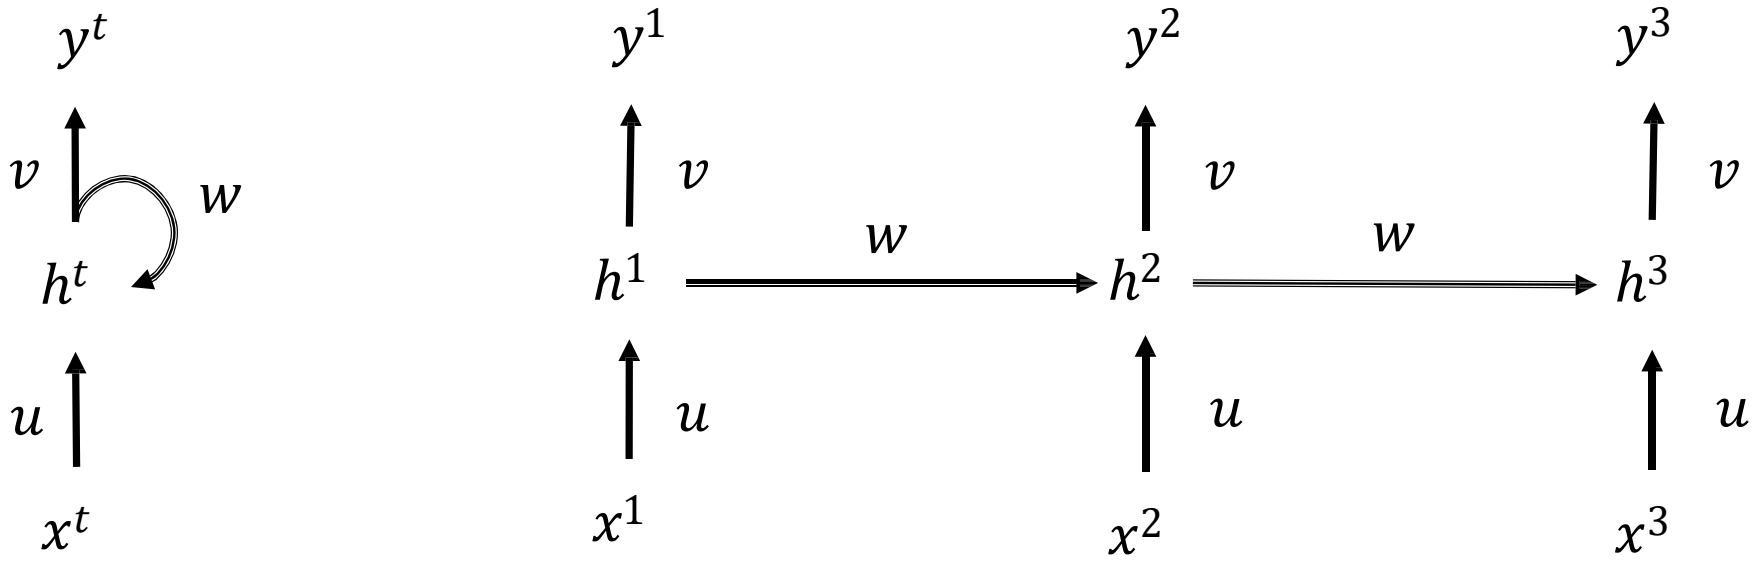
Multiplicar por 5 amplifica la diferencia, haciendo que la salida sea más decisiva.





Retropropagación a Través del Tiempo

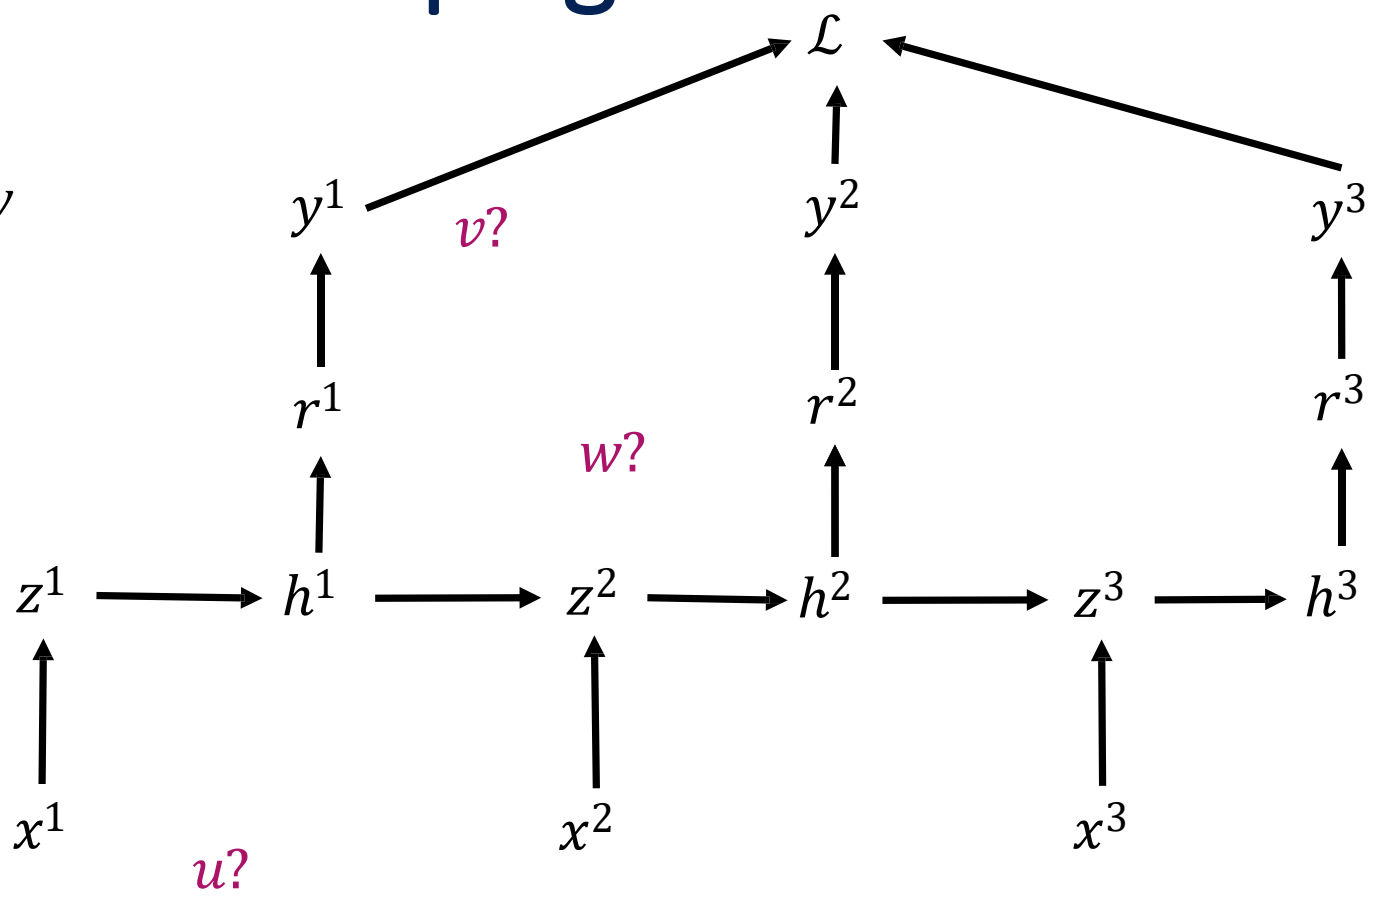
Para aprender los pesos y sesgos en una RNN, realizaremos retropropagación en la red desplegada → Retropropagación a Través del Tiempo



Todas las cantidades son escalares. No hay parámetros de sesgo.

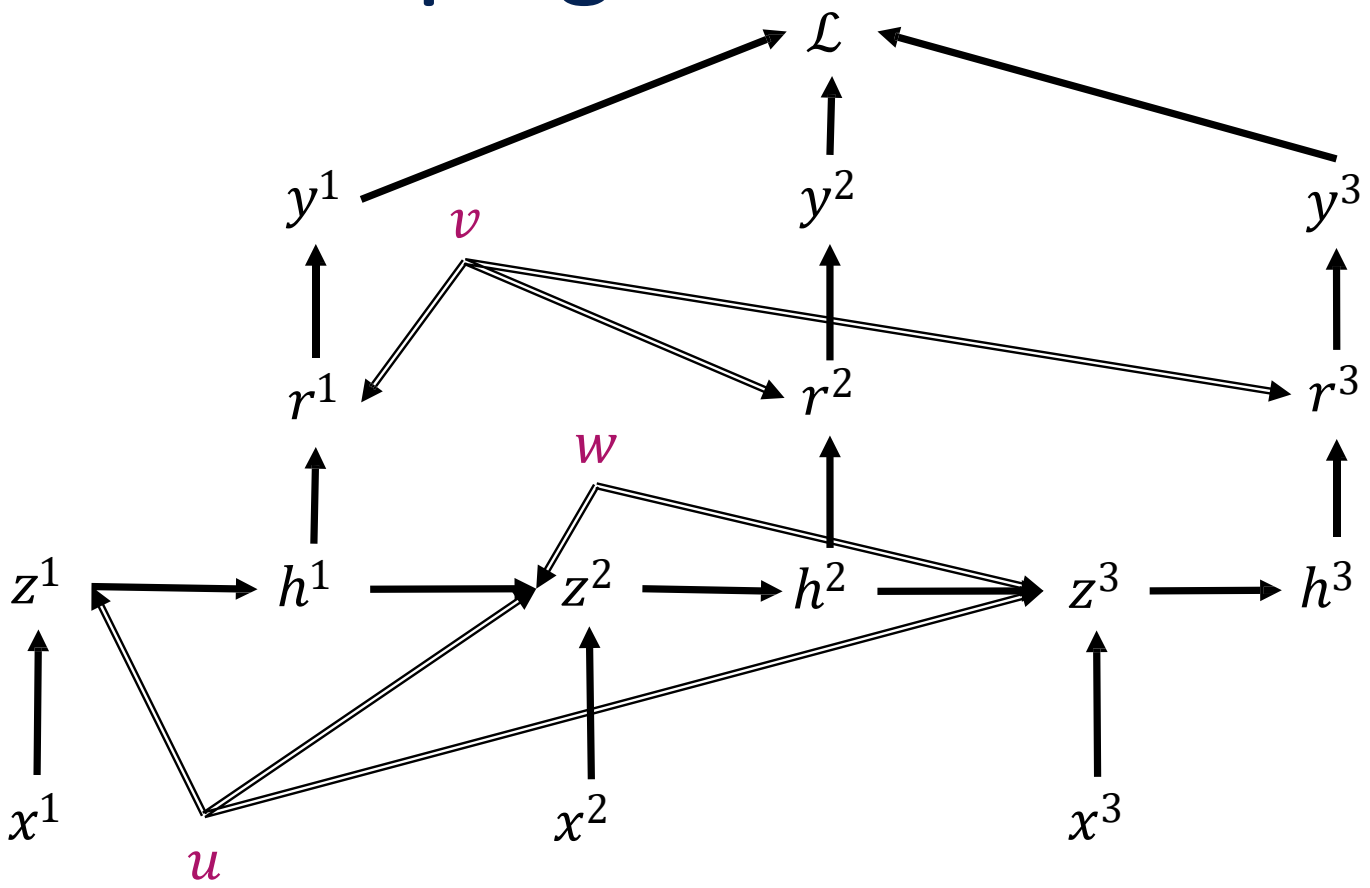
Desplegado

Agregar conexiones desde los pesos u, v, w a la red.



Desplegado

¡Noten los pesos compartidos!



Forward Pass en la RNN

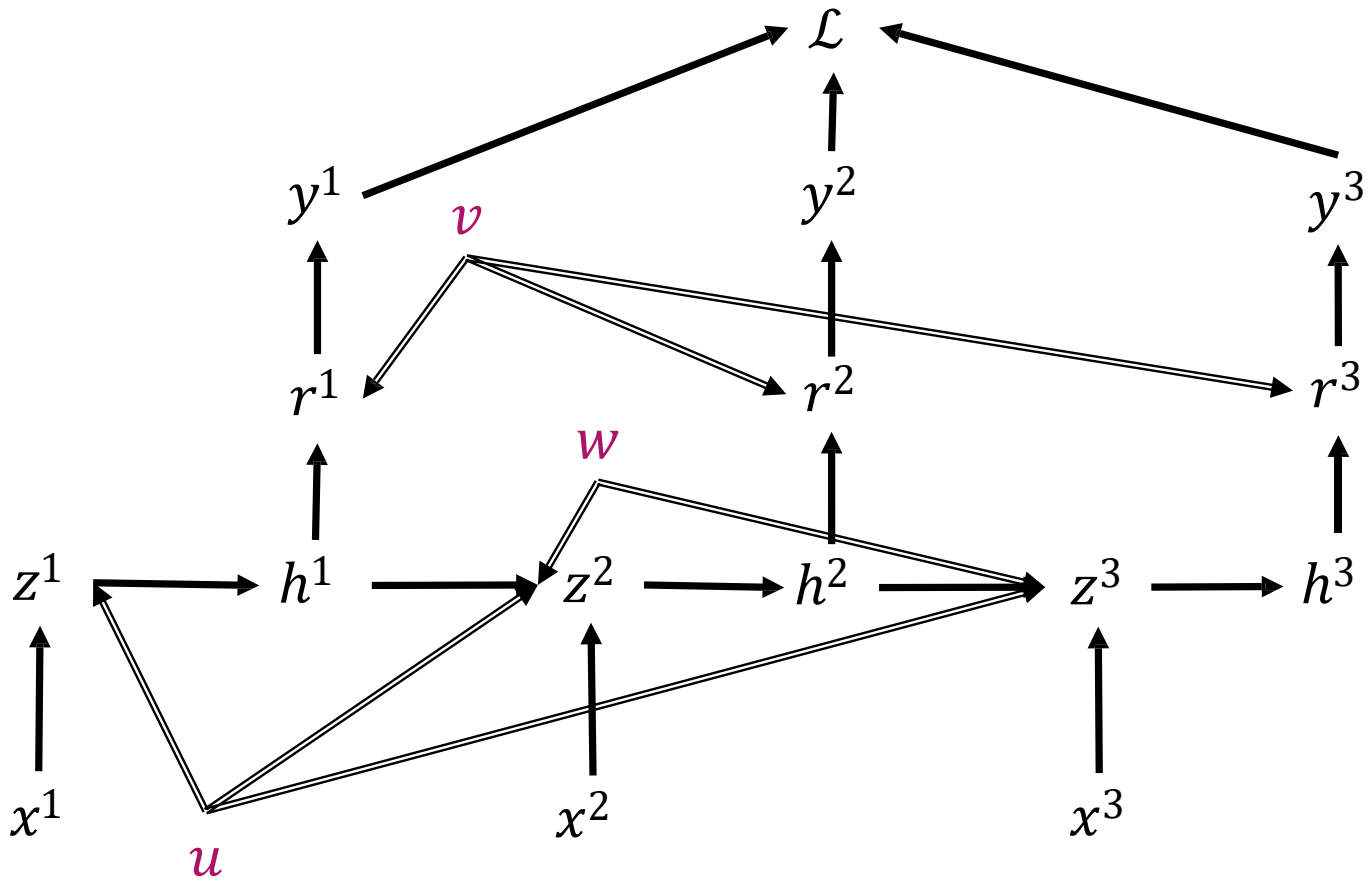
$$z^t = wh^{t-1} + ux^t$$

$$h^t = \phi(z^t)$$

$$r^t = vh^t$$

$$y^t = \phi(r^t)$$

$$\mathcal{L}(y^1, y^2, \dots, t^1, t^2, \dots)$$



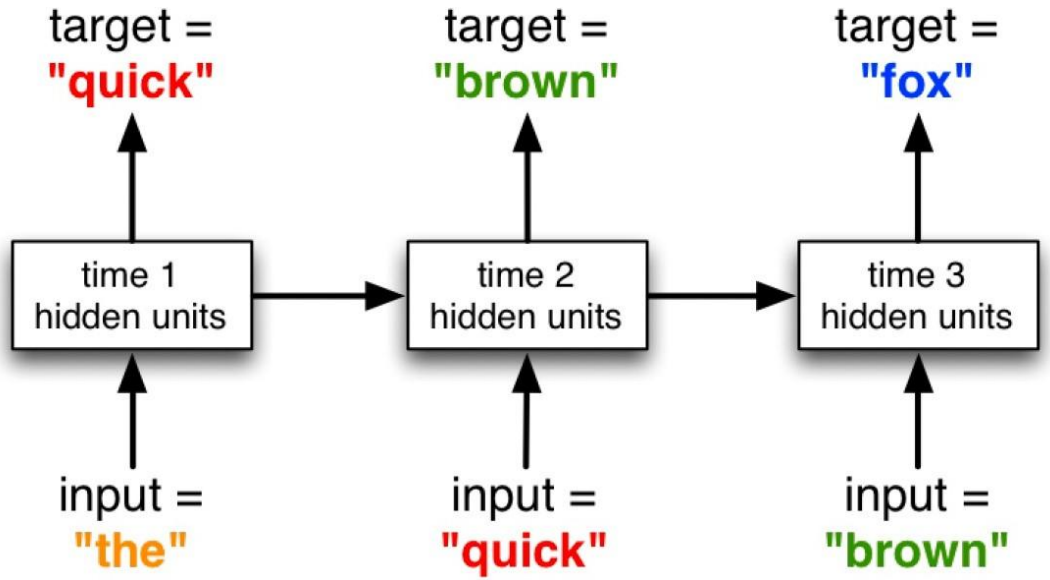


Aplicaciones de RNN

1. Modelado de Lenguaje
2. Traducción Automática
3. Interpretación de Programas

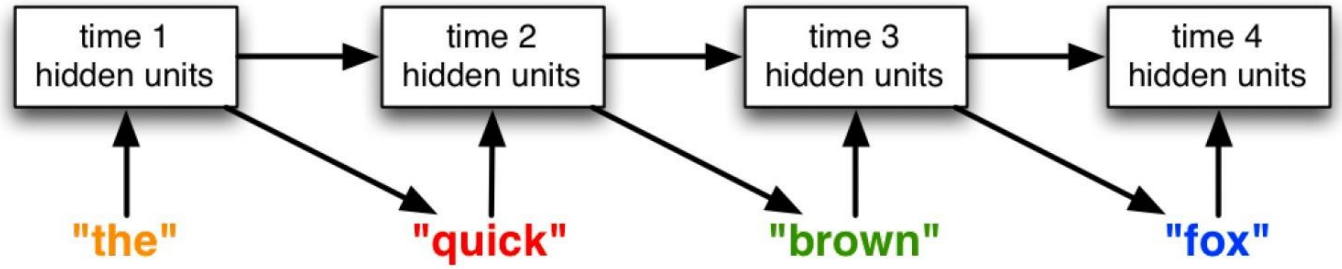
1- Modelado de Lenguaje usando RNN

- Cada palabra como un vector one-hot
- Predice una distribución sobre la siguiente palabra
- Cada palabra sirve como entrada y objetivo.
- El entrenamiento utiliza la pérdida de entropía cruzada
- Puede capturar dependencias de larga distancia.



Generación Versus Entrenamiento

- Generando datos del modelo: Usar salidas del modelo como entradas para el siguiente paso de tiempo
- Entrenando el modelo con *Teacher Forcing*: Usar salida objetivo (verdad fundamental) de los datos de entrenamiento como entrada para el siguiente paso de tiempo
- Desafío en generación de secuencias: podemos entrenar modelos usando entradas de verdad fundamental pero debemos generar secuencias basadas en predicciones del modelo potencialmente incorrectas



Desafíos Restantes en Modelado de Lenguaje
El Problema de Usar Palabras

- Escala del Vocabulario: Los vocabularios modernos incluyen millones de entidades (personas, lugares, términos técnicos)
- Fuera del Vocabulario: Los modelos tienen dificultades con palabras nuevas, nombres y términos no vistos durante el entrenamiento
- Límites de Palabras: Idiomas como alemán, chino y finlandés crean palabras compuestas o carecen de separadores claros

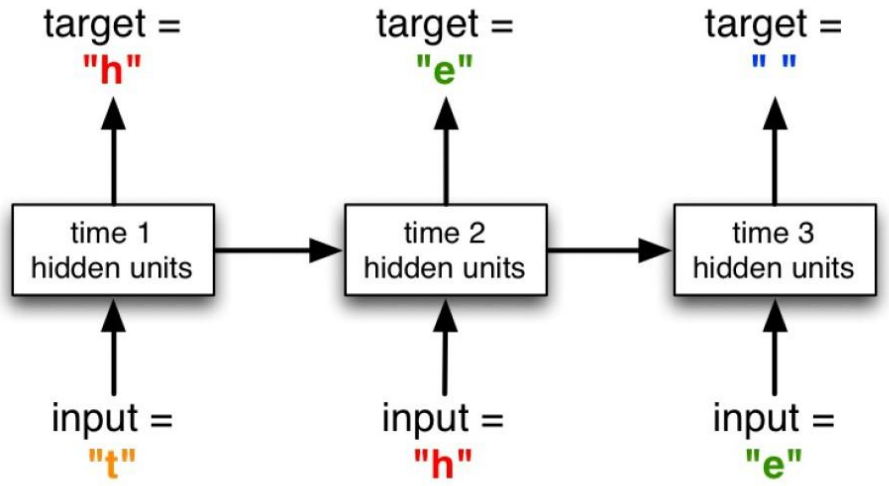
Prediciendo un Carácter a la Vez

Intentar modelado a nivel de caracteres en lugar de modelado a nivel de palabras

¿Qué desafío(s) puede resolver este enfoque?

A. Escala del Vocabulario
B. Fuera del Vocabulario
C. Límites de Palabras

¡La memoria a largo plazo se vuelve crítica!



Modelado de Lenguaje a Nivel de Caracteres

Ventajas:

- Elimina completamente el problema de fuera de vocabulario
- Puede generar palabras nuevas no vistas durante el entrenamiento
- Maneja múltiples idiomas con un solo vocabulario
- Funciona con palabras compuestas arbitrarias y morfología

Desafíos:

- Longitud de secuencia aumentada (×5-10 comparado con modelos de palabras)
- Interacciones multiplicativas para modelar combinaciones de caracteres
- Típicamente requiere redes más profundas

Limitaciones de RNN a Nivel de Caracteres

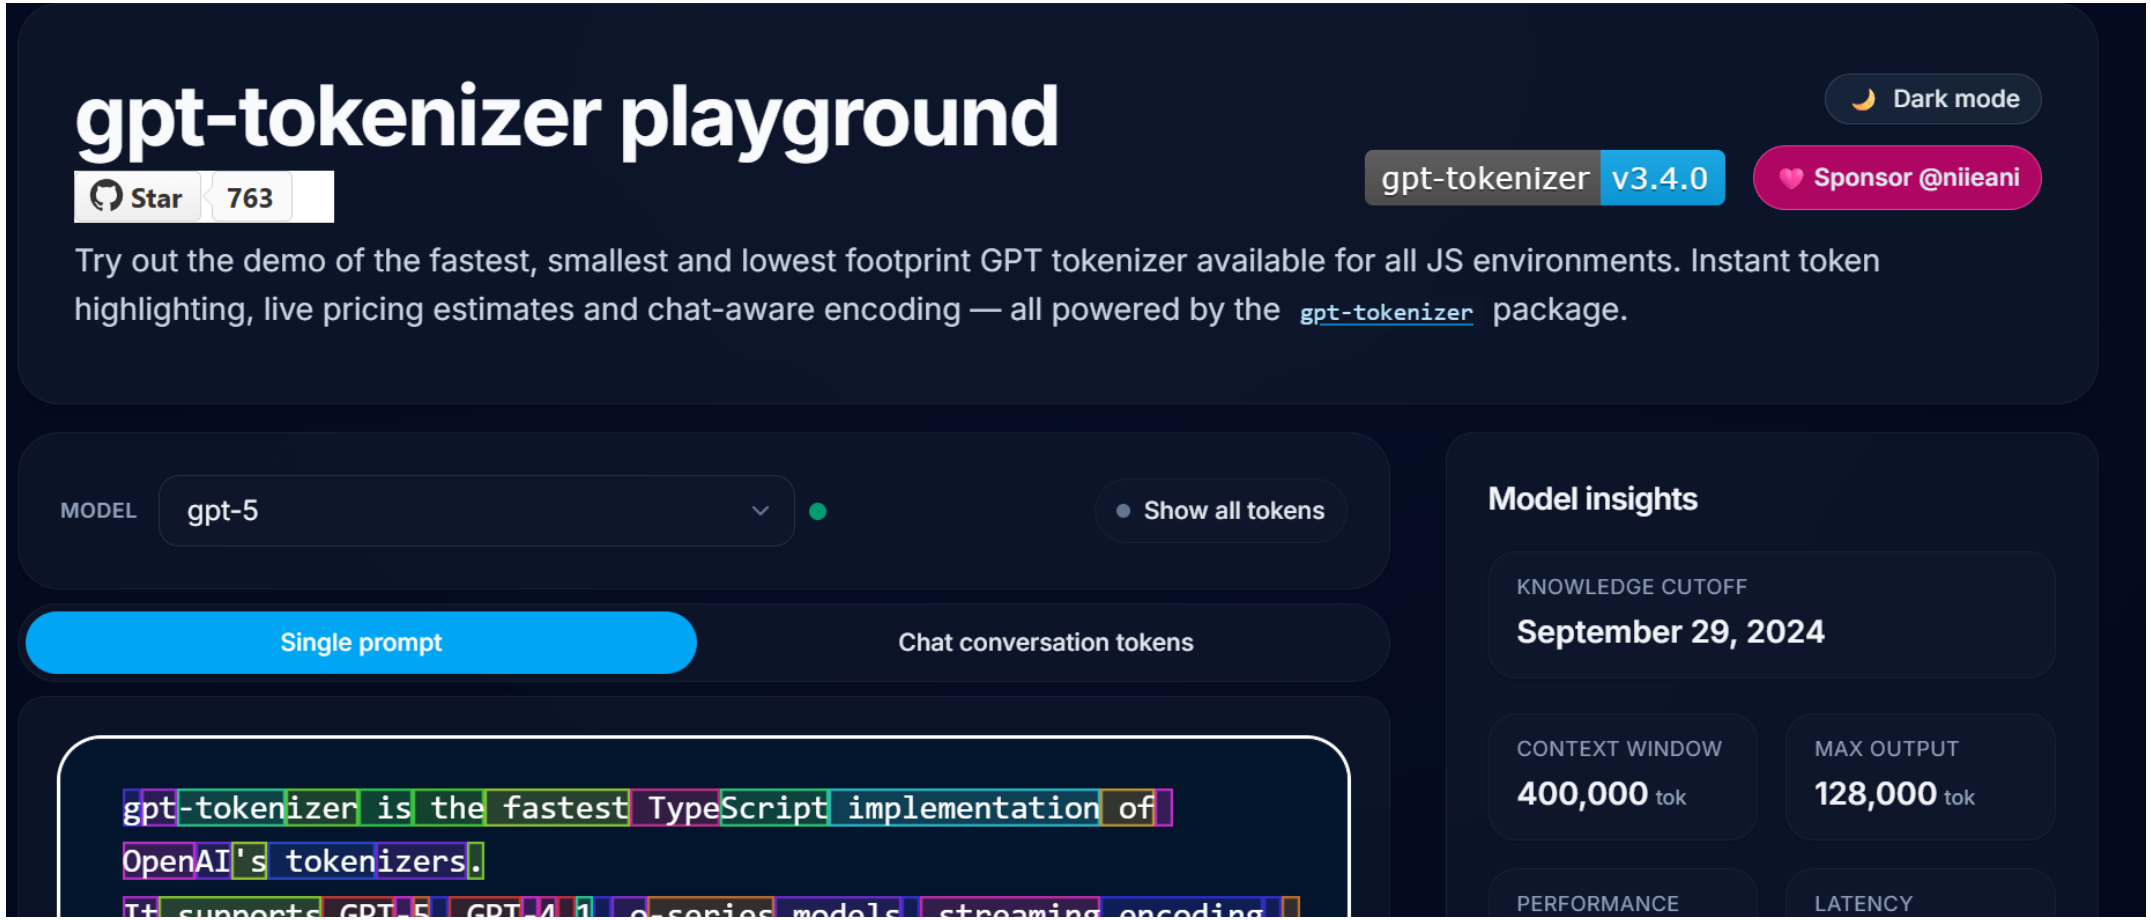
- Mantiene estructura gramatical local
- Carece de coherencia semántica global

He was elected President during the Revolutionary War and forgave Opus Paul at Rome. The regime of his crew of England, is now Arab women's icons in and the demons that use something between the characters‘ sisters in lower coil trains were always operated on the line of the ephemerable street, respectively, the graphic or other facility for deformation of a given proportion of large segments at RTUS). The B every chord was a "strongly cold internal palette pour even the white blade.”

Martens & Sutskever (2011). Learning recurrent neural networks with Hessian-free optimization.

¿Palabras o Caracteres?

La Solución Intermedia: El Token

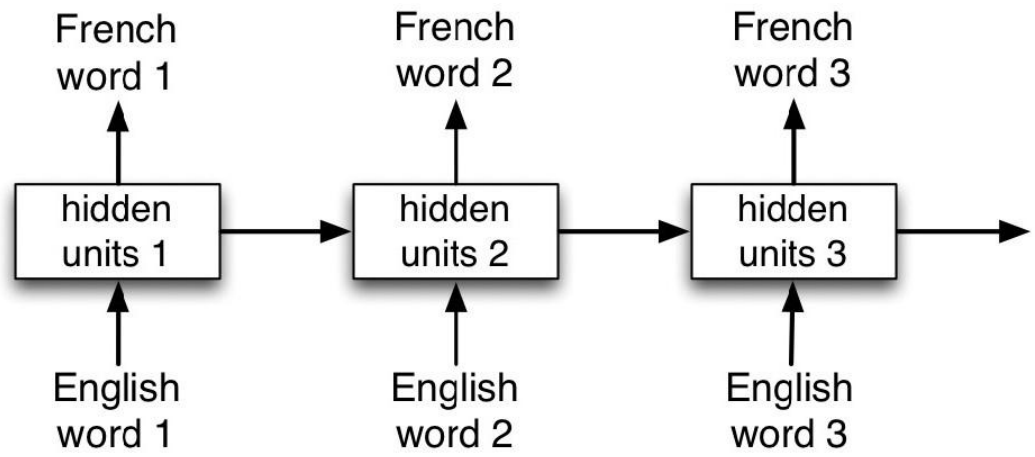


https://gpt-tokenizer.dev/

2- Traducción Automática Neuronal - Un Modelo Palabra por Palabra

- Tarea: Traducir oraciones del inglés al francés.
- Los datos de entrenamiento tienen pares de oraciones traducidas.

¿Ves algún problema potencial con este enfoque?

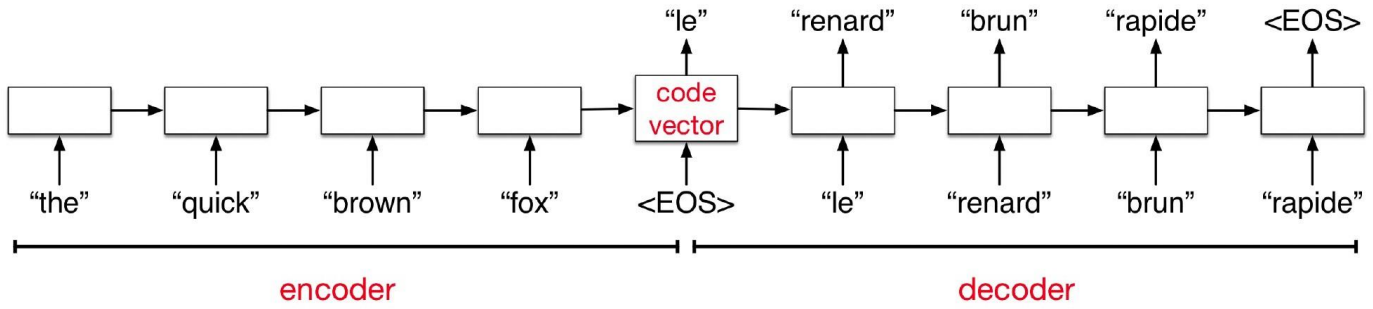


Limitaciones de la Traducción Palabra por Palabra

- Los idiomas tienen diferentes órdenes de palabras y longitudes de oración.
  - Inglés: "The blue house" → Francés: "La maison bleue“
- El modelo puede necesitar palabras futuras para resolver ambigüedades.
  - Inglés: "The doctor said she would call with the results tomorrow.“
  - Francés: "La médecin a dit qu'elle appellerait avec les résultats demain.“
- La traducción requiere contexto completo de la oración.
  - Palabras como "bank" (financiero/río) necesitan contexto para traducción correcta

Arquitectura Secuencia a Secuencia

- Dos redes distintas con pesos diferentes
- El codificador procesa la oración de entrada completa, comprimiéndola en un vector de código.
    - Token especial (<EOS>) marca los límites de la oración.
- El decodificador genera la traducción al francés palabra por palabra.
- Comprendiendo el idioma fuente | Generando el idioma objetivo



Entender el lenguaje original

Generar en un lenguaje nuevo

Comparación de Enfoques

Word-by-Word Translation:

- Los idiomas tienen diferentes órdenes de palabras y longitudes de oración
- El modelo puede necesitar palabras futuras para resolver ambigüedades
- La traducción requiere contexto completo de la oración

Cho, Kyunghyun, et al. "Learning phrase representations using RNN encoder-decoder for statistical machine translation." *arXiv preprint arXiv:1406.1078* (2014).

Encoder-Decoder Architecture:

- Maneja diferentes longitudes de oración naturalmente
- Aprende el orden de palabras específico del idioma
- Captura el contexto completo de la oración

Sutskever, Ilya, Oriol Vinyals, and Quoc V. Le. "Sequence to sequence learning with neural networks." *Advances in neural information processing systems* 27 (2014).



3- RNN como Ejecutores de Programas

- Las RNN pueden aprender a ejecutar programas Python leyéndolos carácter por carácter.
- Pueden entender y trabajar con secuencias estructuradas - no solo lenguaje natural.

Ejemplo 1: Aritmética Simple

```
Input:
  j=8584
  for x in
    range(8):
    j+=920
  b=(1500+j)
  print((b+7567)
) Target: 25011
```

Ejemplo 2: Lógica Condicional

```
Input:
  i=8827
  c=(i-5347)
  print((c+8704) if 2641<8500 else 5308)

Target: 1218
```

Zaremba, Wojciech, and Ilya Sutskever. "Learning to execute." *arXiv preprint arXiv:1410.4615* (2014).



Resultados del Ejemplo "Learning to Execute"

Input:

```
print(6652).
```

Target:	6652.
"Baseline" prediction:	6652.
"Naive" prediction:	6652.
"Mix" prediction:	6652.
"Combined" prediction:	6652.

Input:

```
print((5997-738)).
```

Target:	5259.
"Baseline" prediction:	5101.
"Naive" prediction:	5101.
"Mix" prediction:	5249.
"Combined" prediction:	5229.

Input:

```
d=5446
for x in range(8):d+=(2678 if 4803<2829 else 9848)
print((d if 5935<4845 else 3043)).
```

Target:	3043.
"Baseline" prediction:	3043.
"Naive" prediction:	3043.
"Mix" prediction:	3043.
"Combined" prediction:	3043.

Input:

```
print(((1090-3305)+9466)).
```

Target:	7251.
"Baseline" prediction:	7111.
"Naive" prediction:	7099.
"Mix" prediction:	7595.
"Combined" prediction:	7699.

Zaremba, Wojciech, and Ilya Sutskever. "Learning to execute." *arXiv preprint arXiv:1410.4615* (2014).

Análisis de Resultados

Las RNN pueden aprender a ejecutar código y realizar operaciones matemáticas con diversos grados de precisión.

Cuatro casos de prueba con diferente complejidad

Los cálculos simples se manejan perfectamente

Las operaciones complejas muestran errores de predicción

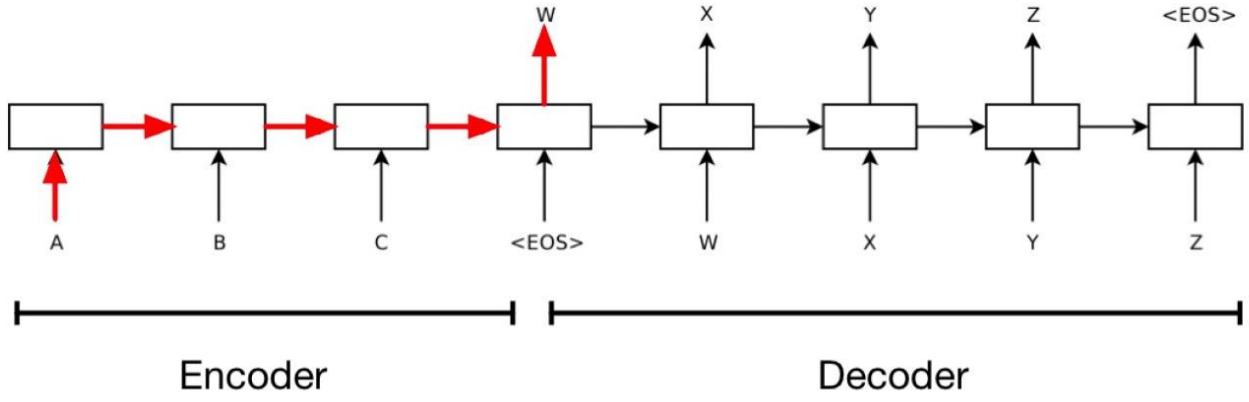
Es interesante analizar los errores e inferir el algoritmo de la red

(10 min) Break



Problema en el Entrenamiento de una RNN

- Para entrenar una RNN, debemos realizar retropropagación a través del tiempo (BPTT).
- Aunque matemáticamente sólido, BPTT sufre de gradientes explosivos/desvanecientes.
- Ejemplo: Los gradientes deben retropropagarse a través de muchos pasos temporales desde la salida (W) hasta la entrada relevante (A).





Gradientes Explosivos/Desvanecientes

Los problemas de gradiente previenen que las RNN aprendan dependencias a largo plazo en datos secuenciales, limitando su aplicación práctica.

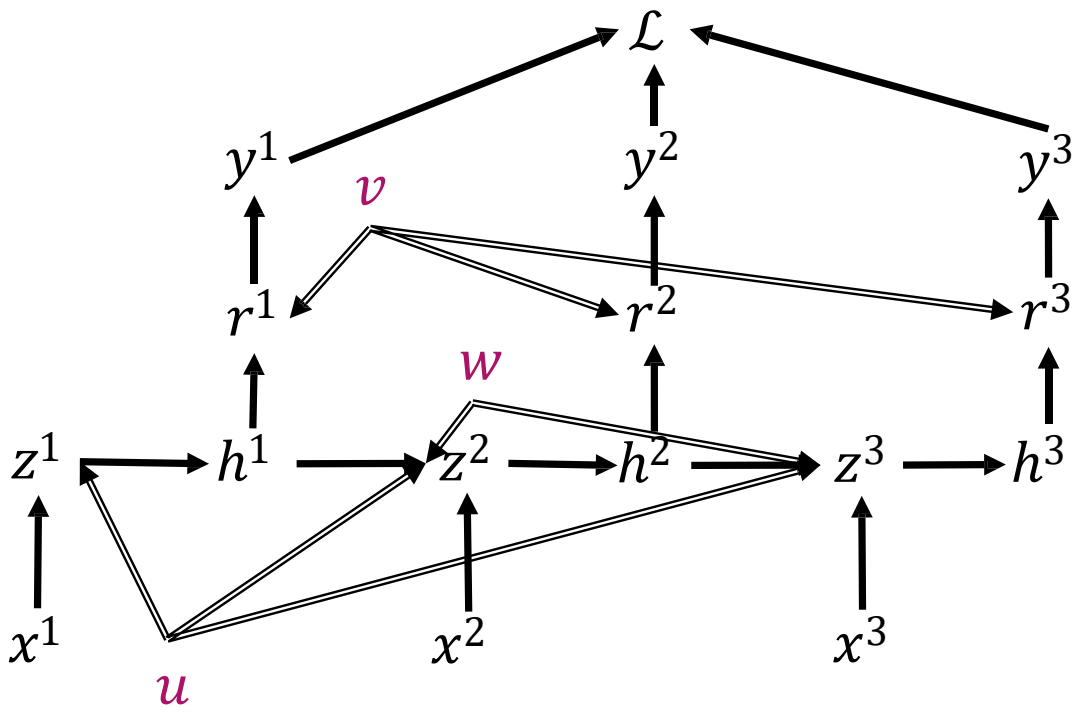
Varias preguntas:

- ¿Por qué ocurren los gradientes explosivos/desvanecientes?
- ¿Qué técnicas podemos usar para mitigar estos problemas?
- Equivalentemente, ¿cómo podemos permitir que las RNN aprendan dependencias a largo plazo?

¿Por qué las RNN Sufren de Gradientes Explosivos/Desvanecientes?

Durante la retropropagación a través del tiempo, los gradientes se multiplican por la misma matriz de pesos repetidamente.

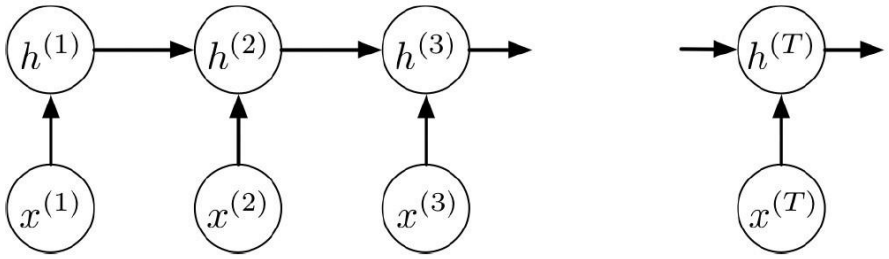
Esta multiplicación repetida causa que los gradientes exploten o se desvanezcan.



Gradientes Explosivos/Desvanecientes

$\phi'(z^{(t)}) = 1$, i.e., **linear activation.**

Una RNN simplificada



Actualización Backprop:

$$\overline{h^t} = \overline{z^{t+1}} w, \qquad \overline{z^t} = \overline{h^t} \phi'(z^t)$$

Aplicando de forma recursiva:

$\Rightarrow \overline{h^1} =$ _____

Asumiendo una activación lineal

$$\frac{\partial h^T}{\partial h^1} =$$ _____

Asume $T = 50$

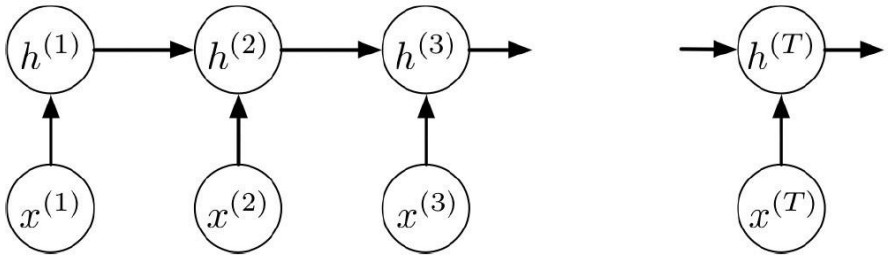
If $w = 1.1$, then $\frac{\partial h^T}{\partial h^1} =$ _____

If $w = 0.9$, then $\frac{\partial h^T}{\partial h^1} =$ _____

Gradientes Explosivos/Desvanecientes

$\phi'(z^{(t)}) = 1$, i.e., **linear activation**.

Una RNN simplificada



Actualización Backprop:

$$\overline{h^t} = \overline{z^{t+1}}w, \qquad \overline{z^t} = \overline{h^t}\phi'(z^t)$$

Aplicando de forma recursiva:

$$\Rightarrow \overline{h^1} = \boldsymbol{w^{T-1}}\phi'(z^2)\phi'(z^3)\cdots\phi'(z^T)\overline{h^T}$$

Asumiendo una activación lineal

$$\frac{\partial h^T}{\partial h^1} = \boldsymbol{w^{T-1}}\phi'(z^2)\phi'(z^3)\cdots\phi'(z^T) = \boldsymbol{w^{T-1}}$$

Asume $T = 50$

If $w = 1.1$, then $\frac{\partial h^T}{\partial h^1} = 1.1^{50} \approx 117.4$

If $w = 0.9$, then $\frac{\partial h^T}{\partial h^1} = 0.9^{50} \approx 0.005$



Gradientes Explosivos/Desvanecientes

Durante la retropropagación, los jacobianos se multiplican, lo que provoca gradientes explosivos o que desaparecen.

¿Es esto un problema durante la propagación hacia adelante?

Gradientes Explosivos/Desvanecientes

Durante la retropropagación, los jacobianos se multiplican, lo que provoca gradientes explosivos o que desaparecen.

¿Es esto un problema durante la propagación hacia adelante?

Forward pass

- Las activaciones se comprimen
- con funciones de activación no lineales,
- lo que protege contra el crecimiento exponencial.

Backward pass

- Las operaciones lineales se combinan de forma multiplicativa.
- Existe una línea delgada entre los gradientes que se desvanecen y los que explotan.



Funciones Iteradas y Mapa Logístico

Las RNN aplican repetidamente la misma función a través de pasos temporales

$$h^t = f(h^{t-1}, x^t) \qquad h^4 = f(f(f(h^1, x^2), x^3), x^4)$$

Esto es una función iterada

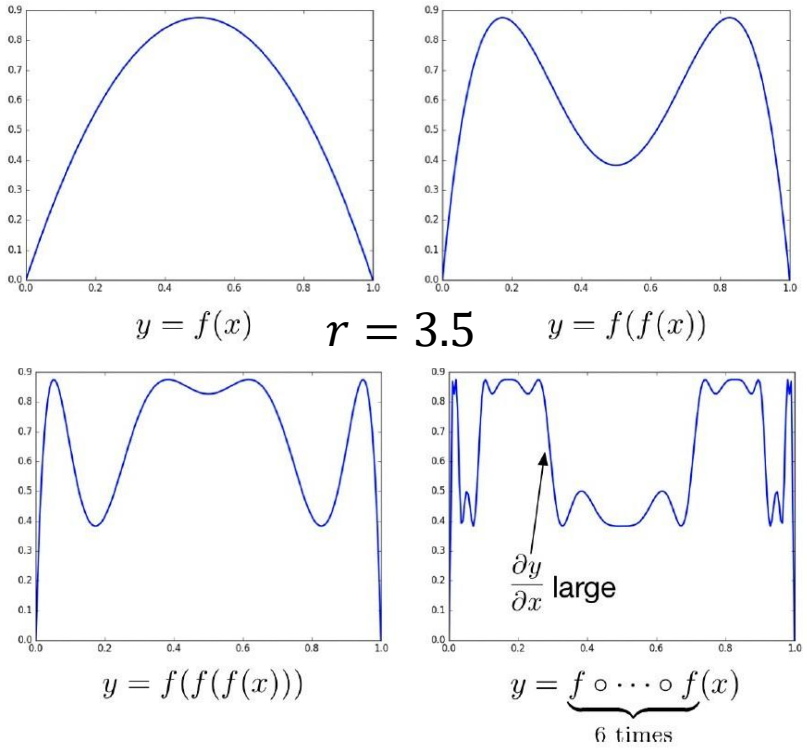
Podemos entender los gradientes de las RNN a través de funciones iteradas.

Mapa logístico

Un ejemplo clásico es el mapa logístico: $f(x) = r\,x(1-x)$.

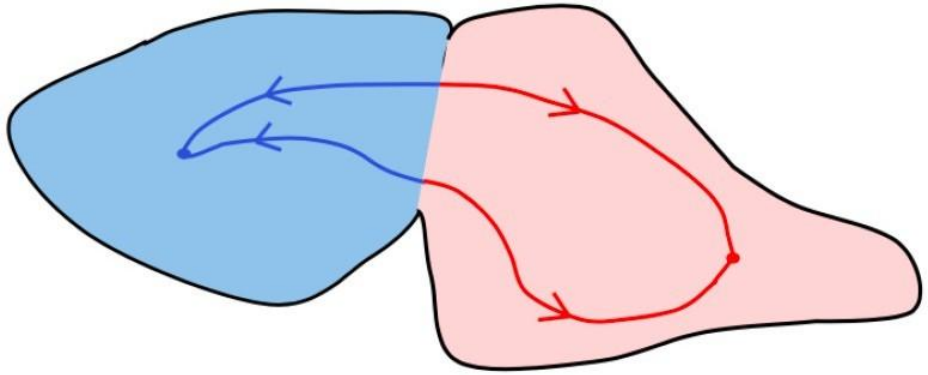
Con múltiples iteraciones, la función exhibe una variedad de comportamientos, desde puntos fijos estables hasta dinámicas caóticas, dependiendo de r.

Componer la misma función muchas veces puede resultar en un comportamiento altamente no lineal.



Dinámica de RNN - Atractores

Cada región de color representa un atractor — un estado estable al que el modelo tiende a converger.

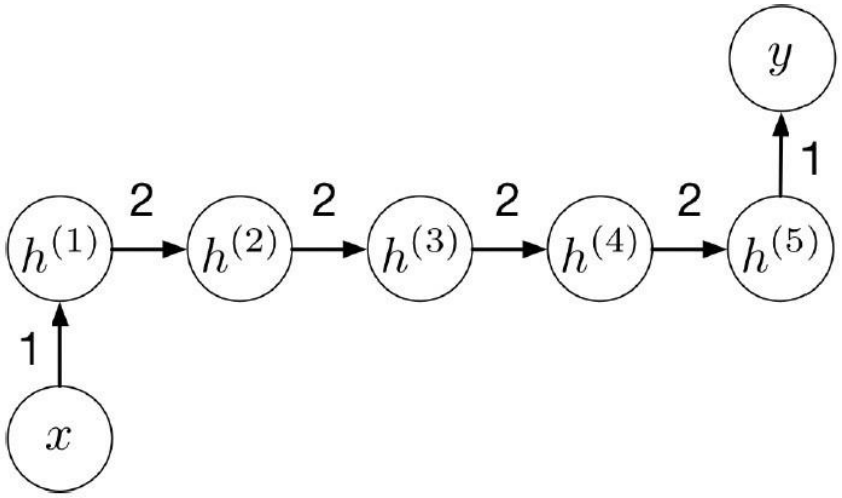


Fuente: Geoffrey Hinton, Coursera

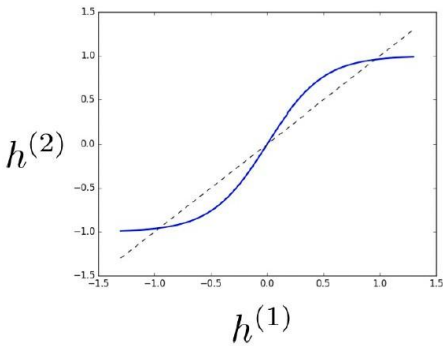
- Dentro de cada región coloreada, los gradientes se desvanecen.
  - (pequeños cambios en la entrada llevan al mismo estado final).
- En los límites, los gradientes explotan
  - (cambios minúsculos en la entrada pueden empujar al sistema de un atractor a otro).
- Durante el entrenamiento, la RNN debe equilibrar la estabilidad (permanecer dentro de un atractor) con la flexibilidad (moverse entre ellos).

Ejemplo con la Activación tanh

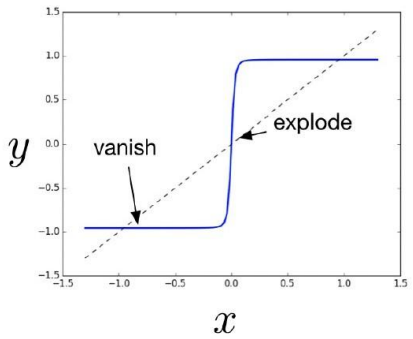
Aplicando peso = 2 en cada paso



Capas ocultas 1 → 2



Input → Output



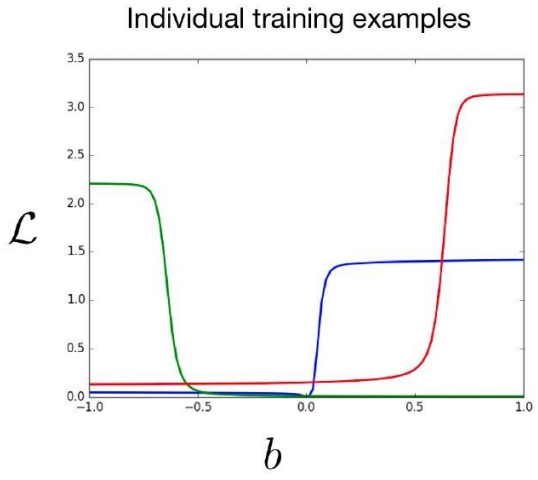
La función tanh provoca dos regiones problemáticas:

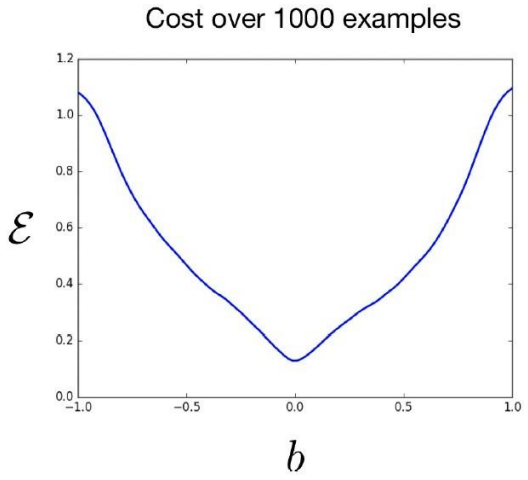
- Zonas planas, donde los gradientes se desvanecen (tanh se satura).
- Transiciones abruptas, donde los gradientes explotan, amplificadas por pesos mayores a 1.

Gradientes Individuales vs Promedio

Izquierda: La función de pérdida muestra transiciones abruptas tipo "acantilado" con respecto al sesgo → los gradientes explotan o se desvanecen.

Derecha: El costo promedio sobre 1000 ejemplos es más suave y con un comportamiento más estable.





Las RNN tienen problemas inherentes de gradientes (que explotan o se desvanecen) en ejemplos individuales.

Usar gradientes promediados sobre múltiples ejemplos puede mitigar estos problemas.

El uso de mini-lotes (mini-batches) durante el entrenamiento ayuda a estabilizar las actualizaciones de los gradientes.



Mitigando Gradientes Explosivos/Desvanecientes

- Recorte de Gradientes
- Invertir la Secuencia de Entrada
- RNN de Identidad
- Memoria a Largo-Corto Plazo (LSTM)

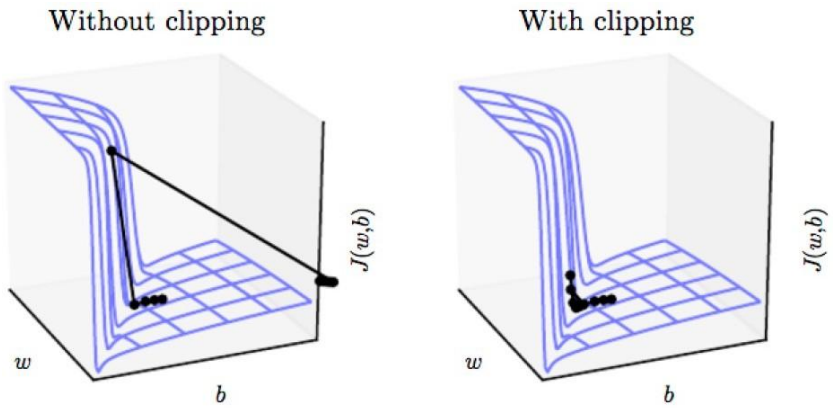
Recorte de Gradientes

Una solución simple al problema de los gradientes que explotan: Recortar el gradiente $\vec{g}$ para que tenga una norma máxima de η.

If $\|\vec{g}\| > \eta$: $\quad \vec{g} = \frac{\eta \vec{g}}{\|\vec{g}\|}$

- Se preserva la dirección del gradiente.
- Se reescala la magnitud del gradiente para que no supere η.

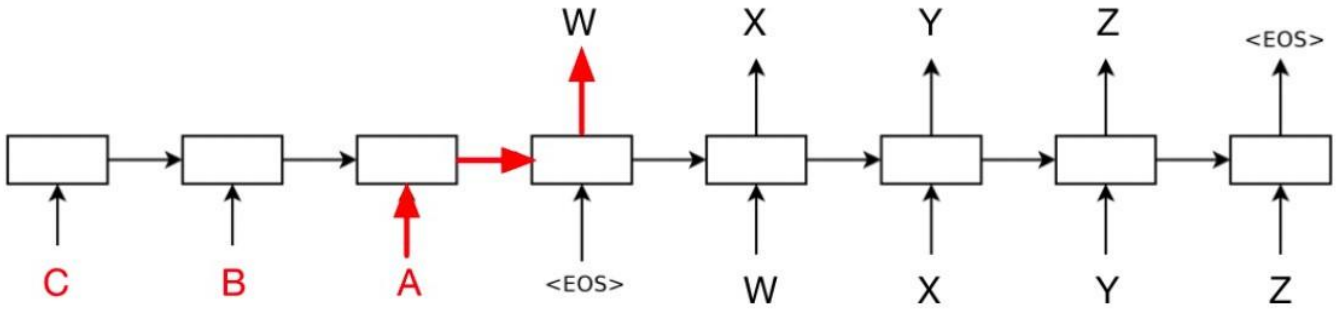
Esto implica un compromiso entre sesgo y estabilidad.



Un truco para modelos secuencia a secuencia

Invertir la secuencia de entrada (manipulación del orden de la secuencia):

- Acorta el camino entre pares de entrada-salida coincidentes.
- Favorece un aprendizaje progresivo: primero se aprenden dependencias a corto plazo, y luego las de largo plazo.



Problema Conceptual con RNN Vanilla

- Los gradientes explosivos/desvanecientes resaltan un problema conceptual
- Las unidades ocultas deberían funcionar como memoria preservando valores previos
- La función en cada paso debería aproximar la función identidad
- Pero es desafiante implementar identidad con activación no lineal

RNN de Identidad como Solución

- Inicializar matrices de pesos como matrices identidad
- Usar función de activación ReLU
- Efectos:
  - Activaciones positivas retienen valores cuando no llegan nuevas entradas
  - Activaciones negativas se recortan a cero
- Puede aprender dependencias mucho más largas que RNN vanilla
- Puede clasificar los dígitos de MNIST procesando la imagen un píxel a la vez.

Le, Quoc V., Navdeep Jaitly, and Geoffrey E. Hinton. "A simple way to initialize recurrent networks of rectified linear units." *arXiv preprint arXiv:1504.00941* (2015).

Long Short-Term Memory (LSTM)

Una arquitectura diseñada para recordar información durante largos períodos de tiempo.

En una red neuronal:

- Las activaciones representan la memoria a corto plazo.
- Los pesos representan la memoria a largo plazo.

Las LSTM están diseñadas para hacer que la memoria a corto plazo dure más tiempo.

Reemplazan cada unidad en una RNN por un bloque de memoria que decide cuándo almacenar o cuándo olvidar información.

Estructura del Bloque de Memoria LSTM

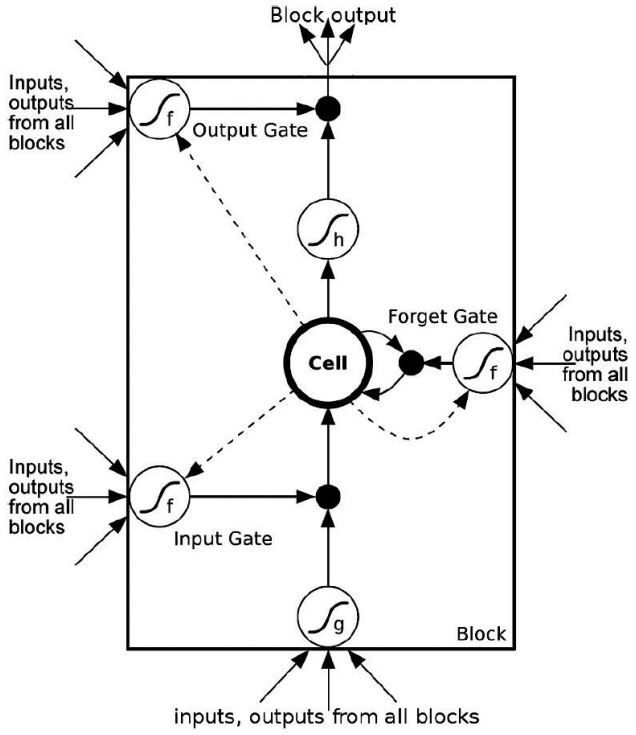
$$c_{t+1} = \text{f (forget gate)} * c_t + \text{i (input gate)} * \text{new input}$$

1. $\text{i} = 0, \text{f} = 1$:

2. $\text{i} = 1, \text{f} = 1$:

3. $\text{i} = 0, \text{f} = 0$:

4. $\text{i} = 1, \text{f} = 0$:



Estructura del Bloque de Memoria LSTM

$$c_{t+1} = \mathrm{f}\,(\text{forget gate}) * c_t + \mathrm{i}\,(\text{input gate}) * \text{new input}$$

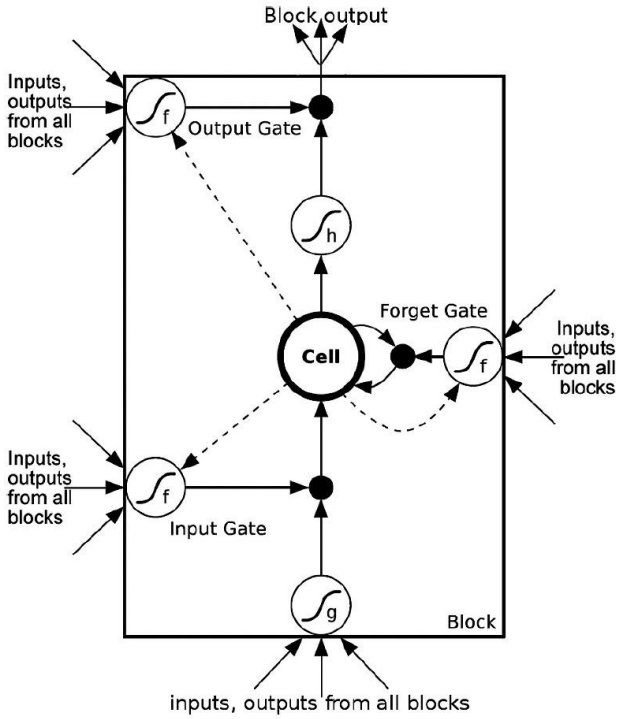
Las gates son aprendidas, no hard coded

1. $\mathrm{i} = 0, \mathrm{f} = 1$: (recordar) Se retiene la memoria anterior — comportamiento útil por defecto.

2. $\mathrm{i} = 1, \mathrm{f} = 1$: (agregar) Se agrega nueva información a la memoria existente.

3. $\mathrm{i} = 0, \mathrm{f} = 0$: (borrar) reset
Se reinicia la memoria a 0.

4. $\mathrm{i} = 1, \mathrm{f} = 0$: (sobrescribir) Se reemplaza la memoria con la nueva entrada.



Formulación Matemática LSTM

1. Calcular los valores de las compuertas

Input Gate

Forget Gate

Output Gate

Input Modulation

$$\begin{pmatrix} \mathbf{i_t} \\ \mathbf{f_t} \\ \mathbf{o_t} \\ \mathbf{g_t} \end{pmatrix} = \begin{pmatrix} \sigma \\ \sigma \\ \sigma \\ \tanh \end{pmatrix} \mathrm{W} \begin{pmatrix} \mathbf{y_t} \\ \mathbf{h_{t-1}} \end{pmatrix}$$

sigmoid comprime los valores entre 0 y 1, "cuánto dejar pasar"

tanh normaliza los valores entre -1 y 1 (capacidad de agregar o sustraer información)

g_t: ¿qué podríamos querer recordar?

i_t: ¿cuánto de eso deberíamos almacenar?

2. Actualizar el estado de la celda de memoria $\mathbf{c_t} = \mathbf{f}_t \circ \mathbf{c_{t-1}} + \mathbf{i_t} \circ \mathbf{g_t}$

3. Calcular el estado oculto $\mathbf{h_t} = \mathbf{o_t} \circ \tanh(\mathbf{c_t})$



Adopción Práctica de LSTM

- Complejidad conceptual limitó adopción por una década (desde 1997)
- 2013-14: resultados impresionantes en reconocimiento de voz y traducción
- Una de las arquitecturas RNN más usadas
- Frameworks como TensorFlow proveen implementaciones fáciles



Gated Recurrent Unit (GRU)

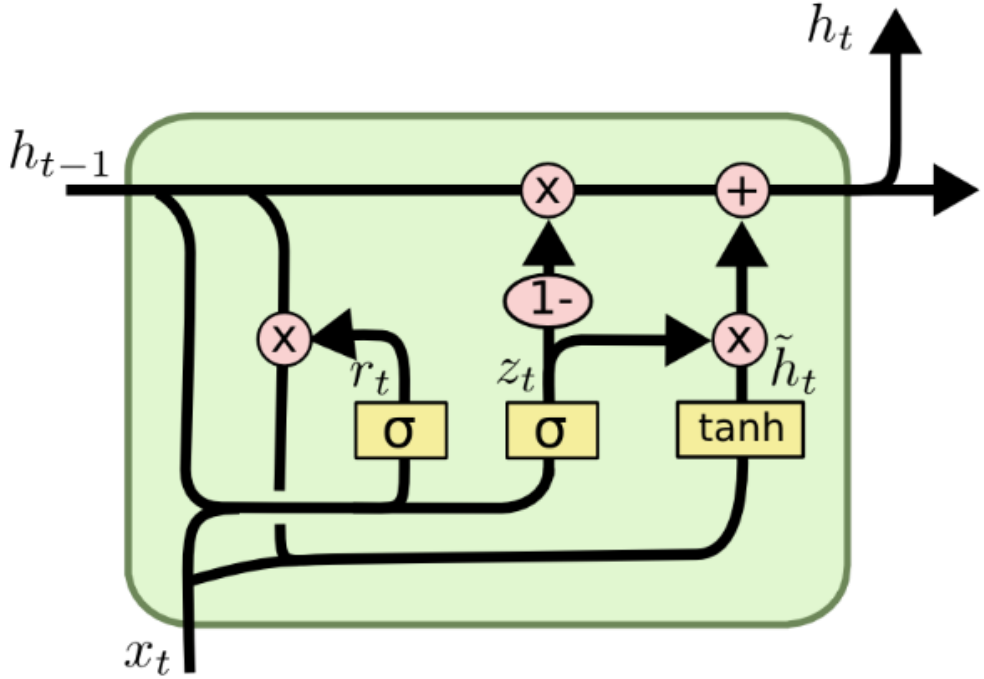
- **Propuesto por Cho et al. (2014)** como alternativa simplificada a la LSTM
- Motivacion: la LSTM tiene muchos parametros - puede lograrse rendimiento comparable con menor complejidad?
- Elimina la celda de memoria explicita (cell state ct) y funde input/forget gates en un mecanismo unificado
- Solo dos compuertas: **Reset Gate** (cuanto del pasado olvidar?) y **Update Gate** (cuanto actualizar el estado oculto?)
- Menos parametros que LSTM: entrenamiento mas rapido, menos propenso a overfitting en datasets pequenos

GRU: Reset Gate y Update Gate

- **Reset Gate (rt):** controla cuanta informacion del estado oculto pasado se usa al calcular el candidato de nuevo estado
  - rt cerca de 0: ignora la historia (nuevo comienzo)
  - rt cerca de 1: preserva el contexto previo completo
- **Update Gate (zt):** decide cuanto del estado oculto anterior se retiene versus cuanto del candidato nuevo se incorpora
  - zt cerca de 1: copia el estado anterior (memoria fuerte = dependencia larga)
  - zt cerca de 0: adopta el candidato nuevo (olvida el pasado)
- Ambas gates son vectores aprendidos, aplicados elemento a elemento (Hadamard product)
- El Update Gate unifica el rol del forget gate y el input gate de la LSTM en un solo parametro complementario (1 - zt)

GRU: Formulacion Matematica

- **1. Reset Gate:** `rt` Sigmoid lleva valores a [0,1]: cuanto del estado oculto previo conservar
- **2. Update Gate:** `zt` Decide el balance entre memoria y nueva informacion
- **3. Candidato de estado oculto:** `h~t` El reset gate (rt) filtra la informacion del pasado antes de calcular el candidato
- **4. Estado oculto final:** `ht` Interpolacion convexa entre estado anterior y candidato nuevo, controlada por zt



$$z_t = \sigma\left(W_z \cdot [h_{t-1}, x_t]\right)$$

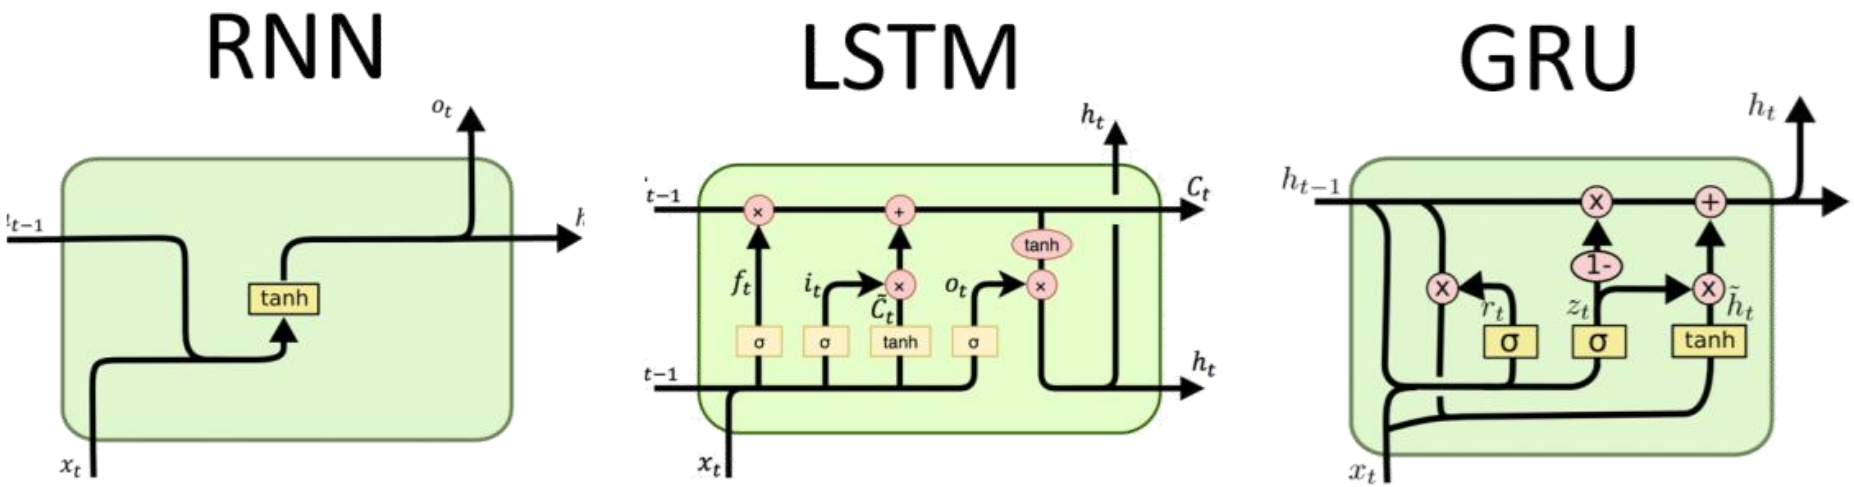
$$r_t = \sigma\left(W_r \cdot [h_{t-1}, x_t]\right)$$

$$\tilde{h}_t = \tanh\left(W \cdot [r_t * h_{t-1}, x_t]\right)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

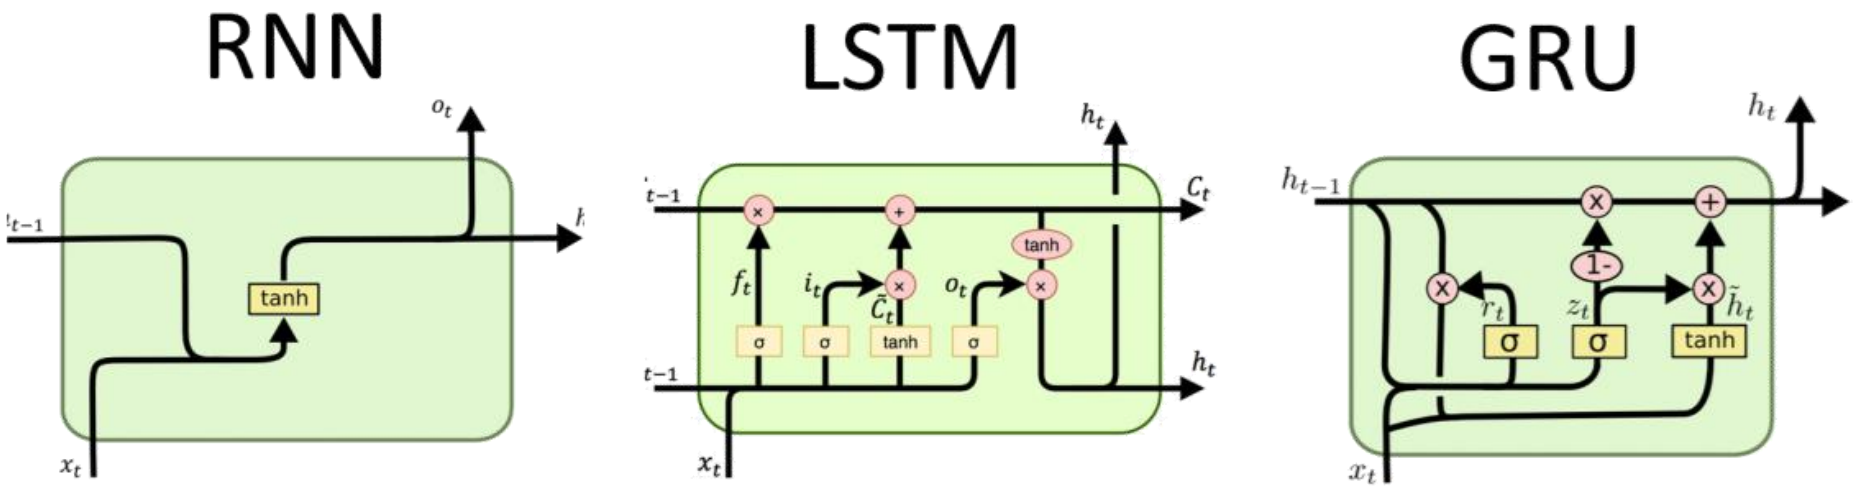
Comparativa: RNN, LSTM y GRU

- **RNN Vanilla:** simple, rapida, pero sufre de gradiente desvaneciente. Sin mecanismo de control de memoria. Falla en dependencias largas.
- **LSTM:** cell state separado + 3 gates (input, forget, output). Excelente para dependencias muy largas. Mayor capacidad pero mas parametros y tiempo de entrenamiento.
- **GRU:** solo 2 gates (reset + update), sin cell state separado. Rendimiento comparable a LSTM en muchas tareas. Entrena mas rapido con menos datos.



Comparativa: RNN, LSTM y GRU

- **Trade-offs en practica:**
  - Series temporales cortas/medianas: GRU suele igualar o superar a LSTM
  - Clasificacion de texto (secuencias largas): LSTM puede tener ventaja en dependencias muy lejanas
  - Recursos computacionales limitados o datasets pequenos: GRU es la eleccion recomendada



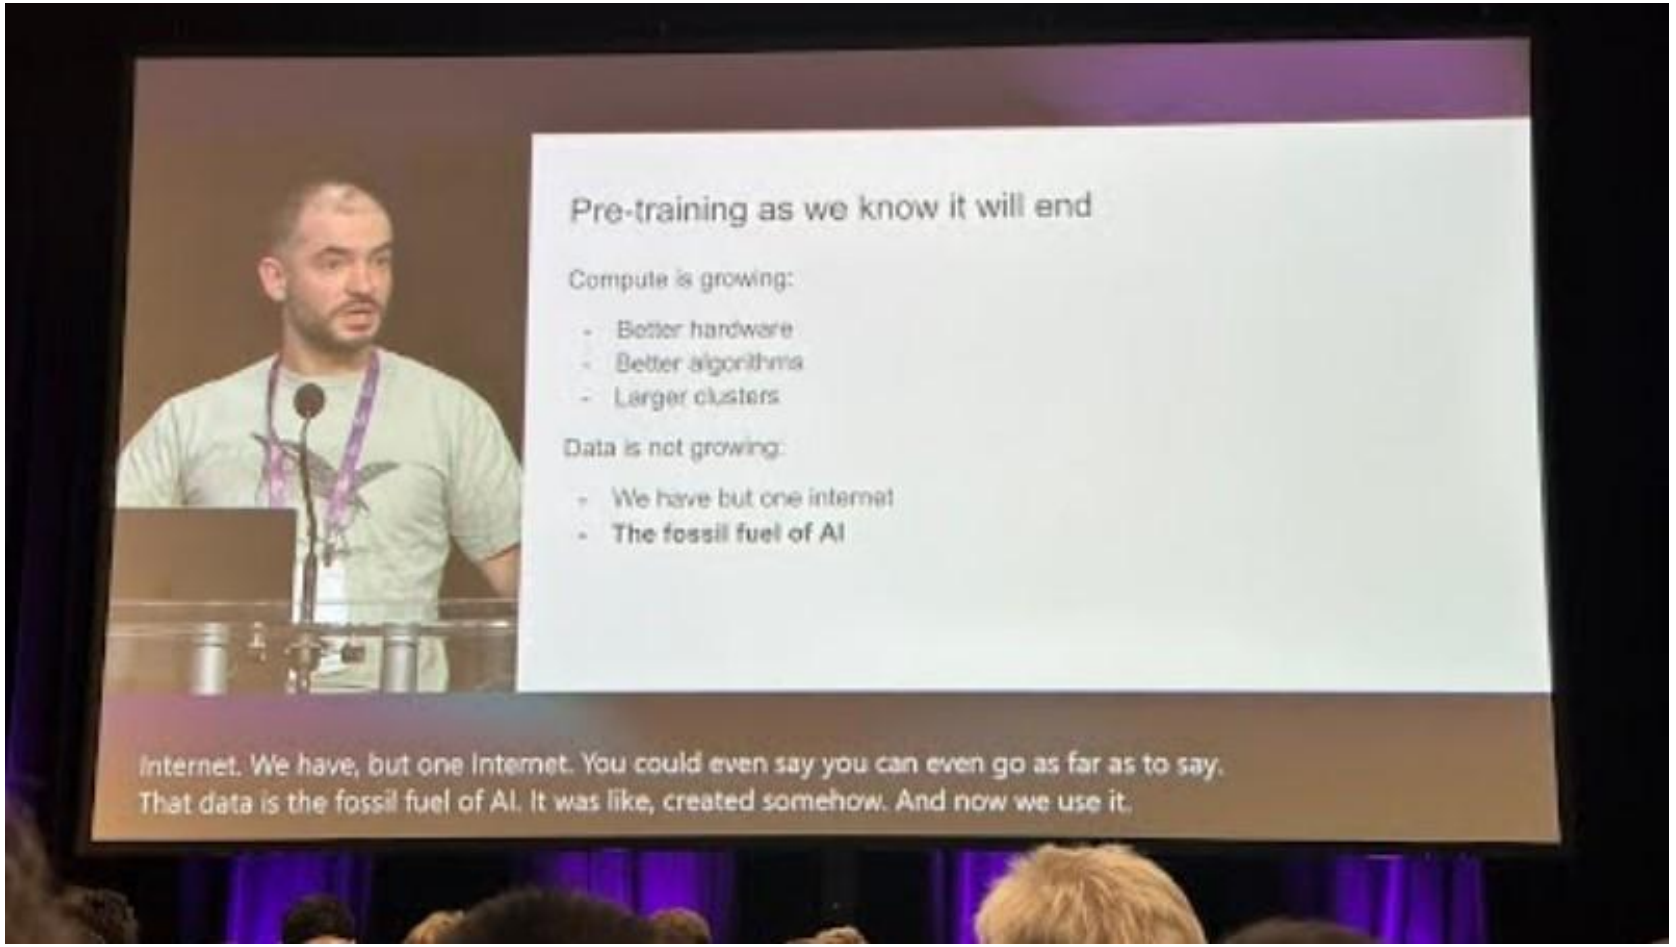


Recursos sobre RNN

Un buen artículo sobre RNN con visualizaciones

https://karpathy.github.io/2015/05/21/rnn-effectiveness/

Sequence to sequence learning with neural networks: what a decade



Ilya Sutskever at NeurIPS 2024 in Vancouver, Canada.

Sobre el Nacimiento de Deep Learning

https://www.youtube.com/watch?v=1yvBqasHLZs

Preguntas del Vibe Quest

- ¿Cómo afectan los gradientes que se desvanecen al rendimiento de una RNN simple en una tarea con dependencias a largo plazo? ¿Puedes demostrarlo con un ejemplo de código cómo esas gradientes explotan vs un modelo normal?
- ¿Puedes diseñar y entrenar una RNN para generar texto coherente a partir de un conjunto de datos pequeño? ¿Cómo afecta los tokens o embeddings utilizados para entrenar este modelo?
- ¿Qué información almacenan realmente las neuronas del estado oculto de una RNN entrenada para modelado de lenguaje? ¿Puedes visualizar las activaciones internas y encontrar neuronas que representen conceptos como comillas abiertas/cerradas, niveles de indentación o estructuras sintácticas?
- ¿Cómo evoluciona la capacidad de una RNN para aprender patrones de corto y largo plazo durante el entrenamiento de un modelo generador de texto a nivel de caracteres? ¿Puedes demostrarlo entrenando una RNN/LSTM y comparando muestras de texto generadas en distintas etapas del entrenamiento, además de analizar qué tipos de dependencias (ortografía, sintaxis, estructura y contexto) se aprenden primero y cuáles aparecen más tarde?