TAREA ACADÉMICA FINAL DE CURSO

Proyecto de investigación y aplicación en Deep Learning

Curso	Deep Learning	**Créditos**	03
Clave	INF659	**Semestre**	2026-2
Programa	Maestría en Ciencia de la Computación	**Docentes**	Dr. César A. Beltrán Castañón Dr. Rodrigo Uribe
Modalidad	Grupal (3 integrantes)		

1. Presentación y objetivo

La tarea académica final permite aplicar el conocimiento del curso al **diseño, implementación y evaluación** de algoritmos de aprendizaje profundo sobre un problema del estado del arte. El objetivo es **abrir el núcleo de una arquitectura, intervenirlo de forma controlada y explicar su comportamiento**. La evaluación se centra en: **elegir, ablacionar, diagnosticar y defender decisiones de diseño**.

2. El proyecto: ciclo de tres fases

El proyecto parte de un **artículo/modelo de referencia del estado del arte** y de un **conjunto de datos de reto**, y recorre tres fases:

Fase A — Disección instrumentada del modelo base

No basta con ejecutar el modelo: hay que abrirlo. Se exige un *architecture teardown*: conteo de parámetros y FLOPs por bloque, visualización de características intermedias, mapa del campo receptivo, y medición de latencia/memoria. El objetivo es entender **por qué** el modelo tiene la forma que tiene.

Fase B — Intervención en el núcleo

El corazón del reto: **modificar una parte del núcleo y medir el efecto con ablaciones controladas**, cada una con una hipótesis previa. Ejemplos: cambiar el backbone de un detector (ResNet → DINOv2), variar el *patch size* de un ViT, sustituir la conexión residual por concatenación densa, cambiar la función de pérdida (Dice / cross-entropy / focal), o podar y cuantizar midiendo el compromiso precisión–tamaño.

Fase C — Estrés y honestidad

Se evalúa el modelo en un **dominio de distribución distinta** a la de su preentrenamiento. Aquí el modelo «que funcionaba» suele romperse; el equipo debe **diagnosticar por qué**, conectando con transfer learning y domain adaptation, y reportar explícitamente **lo que no funcionó**.

3. Alcance y expectativas

El objetivo es una **contribución de investigación** con rigor experimental cercano a lo publicable. El equipo debe recorrer las tres fases con la profundidad siguiente:

- Formular y responder una **pregunta de investigación** clara.
- Reproducir la línea base **y posicionarla frente al estado del arte** (related work).
- Realizar **varias ablaciones sistemáticas** con hipótesis, barrido de hiperparámetros y **significancia estadística** (múltiples semillas, análisis de sensibilidad).
- Aportar un **elemento novedoso** (método, análisis o dominio) y reportar **resultados negativos** con honestidad.
- Incluir una sección obligatoria de **limitaciones, sesgos y ética**.

Se exige	Estándar de calidad
Pregunta de investigación + contribución propia.	Cercano a lo publicable en un taller.
Ablaciones sistemáticas con rigor estadístico.	Múltiples semillas; resultados con incertidumbre.
Related work y posicionamiento frente al SOTA.	Referencias actuales y pertinentes.
Defensa oral individual de las decisiones.	Dominio del núcleo, no solo de la API.

4. Recursos: modelos y datasets

Como referencia general de implementaciones abiertas se mantiene el directorio Papers With Code (paperswithcode.com/sota). Gracias a la colaboración con **Meta AI**, los equipos disponen de acceso a sus modelos (huggingface.co/facebook) y a sus conjuntos de datos (ai.meta.com/ai-for-good/datasets). Se recomienda **emparejar un modelo core con un dataset de reto** que lo saque de su dominio de preentrenamiento:

Modelo core (Meta)	Dataset de reto	Foco del núcleo
SAM / SAM 2	SA-1B · dominio médico o satelital	Segmentación promptable: adaptar sin prompts humanos; analizar el mask decoder.
DINOv2 / DINOv3	Canopy Height Maps · satélite	Features auto-supervisadas: linear probing vs fine-tuning fuera de ImageNet.
DETR / RF-DETR	Detección (COCO) · dominio propio	Predicción de conjunto (Hungarian matching) vs anchors; backbone swap.
Detección de deepfakes	DFDC (Deepfake Detection Challenge)	Generalización cross-manipulation; robustez.
Backbones varios	Datasets AI-for-Good (población, movilidad)	Shift de dominio en problemas socialmente relevantes; uso responsable.

Cada equipo debe verificar y respetar la licencia y los términos de uso de modelos y datos. Los conjuntos socialmente sensibles exigen especial cuidado con la privacidad y el sesgo.

5. Banco de proyectos-reto

Los temas se formulan como **preguntas de investigación**. Cada tema puede ser elegido por un **máximo de 2 equipos**, con artículo/modelo distinto. La versión de posgrado **extiende** la línea base a una contribución:

- **¿Sirven las features de DINOv2 fuera de ImageNet?** Linear probing y fine-tuning parcial sobre datos satelitales, análisis por capa y eficiencia por muestra etiquetada.
- **El costo del prompt en SAM.** Caracterizar dónde y por qué falla el mask decoder sin prompts, y proponer una mitigación.
- **Predicción de conjunto vs anchors.** Analizar la convergencia del Hungarian matching y el desempeño en objetos pequeños.
- **Backbone swap.** Aislar el efecto del preentrenamiento auto-supervisado con ablaciones controladas.
- **Robustez de detectores de deepfakes.** Proponer y validar una estrategia de generalización cross-manipulation.
- **Compresión con honestidad.** Explicar qué se rompe primero al cuantizar/podar y por qué, con análisis de errores.

Se admiten propuestas fuera de este banco previa aprobación docente, siempre que respeten el ciclo de tres fases y el nivel exigido.

6. Entregables y cronograma

Entregable	Fecha límite	Puntaje
E1 · Propuesta + *teardown* + intervención preliminar + cuaderno de decisiones + related work inicial.	Lunes 12 de octubre de 2026	4 puntos
E2 · Registro de poster en **WAIMLAP**.	Hasta 16 de octubre de 2026	2 puntos
E3 · Entrega de trabajo.	Lunes 16 de noviembre de 2026	2 puntos
E2 · Presentación oral en **WAIMLAP** + defensa.	18–20 de noviembre de 2026	6 puntos
E3 · **Artículo de taller** final (4–8 pág., IEEE/LNCS) revisado con la retroalimentación del workshop.	Lunes 30 de noviembre de 2026	6 puntos

7. Evaluación (rúbrica)

La rúbrica premia la contribución, el rigor y la comprensión por encima del resultado alcanzado.

Criterio	Peso
Originalidad y contribución	20 %
Rigor experimental (ablaciones, estadística)	20 %
Análisis de fallos y límites	15 %
Calidad del artículo (claridad, related work)	15 %
Defensa oral individual	20 %
Reproducibilidad y ética de datos	10 %

8. Política de uso de asistentes de IA

- El uso de agentes de código y asistentes de IA está **permitido y se fomenta** como herramienta de trabajo.
- El **cuaderno de decisiones** (design log) debe registrar cada decisión arquitectónica y su justificación, e indicar dónde se usó asistencia de IA.
- Antes de cada ablación, el equipo escribe **qué espera que ocurra y por qué**; luego contrasta con el resultado. Se evalúa el modelo mental, no la ejecución.
- La **defensa oral individual** es la salvaguarda central: cada integrante responde preguntas sobre cualquier decisión del código y del diseño. No poder explicar el propio trabajo penaliza la nota individual.
- Delegar la ejecución es válido; **delegar la comprensión no lo es**.

9. Formato de entrega

- **Repositorio en GitHub**: notebooks reproducibles, README con instrucciones, semillas fijadas y entorno documentado.
- **Documento**: artículo de taller (4–8 pág., formato IEEE/LNCS) según la plantilla de WAIMLAP.
- **Presentación** en el workshop.
- Toda figura, dataset o modelo de terceros debe estar **correctamente citado** y con su licencia respetada.

10. Limitaciones, sesgos y ética (obligatorio)

El artículo debe incluir una sección de **limitaciones y consideraciones éticas**. Cuando se usen conjuntos socialmente sensibles (población, riqueza, movilidad), es obligatorio discutir **privacidad, representatividad y posibles sesgos**, y citar la documentación oficial del dataset.